# ANALISIS PERFORMA ARSITEKTUR *RESNET-18* DAN *RESNET-50* DENGAN PENERAPAN AUGMENTASI DATA KELAS MINORITAS PADA DATASET DERMAMNIST

**TUGAS AKHIR**

Diajukan sebagai syarat menyelesaikan jenjang strata Satu (S-1) di Program Studi Teknik Informatika, Fakultas Teknologi Industri, Institut Teknologi Sumatera


**Oleh:**

**Arkan Hariz Chandrawinata Liem**

**122140038**



**PROGRAM STUDI TEKNIK INFORMATIKA**

**FAKULTAS TEKNOLOGI INDUSTRI**

**INSTITUT TEKNOLOGI SUMATERA**

**LAMPUNG SELATAN**


**2026**

# LEMBAR PENGESAHAN

Saya menyatakan bahwa Tugas Akhir berjudul "ANALISIS PERFORMA ARSITEKTUR *RESNET-18* DAN *RESNET-50* DENGAN PENERAPAN AUGMENTASI DATA KELAS MINORITAS PADA DATASET DERMAMNIST" merupakan hasil karya saya sendiri dan belum pernah diajukan, baik sebagian maupun seluruhnya, di Institut Teknologi Sumatera atau institusi pendidikan lain oleh saya maupun pihak lain.

Lampung Selatan, 08-04-2026
Penulis,

Foto 2x3

Arkan Hariz Chandrawinata Liem
NIM. 122140038

Diperiksa dan disetujui oleh,

Pembimbing

1. Hartanto Tantriawan, S.Kom., M.Kom.
   NIP. 19920522 2019 03 1 012 .....

Penguji

1. Mohamad Idris, S.Si., M.Sc.
   NIP. 19861010 2019 03 1 016 .....
2. Eko Dwi Nugroho, S.Kom., M.Cs.
   NIP. 19910209 202406 1 001 .....

Disahkan oleh,
Koordinator Program Studi Teknik Informatika
Fakultas Teknologi Industri
Institut Teknologi Sumatera

Andika Setiawan, S.Kom., M.Cs.
NIP. 19911127 2022 03 1 007

# HALAMAN PERNYATAAN ORISINALITAS

**Tugas Akhir dengan judul "ANALISIS PERFORMA ARSITEKTUR *RESNET-18* DAN *RESNET-50* DENGAN PENERAPAN AUGMENTASI DATA KELAS MINORITAS PADA DATASET DERMAMNIST" adalah karya saya sendiri, dan semua sumber baik yang dikutip maupun dirujuk telah saya nyatakan benar.**

| | | |
|---|---|---|
| **Nama** | **:** | **Arkan Hariz Chandrawinata Liem** |
| **NIM** | **:** | **122140038** |
| **Tanda Tangan** | **:** | **.....** |
| **Tanggal** | **:** | **.....** |

## HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS

Sebagai civitas akademik Institut Teknologi Sumatera, saya yang bertanda tangan di bawah ini:

Nama : Arkan Hariz Chandrawinata Liem
NIM : 122140038
Program Studi : Teknik Informatika
Fakultas : Teknologi Industri
Jenis Karya : Tugas Akhir

demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Institut Teknologi Sumatera **Hak Bebas Royalti Noneksklusif** ***(Non-exclusive Royalty Free Right)*** atas karya ilmiah saya yang berjudul:

**ANALISIS PERFORMA ARSITEKTUR *RESNET-18* DAN *RESNET-50* DENGAN PENERAPAN AUGMENTASI DATA KELAS MINORITAS PADA DATASET DERMAMNIST**

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Institut Teknologi Sumatera berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Lampung Selatan
Pada tanggal : 08-04-2026

Yang menyatakan

Arkan Hariz Chandrawinata Liem

# KATA PENGANTAR

Puji syukur kehadirat Allah SWT/Tuhan Yang Maha Esa atas limpahan rahmat, karunia, serta petunjuk-Nya sehingga penyusunan tugas akhir ini telah terselesaikan dengan baik. Dalam penyusunan tugas akhir ini penulis telah banyak mendapatkan arahan, bantuan, serta dukungan dari berbagai pihak. Oleh karena itu pada kesempatan ini penulis mengucapan terima kasih kepada:

1. Prof. Dr. I Nyoman Pugeg Aryantha selaku Rektor Institut Teknologi Sumatera.
2. Hadi Teguh Yudistira, S.T., Ph.D. selaku Dekan Fakultas Teknologi Industri.
3. Andika Setiawan, S.Kom., M.Cs. selaku Ketua Program Studi Teknik Informatika.
4. Hartanto Tantriawan, S.Kom., M.Kom. selaku Dosen Pembimbing atas ide, waktu, tenaga, perhatian, dan masukan yang telah disumbangsihkan kepada penulis.
5. [Isi nama lainnya]

Akhir kata penulis berharap semoga tugas akhir ini dapat memberikan manfaat bagi kita semua.

# RINGKASAN

ANALISIS PERFORMA ARSITEKTUR *RESNET-18* DAN *RESNET-50* DENGAN PENERAPAN AUGMENTASI DATA KELAS MINORITAS PADA DATASET DERMAMNIST

Arkan Hariz Chandrawinata Liem

*Halaman Ringkasan berisi uraian singkat tentang latar belakang masalah, rumusan masalah, tujuan, metodologi penelitian, hasil dan analisis data, serta kesimpulan dan saran. Isi ringkasan tidak lebih dari 1000 kata (sekitar maksimal 2 halaman).*

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

# ABSTRAK

ANALISIS PERFORMA ARSITEKTUR *RESNET-18* DAN *RESNET-50* DENGAN PENERAPAN AUGMENTASI DATA KELAS MINORITAS PADA DATASET DERMAMNIST

Arkan Hariz Chandrawinata Liem

Klasifikasi penyakit kulit merupakan salah satu penerapan kecerdasan buatan dalam bidang medis, khususnya untuk proses diagnosis otomatis melalui analisis citra medis. Dataset yang digunakan dalam penelitian ini yaitu DermaMNIST dengan 7 kelas didalamnya. Dataset ini memiliki suatu masalah yaitu ketidakseimbangan distribusi data antar kelas nya yang terdapat potensi untuk memengaruhi performa model, terutama pada kelas minoritas. Kondisi ini menyebabkan model cenderung akurat dalam memprediksi terhadap kelas mayoritas. Penelitian ini bertujuan menganalisis pengaruh penerapan augmentasi data pada kelas minoritas terhadap performa model *deep learning* dalam klasifikasi citra penyakit kulit. Model *CNN based* yang digunakan adalah *ResNet-18* dan *ResNet-50*, yang di-*train* dengan dua ukuran citra yaitu 28x28 dan 224x224. Penelitian meliputi tahap *preprocessing data*, penerapan augmentasi citra pada kelas minoritas, *training* model, dan evaluasi performa model menggunakan metrik *accuracy*, *precision*, *recall*, *f1-score*, AUC, dan MCC. Hasil penelitian menunjukkan bahwa model *ResNet-18* yang di-*train* dengan citra ukuran 224x224 memperoleh akurasi 80%, *precision macro* 71%, *recall macro* 76%, *f1-score macro* 73%, AUC 95%, dan MCC 64%. Berdasarkan hasil penelitian, penerapan augmentasi data pada kelas minoritas dapat mengurangi dampak ketidakseimbangan data serta meningkatkan kemampuan model dalam melakukan klasifikasi citra penyakit kulit.

**Kata Kunci: Klasifikasi Penyakit Kulit, Augmentasi Data, ResNet-18, ResNet-50, DermaMNIST**

# ABSTRACT

*ANALYSIS PERFORMANCE OF RESNET-18 AND RESNET-50 ARCHITECTURES WITH THE APPLICATION OF MINORITY CLASS DATA AUGMENTATION ON THE DERMAMNIST DATASET*

Arkan Hariz Chandrawinata Liem

Skin disease classification is one of the applications of artificial intelligence in the medical field, particularly for automated diagnosis through medical image analysis. The dataset used in this study is DermaMNIST, which consists of seven classes. However, this dataset has an issue related to class imbalance in the data distribution, which may affect the performance of the model, especially for minority classes. This condition causes the model to be more accurate in predicting the majority classes. This study aims to analyze the effect of applying data augmentation to minority classes on the performance of deep learning models in skin disease image classification. The CNN-based models used in this research are ResNet-18 and ResNet-50, which were trained using two image sizes: 28x28 and 224x224. The research process includes data preprocessing, applying image augmentation to minority classes, model training, and model performance evaluation using several metrics, including accuracy, precision, recall, F1-score, AUC, and Matthews Correlation Coefficient (MCC). The results show that the ResNet-18 model trained with 224x224 image size achieved an accuracy of 80%, precision macro 71%, recall macro 76%, F1-score macro 73%, AUC 95%, and MCC 64%. Based on these results, the application of data augmentation on minority classes can reduce the impact of data imbalance and improve the model's ability to classify skin disease images.

**Keywords: Skin Disease Classification, Data Augmentation, ResNet-18, ResNet-50, DermaMNIST**

# DAFTAR ISI

**LEMBAR PENGESAHAN** . . . . . **ii**

**HALAMAN PERNYATAAN ORISINALITAS** . . . . . **iii**

**HALAMAN PERSETUJUAN PUBLIKASI** . . . . . **iv**

**KATA PENGANTAR** . . . . . **v**

**RINGKASAN** . . . . . **vi**

**ABSTRAK** . . . . . **vii**

**ABSTRACT** . . . . . **viii**

**DAFTAR ISI** . . . . . **ix**

**DAFTAR TABEL** . . . . . **xii**

**DAFTAR GAMBAR** . . . . . **xiii**

**DAFTAR RUMUS** . . . . . **xv**

**DAFTAR KODE** . . . . . **xvi**

**BAB I PENDAHULUAN** . . . . . **1**

1.1 Latar Belakang . . . . . 1

1.2 Rumusan Masalah . . . . . 3

1.3 Tujuan Penelitian . . . . . 4

1.4 Batasan Masalah . . . . . 4

1.5 Manfaat Penelitian . . . . . 4

1.6 Sistematika Penulisan . . . . . 5

**BAB II TINJAUAN PUSTAKA** . . . . . **7**

2.1 Tinjauan Pustaka . . . . . 7

2.2 Dasar Teori . . . . . 12

2.2.1 DermaMNIST . . . . . 12
2.2.1.1 Actinic Keratosis and Intraepithelial Carcinoma . . . . 12
2.2.1.2 Basal Cell Carcinoma . . . . . 13
2.2.1.3 Benign Keratosis-Like Lesions . . . . . 14
2.2.1.4 Dermatofibroma . . . . . 15
2.2.1.5 Melanoma . . . . . 15
2.2.1.6 Melanocytic Nevi . . . . . 16
2.2.1.7 Vascular Lesions . . . . . 17
2.2.2 Imbalanced Data . . . . . 17
2.2.3 Data Augmentasi . . . . . 18
2.2.3.1 *Flip* . . . . . 18
2.2.3.2 Rotasi . . . . . 18
2.2.3.3 *Random Erasing* . . . . . 19
2.2.3.4 *Random Augmentation* . . . . . 19
2.2.3.5 *Color Jitter* . . . . . 19
2.2.4 Convolutional Neural Network . . . . . 20
2.2.5 Residual Network . . . . . 22
2.2.5.1 Residual Learning . . . . . 25
2.2.5.2 Shortcut Connections . . . . . 25
2.2.6 Confusion Matrix . . . . . 25
2.2.7 Matthews Correlation Coefficient . . . . . 28

**BAB III METODE PENELITIAN . . . . . 29**
3.1 Alur Penelitian . . . . . 29
3.2 Penjabaran Langkah Penelitian . . . . . 29
3.2.1 Identifikasi Masalah . . . . . 29
3.2.2 Studi Literatur . . . . . 30
3.2.3 Akuisisi Dataset . . . . . 30
3.2.4 Preprocessing Data . . . . . 31

3.2.5 Augmentasi Kelas Minoritas . . . . . 31
3.2.6 Perancangan Model ResNet-18 dan ResNet-50 . . . . . 32
3.2.7 Evaluasi . . . . . 32
3.3 Alat dan Bahan Tugas Akhir . . . . . 32
3.3.1 Alat . . . . . 32
3.3.2 Bahan . . . . . 33
3.4 Metode Pengembangan . . . . . 33
3.5 Ilustrasi Perhitungan Metode . . . . . 37
3.5.1 Ilustrasi Perhitungan Konvolusi . . . . . 37
3.5.2 Ilustrasi Perhitungan Fungsi Aktivasi ReLU . . . . . 40
3.5.3 Max Pooling dan Average Pooling . . . . . 41
3.6 Rancangan Pengujian . . . . . 42
3.6.1 Pengukuran *Confusion Matrix* . . . . . 42
3.6.2 Perhitungan Macro Average . . . . . 45
3.6.3 Perhitungan Matthews Correlation Coefficient . . . . . 46

**BAB IV HASIL DAN PEMBAHASAN . . . . . 49**
4.1 Hasil Penelitian . . . . . 49
4.1.1 Akuisisi Dataset . . . . . 49
4.1.2 Pembagian Dataset . . . . . 51
4.1.3 *Preprocessing* Data . . . . . 51
4.1.4 Augmentasi Data . . . . . 52
4.1.4.1 *Flip* . . . . . 53
4.1.4.2 *Rotation* . . . . . 53
4.1.4.3 *Color Jitter* . . . . . 54
4.1.4.4 *Random Erasing* . . . . . 54
4.1.4.5 *Random Augment* . . . . . 55
4.1.5 Hasil *Training* Model . . . . . 55
4.1.5.1 Hasil *ResNet-18* Menggunakan Citra *Size* 28x28 Piksel 55

4.1.5.2 Hasil *ResNet-50* Menggunakan Citra *Size* 28x28 Piksel 57
4.1.5.3 Hasil *ResNet-18* Menggunakan Citra *Size* 224x224 Piksel . . . . . 58
4.1.5.4 Hasil *ResNet-50* Menggunakan Citra *Size* 224x224 Piksel . . . . . 59
4.2 Analisis Hasil Penelitian . . . . . 60
4.2.1 Hasil Model *Baseline* . . . . . 62
4.2.1.1 Model *ResNet-18 Baseline* . . . . . 63
4.2.1.2 Model *ResNet-50 Baseline* . . . . . 64
4.2.2 Perbandingan Model *Baseline* Dengan Model Sendiri . . . . . 66
4.2.3 Penggunaan *Class Weight* . . . . . 68
4.2.4 Perbandingan Hasil *Baseline* Dengan Hasil Sendiri . . . . . 68

**BAB V KESIMPULAN DAN SARAN . . . . . 76**
5.1 Kesimpulan . . . . . 76
5.2 Saran . . . . . 77

**DAFTAR PUSTAKA . . . . . 78**

**LAMPIRAN . . . . . 83**
A Dataset . . . . . 83
B Hasil Wawancara . . . . . 83
C Rincian Kasus Uji . . . . . 83

# DAFTAR TABEL

Tabel 2.1 Tabel Studi Literatur . . . . . 10
Tabel 2.2 Struktur ResNet-18 [32] . . . . . 23
Tabel 2.3 Struktur ResNet-50 [32] . . . . . 24
Tabel 3.1 Contoh Hasil Confusion Matrix . . . . . 42
Tabel 3.2 Hasil Perhitungan Metrik Evaluasi per Kelas . . . . . 45
Tabel 4.1 Contoh Citra dari Setiap Kelas Penyakit . . . . . 49
Tabel 4.2 Persebaran Data . . . . . 51
Tabel 4.3 Hasil Evaluasi *ResNet-18* Dengan Citra 28×28 Piksel . . . . . 56
Tabel 4.4 Hasil Evaluasi *ResNet-50* Dengan Citra 28×28 Piksel . . . . . 57
Tabel 4.5 Hasil Evaluasi *ResNet-18* Dengan Citra 224×224 Piksel . . . 58
Tabel 4.6 Hasil Evaluasi *ResNet-50* Dengan Citra 224×224 Piksel . . . 59
Tabel 4.7 Hasil Evaluasi *ResNet-18 Baseline* dengan Citra 28×28 Piksel . . . . . 63
Tabel 4.8 Hasil Evaluasi *ResNet-18 Baseline* dengan Citra 224×224 Piksel . . . . . 64
Tabel 4.9 Hasil Evaluasi *ResNet-50 Baseline* dengan Citra 28×28 Piksel . . . . . 65
Tabel 4.10 Hasil Evaluasi *ResNet-50 Baseline* dengan Citra 224×224 Piksel . . . . . 65
Tabel 4.11 Perbandingan Hasil *Baseline* dan Model Sendiri . . . . . 69

# DAFTAR GAMBAR

Gambar 2.1 Sampel Kelas *Actinic Keratosis and Intraepithelial Carcinoma* . . . . . 12
Gambar 2.2 Sampel Kelas *Basal Cell Carcinoma* . . . . . 13
Gambar 2.3 Sampel Kelas *Benign Keratosis-Like Lesions* . . . . . 14
Gambar 2.4 Sampel Kelas *Dermatofibroma* . . . . . 15
Gambar 2.5 Sampel Kelas *Melanoma* . . . . . 15
Gambar 2.6 Sampel Kelas *Melanocytic Nevi* . . . . . 16
Gambar 2.7 Sampel Kelas *Vascular Lesions* . . . . . 17
Gambar 2.8 Illustrasi Convolutional Neural Network [31] . . . . . 20
Gambar 2.9 ResNet-34 dan CNN 34 *layer* tanpa residual learning [32] 22
Gambar 2.10 Ilustrasi Confusion Matrix Multi-Kelas . . . . . 26
Gambar 3.1 Diagram Alur Penelitian . . . . . 29
Gambar 3.2 Visualisasi Arsitektur *ResNet-18* Dengan *Dropout* . . . . . 34
Gambar 3.3 Visualisasi Arsitektur *ResNet-50* Dengan *Dropout* . . . . . 35
Gambar 3.4 Matriks Input Gambar 7x7 . . . . . 37
Gambar 3.5 Matriks Kernel 7x7 . . . . . 38
Gambar 3.6 Contoh Hasil Konvolusi . . . . . 38
Gambar 3.7 Contoh Hasil Konvolusi . . . . . 39
Gambar 3.8 Hasil Akhir Proses Konvolusi . . . . . 39
Gambar 3.9 Visualisasi Fungsi Aktivasi ReLU . . . . . 40
Gambar 3.10 Visualisasi Perhitungan Max Pooling . . . . . 41
Gambar 3.11 Visualisasi Perhitungan Average Pooling . . . . . 41
Gambar 4.1 Hasil Augmentasi Flip . . . . . 53
Gambar 4.2 Hasil Augmentasi Rotasi . . . . . 53
Gambar 4.3 Hasil Augmentasi Color Jitter . . . . . 54
Gambar 4.4 Hasil Augmentasi Random Erasing . . . . . 54

Gambar 4.5 Hasil Augmentasi Random Augment . . . . . 55
Gambar 4.6 Grafik Loss Resnet-18 224x224 Augmentasi Minoritas . . 70
Gambar 4.7 Grafik Loss Resnet-18 224x224 Tanpa Augmentasi Minoritas . . . . . 70
Gambar 4.8 Grafik Loss Resnet-18 28x28 Augmentasi Minoritas . . . . 71
Gambar 4.9 Grafik Loss Resnet-18 28x28 Tanpa Augmentasi Minoritas 72
Gambar 4.10 Grafik Loss Resnet-50 28x28 Augmentasi Minoritas . . . . 73
Gambar 4.11 Grafik Loss Resnet-50 28x28 Tanpa Augmentasi Minoritas 73
Gambar 4.12 Grafik Loss Resnet-50 224x224 Augmentasi Minoritas . . 74
Gambar 4.13 Grafik Loss Resnet-50 224x224 Tanpa Augmentasi Minoritas . . . . . 74

# DAFTAR RUMUS

Rumus 2.1 Accuracy . . . . . 27
Rumus 2.2 Precision . . . . . 27
Rumus 2.3 Recall . . . . . 27
Rumus 2.4 F1-Score . . . . . 27
Rumus 2.5 MCC . . . . . 28

# DAFTAR KODE

Kode 4.1 Kode Normalisasi dan Resize . . . . . 52
Kode 4.2 Kode Augmentasi Data . . . . . 52
Kode 4.3 Kode ResNet-18 28x28 . . . . . 56
Kode 4.4 Kode ResNet-50 28x28 . . . . . 57
Kode 4.5 Kode ResNet-18 224x224 . . . . . 58
Kode 4.6 Kode ResNet-50 224x224 . . . . . 59
Kode 4.7 Perbedaan Model *Scratch* . . . . . 66
Kode 4.8 Perbedaan Model *Pretrained* . . . . . 67
Kode 4.9 Penggunaan *Class Weight* . . . . . 68

# BAB I
# PENDAHULUAN

## 1.1 Latar Belakang

Bidang kesehatan kini sudah memperlihatkan penggunaan tren teknologi seperti *artificial intelligence* (AI) dalam kegiatan medis. Pemanfaatan AI dalam bidang kesehatan banyak digunakan untuk meningkatkan akurasi diagnosis, personalisasi pengobatan, serta membuat prosesadministrasi di rumah sakit menjadi efisien [1]. Kemajuan teknologi kesehatan digital telah mendorong transformasi sistem pelayanan medis menuju pendekatan yang lebih terintegrasi dan berbasis informasi. Meski demikian, aspek keselamatan data pribadi tetap menjadi fokus utamanya [2]. Melalui transformasi tersebut, diharapkan terjadi perluasan akses masyarakat terhadap pelayanan kesehatan yang berkualitas dan terjangkau.

Salah satu implementasi AI yang menonjol dalam bidang kesehatan adalah pada pengolahan citra medis. Kontribusi AI dalam sektor kesehatan mengalami perkembangan signifikan, khususnya pada citra medis dan klasifikasi penyakit. Dengan menggunakan *deep learning* seperti *Convolutional Neural Network* (CNN) menunjukkan performa yang sangat baik dalam mengidentifikasi dan mengelompokkan berbagai penyakit dari citra medis seperti fundus mata, radiologi, dan hasil pemindaian lainnya. Pendekatan ini memungkinkan ekstraksi fitur penting secara otomatis, sehingga mempercepat proses diagnosis dan memperkecil risiko kesalahan manusia dalam interpretasi gambar medis [3]. Hasil penelitian dari berbagai studi literatur mengindikasikan bahwa AI berkontribusi dalam meningkatkan akurasi deteksi penyakit serta menyediakan alternatif otomatisasi untuk analisis citra medis yang sebelumnya sangat bergantung pada keahlian manual [4]. Selain itu, pengembangan framework inovatif berbasis *deep learning* berperan besar dalam mengintegrasikan patologi

dan radiologi, sehingga menghasilkan klasifikasi penyakit yang lebih presisi dan transparan [5]. AI dengan tingkat presisi yang menyamai atau bahkan mengungguli kemampuan praktisi medis, berkontribusi dalam mengoptimalkan manajemen perawatan pasien melalui pendekatan yang lebih fokus.

Dalam penerapannya pada klasifikasi penyakit spesifik seperti penyakit kulit, muncul tantangan terkait ketidakseimbangan data. Klasifikasi penyakit kulit menggunakan citra medis memiliki salah satu tantangan yaitu data yang tidak seimbang antar kelas penyakit. Masalah ini menyebabkan model menghasilkan prediksi yang lebih akurat pada kelas mayoritas dibandingkan dengan kelas minoritas yang performanya lebih rendah [6]. Ketidakseimbangan data dapat memicu bias prediksi dan sensitivitas model akan berkurang terhadap penyakit minoritas, yang akhirnya menyebabkan risiko misdiagnosis pada kasus penting meningkat. Pada penelitian klasifikasi penyakit kulit wajah menggunakan ResNet-50, ditemukan bahwa data yang tidak terdistribusi dengan seimbang menyebabkan presisi dan recall menjadi rendah. [7]. Salah satu dataset yang banyak digunakan dalam klasifikasi penyakit kulit adalah DermaMNIST, yang juga memiliki distribusi data yang tidak merata antar kelas. Dalam mengatasi masalah tersebut, teknik augmentasi data dapat dimanfaatkan pada kelas minoritas supaya performa model meningkat [8].

Augmentasi pada kelas minoritas telah terbukti dalam meningkatkan performa model, yang merupakan salah satu solusi untuk mengatasi data yang tidak seimbang pada klasifikasi penyakit kulit berbasis citra medis, terutama dalam mendeteksi penyakit yang spesifik atau langka [9]. Melalui teknik augmentasi, jumlah dan keberagaman data pada kelas minoritas dapat ditingkatkan sehingga model memiliki peluang lebih besar untuk mempelajari karakteristik kelas tersebut secara lebih representatif. Pemilihan arsitektur deep learning yang tepat merupakan langkah penting. Berbagai arsitektur deep learning seperti VGG, DenseNet, EfficientNet, dan ResNet telah banyak diterapkan dalam klasifikasi citra medis dengan masing-masing karakteristik dan

keunggulan yang berbeda [10] [11] [12]. Di antara arsitektur tersebut, ResNet dikenal memiliki kemampuan yang baik dalam menangani jaringan yang lebih dalam melalui mekanisme residual learning, sehingga mampu menjaga stabilitas proses pelatihan dan mempertahankan performa model. Maka dari itu, untuk penelitian yang dilakukan menggunakan arsitektur ResNet.

Jenis arsitektur ResNet yang digunakan adalah ResNet-18 dan ResNet-50. Kedua jenis arsitektur menerapkan konsep *residual learning* melalui *skip connections* untuk mengatasi masalah vanishing dan *exploding gradient*, di mana ResNet-50 memfasilitasi aliran informasi pada jaringan dalam, sedangkan ResNet-18 dibangun dengan struktur spesifik yang terdiri dari 17 lapisan konvolusi, max pooling $3 \times 3$, serta lapisan fully connected dengan fungsi aktivasi ReLU [13] [14]. Performa model dievaluasi menggunakan Matthews Correlation Coefficient (MCC) untuk memastikan penilaian yang adil, terutama pada kasus dengan ukuran kelas data yang tidak seimbang [15]. Selain itu, evaluasi performa juga dilengkapi dengan penggunaan *confusion matrix* yang meliputi akurasi, *precision*, *recall*, dan *f1-score*. Hasil evaluasi dari masing-masing arsitektur yaitu ResNet-18 dan ResNet-50 akan dibandingkan untuk menentukan arsitektur yang memberikan performa terbaik dalam klasifikasi citra medis sesudah melakukan augmentasi data.

## 1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana menerapkan teknik augmentasi data yang ditujukan hanya pada kelas minoritas untuk meningkatkan hasil model klasifikasi citra penyakit kulit berbasis dataset DermaMNIST yang tidak seimbang ?
2. Bagaimana hasil arsitektur ResNet-18 dan ResNet-50 dalam mengklasifikasikan citra penyakit kulit setelah diterapkan augmentasi khusus pada kelas minoritas dibandingkan tanpa augmentasi ?

## 1.3 Tujuan Penelitian

Penelitian ini bertujuan untuk mengatasi permasalahan ketidakseimbangan data pada klasifikasi citra penyakit kulit dengan menerapkan pendekatan augmentasi pada kelas minoritas. Secara khusus, tujuan dari penelitian ini adalah sebagai berikut:

1. Menerapkan teknik augmentasi data yang ditujukan khusus pada kelas minoritas dalam dataset DermaMNIST untuk mengatasi ketidakseimbangan data dan meningkatkan keberagaman citra penyakit kulit.
2. Mengukur hasil arsitektur ResNet-18 dan ResNet-50 dalam klasifikasi citra penyakit kulit sebelum dan sesudah penerapan augmentasi pada kelas minoritas, untuk mengetahui efektivitas strategi augmentasi terhadap akurasi dan keadilan prediksi antar kelas.

## 1.4 Batasan Masalah

Supaya ruang lingkup penelitian ini lebih terarah dan realistis untuk diselesaikan dalam waktu yang telah ditentukan, maka penelitian ini dibatasi pada hal-hal berikut:

1. Penelitian hanya menggunakan dataset DermaMNIST, yang terdiri dari citra medis penyakit kulit dalam tujuh kelas dengan distribusi data yang tidak seimbang.
2. Teknik augmentasi citra hanya diterapkan pada kelas minoritas, tanpa melakukan augmentasi pada kelas mayoritas.
3. Arsitektur yang digunakan hanya ResNet-18 dan Resnet-50 untuk perbandingan performa.

## 1.5 Manfaat Penelitian

Penelitian diharapkan dapat memberikan manfaat baik bagi penulis sendiri maupun dunia akademik. Adapun manfaat dari penelitian sebagai berikut:

1. Memberikan solusi praktis dalam menangani ketidakseimbangan data pada klasifikasi citra penyakit kulit melalui teknik augmentasi khusus pada kelas minoritas.
2. Menyediakan perbandingan empiris performa arsitektur ResNet-18 dan ResNet-50 dalam klasifikasi citra medis dengan data tidak seimbang.
3. Berkontribusi pada pengembangan metode evaluasi model menggunakan metrik yang tepat untuk data tidak seimbang dalam konteks klasifikasi citra medis.

## 1.6 Sistematika Penulisan

Sistematika penulisan ini bertujuan untuk memberikan gambaran umum mengenai struktur dan isi dari laporan tugas akhir yang disusun. Penulisan dibagi ke dalam lima bab utama yang saling berkaitan dan disusun secara sistematis untuk memudahkan pembaca memahami alur penelitian dari awal hingga akhir.

**Bab I**

Pada Bab ini, berisi penjabaran mengenai latar belakang permasalahan yang menjadi dasar dilakukannya penelitian ini. Selain itu, bab ini juga memuat rumusan masalah, tujuan penelitian, manfaat penelitian, batasan masalah, serta sistematika penulisan.

**Bab II**

Bab ini memuat teori-teori dan konsep yang relevan dengan penelitian, seperti teori tentang klasifikasi citra, augmentasi data, ketidakseimbangan kelas, arsitektur *Convolutional Neural Network* (CNN), serta penjelasan mengenai dataset DermaMNIST dan penelitian terdahulu yang mendukung.

**Bab III**

Bab ini menjelaskan metode yang digunakan dalam penelitian, mulai dari tahapan pengolahan data, penerapan teknik augmentasi pada kelas minoritas,

perancangan model ResNet-18, hingga proses pelatihan dan evaluasi model.

**Bab IV**

Bab ini menyajikan hasil eksperimen yang diperoleh, termasuk analisis performa model berdasarkan metrik evaluasi yang digunakan serta pembahasan terhadap pengaruh augmentasi kelas minoritas terhadap hasil klasifikasi.

**Bab V**

Bab ini berisi kesimpulan dari penelitian yang dilakukan berdasarkan hasil yang diperoleh serta memberikan saran untuk pengembangan atau penelitian selanjutnya.

# BAB II
# TINJAUAN PUSTAKA

## 2.1 Tinjauan Pustaka

Dalam penelitian ini, studi literatur dilakukan untuk meninjau riset terdahulu. Peninjauan ini berfungsi sebagai panduan utama bagi peneliti untuk mengantisipasi dan merumuskan pendekatan yang berbasis bukti dalam menghadapi permasalahan yang mungkin timbul. Berikut adalah beberapa penelitian terdahulu yang berkaitan dengan penelitian ini:

1. Penelitian sebelumnya oleh Nermi Kadric, Amila Akagic, dan Medina Kapo pada tahun 2025 dengan judul penelitian "*Improving Dianostic Accuracy of Pigmented Skin Lesions With CNNs: A Case Study with DermaMNIST Dataset*" membahas terkait upaya untuk meningkatkan akurasi diagnostik lesi kulit berpigmen, yang merupakan indikator kondisi serius seperti melanoma. Penelitian ini juga menyoroti berbagai kelemahan pada dataset DermaMNIST orisinal, termasuk resolusi gambar yang rendah (28x28), ketidakseimbangan data, dan organisasi data yang buruk yang terbukti tidak memadai untuk klasifikasi yang andal. Terdapat perbandingan metode yang digunakan sebelumnya. Penelitian sebelumnya membandingkan model ResNet-50 dan EfficientNetV2L, serta menerapkan *transfer learning* pada dua versi dataset yaitu DermaMNIST orisinal dan DermaMNIST-C (versi perbaikan resolusi 224x224). Sedangkan penelitian yang akan dilakukan membandingkan model ResNet-18 dan ResNet-50 [12].
2. Penelitian sebelumnya oleh Ian Mateos Gonzales, Estefani Jaramilla Nava, Abraham Sánchez Morales, Jesús García Ramírez, dan Ricardo Ramos Aguilar pada tahun 2025 dengan judul penelitian "*Lighweight Deep Models for Dermatological Disease Detection: A Study on Instance*

*Selection and Channel Optimization*" membahas tentang pengembangan model deep learning yang ringan untuk deteksi penyakit dermatologis. Penelitian ini menggunakan dataset DermaMNIST yang terdiri dari 7 kelas yang berbeda. Penelitian ini meneliti dengan menggunakan data yang sedikit dengan cara seleksi instance menggunakan K-Means Clustering. Namun, penelitian yang akan dilakukan tidak mengurangi data melainkan menambahkan data pada kelas minoritas. Selain itu, penelitian akan dilakukan menggunakan arsitektur ResNet-18 dan ResNet-50 sedangkan penelitian sebelumnya menggunakan Lighweight Deep Models [16].

3. Penelitian sebelumnya oleh Arindam Halder, Anogh Dalal, Sanghita Gharami, Marcin Wozniak, Muhammad Fajal Ijaz, dan Pawan Kumar Singh pada tahun 2025 dengan judul penelitian "*A fuzzy rank-based deep ensemble methodology for multi-class skin cancer classification*" membahas masalah klasifikasi kanker kulit multi-kelas dan tantangan *imbalanced dataset*. Penelitian ini menggunakan *deep ensemble* yang menggabungkan beberapa arsitektur, yaitu Xception, InceptionResNetV2, dan MobileNetV2. Dalam mengatasi data yang tidak seimbang, penelitian sebelumnya menerapkan augmentasi data untuk menyeimbangkan dataset sebelum proses pelatihan. Dengan menerapkan augmentasi data membuktikan bahwa dapat berhasil meningkatkan performa. Penelitian sebelumnya relevan dengan penelitian yang akan dilakukan dengan adanya beberapa perbedaan. Penelitian yang akan dilakukan menerapkan augmentasi data pada kelas minoritas serta menggunakan ResNet-18 dan ResNet-50 untuk mengukur pengaruh augmentasi terhadap performa kedua model [17].
4. Penelitian yang dilakukan pada tahun 2024 oleh Gogor Putra, Elin Haerani, Fadhillah Syafria, Febi Yanto, dan Siska Kurnia Gusti dengan judul "Implementasi Algoritma *Convolutional Neural Network* (Resnet-50) untuk Klasifikasi Kanker Kulit Benign dan Malignant". Penelitian

ini membahas tentang klasifikasi kanker kulit untuk membedakan antara lesi *Benign* dan *Malignant*, yang merupakan masalah klasifikasi biner. Penelitian ini melakukan implmentasi *transfer learning* menggunakan arsitektur ResNet-50 yang telah dilatih. Penelitian sebelumnya relevan karena menggunakan arsitektur yang sama yaitu ResNet-50. Terdapat perbedaan dengan penelitian yang akan dilakukan, yaitu menangani klasifikasi multi-kelas dengan masalah *imbalanced data*. Serta melakukan augmentasi data pada kelas minoritas [18]. Dengan demikian, penelitian ini dapat dijadikan sebagai referensi awal dalam memahami penerapan arsitektur ResNet pada citra medis. Selain itu, hasil penelitian tersebut memberikan gambaran umum mengenai performa model deep learning dalam konteks klasifikasi penyakit kulit.

5. Penelitian yang dilakukan pada tahun 2022 oleh Shuwei Shen, Mengjuan Xu, Fan Zhang, Pengfei Shao, Honghong Liu, Liang Xu, dan Ronald X. Xu dengan judul "*A Low-Cost and High-Performance Data Augmentation for Deep-Learning-Based Skin Lesion Classification*" membahas tantangan dataset yang tidak seimbang dalam klasifikasi lesi kulit menggunakan arsitektur EfficientNet. Penelitian ini menerapkan strategi augmentasi otomatis (*Low-Cost-Augment*) yang teroptimasi untuk meningkatkan keseimbangan data dan performa klasifikasi pada dataset HAM10000. Meskipun arsitektur utama yang diuji berupa EfficientNet, hasil eksperimen menunjukkan bahwa augmentasi otomatis dapat meningkatkan *accuracy* tanpa memerlukan data eksternal. Namun, keterbatasannya adalah belum diuji pada arsitektur ResNet-18 dan ResNet-50 serta belum diaplikasikan pada dataset DermaMNIST [19]. Oleh karena itu, penelitian ini tetap memiliki kontribusi penting dalam pengembangan strategi augmentasi data pada bidang klasifikasi citra medis. Selain itu, pendekatan yang diusulkan dapat menjadi acuan awal bagi penelitian lanjutan dengan arsitektur dan dataset yang berbeda.

Tabel 2.1 Tabel Studi Literatur

| No. | Judul | Masalah | Metode | Hasil |
|---|---|---|---|---|
| 1. | Nerma Kadric, dkk [2025] [*Improving Diagnostic Accuracy of Pigmented Skin Lesions With CNNs: A Case Study with DermaMNIST Dataset*] | Kelemahan dataset DermaMNIST yang memiliki resolusi gambar yang rendah (28 x 28), *imbalanced data*. | *Trasnfer learning* arsitektur ResNet-50 dan EfficientNetV2L dengan menggunakan dataset DermaMNIST orisinal dan DermaMNIST-C (224 x 224). | Arsitektur EfficientNetV2L mencapai akurasi 84.90% pada dataset DermaMNIST-C. |
| 2. | Ian Mateos Gonzales, dkk [2025] [*Lightweight Deep Models for Dermatological Disease Detection: A Study on Instance Selection and Channel Optimization*] | Model *deep learning* yang ringan untuk deteksi penyakit dermatologis. | Menggunakan *Lightweight Deep Models*, melakukan *instance selection* menggunakan K-Means Clustering. | Model dengan 472K parameter mencapai akurasi 71.57%, dengan komputasi yang lebih efisien yang sebanding dengan model ResNet. |

| No. | Judul | Masalah | Metode | Hasil |
|---|---|---|---|---|
| 3. | Arindam Halder, dkk [2025] [*A fuzzy rank-based deep ensemble methodology for multi-class skin cancer classification*] | *Imbalanced data* pada klasifikasi kanker kulit multi-class. | *Fuzzy ensemble* (Xception, InceptionResNet V2, dan MobileNetV2). Menerapkan augmentasi data. | Model ensemble mencapai akurasi 95% pada HAM10000 dan 73% pada dataset DermaMNIST. |
| 4. | Gogor Putra Hafi P. G., dkk [2024] [Implementasi Algoritma CNN (ResNet-50) untuk Klasifikasi Kanker Kulit Benign dan Malignant] | Klasifikasi kanker kulit untuk membedakan antara Benign (jinak) dan Malignant (ganas). | Implementasi *transfer learning* menggunakan ResNet-50 yang *pre-trained*. | Dengan menggunakan ResNet-50 mencapai akurasi 90% dengan *loss* 13%. |
| 5. | Shuwei Shen, dkk [2022] [*A Low-Cost High-Performance Data Augmentation for Deep Learning-Based Skin Lesion Classification*] | Data klasifikasi lesi kulit yang tidak seimbang. | Menggunakan arsitektur EfficientNet b2 serta menerapkan *Low Cost Augment* untuk augmentasi data. | Dengan menerapkan *Low Cost Augment* dan EfficientNet b2, hasil evaluasi BACC mencapai 0.853. |

## 2.2 Dasar Teori

Berikut ini adalah dasar teori atau penjelasan teori terkait yang akan digunakan dalam penelitian ini.

### 2.2.1 DermaMNIST

DermaMNIST adalah salah satu dari dataset yang ada di dalam koleksi MedMNIST. DermaMNIST berdasar pada HAM10000 yang merupakan kumpulan gambar dermatoskopik dari lesi kulit berpigmen yang memiliki *multi-class*. DermaMNIST memiliki 10.015 gambar yang diklasifikasikan ke dalam 7 kelas, yaitu *actinic keratosis and intraepithelial carcinoma*, *basal cell carcinoma*, *benign keratosis-like lesions*, *dermatofibroma*, *melanoma*, *melanocytic nevi*, *vascular lesions* [20]. Dataset ini digunakan dalam penelitian klasifikasi citra medis karena memiliki standar anotasi yang jelas. Selain itu, ketersediaannya secara publik memudahkan proses replikasi dan perbandingan hasil penelitian.

#### 2.2.1.1 Actinic Keratosis and Intraepithelial Carcinoma

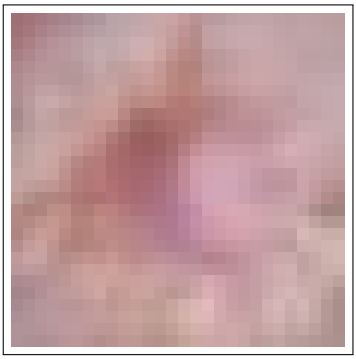

Gambar 2.1 Sampel Kelas *Actinic Keratosis and Intraepithelial Carcinoma*

*Actinic Keratosis* adalah sel kulit yang mengalami transformasi neoplastik diakibatkan paparan sinar UV. Pertumbuhan *Actinic Keratosis* masih berada di

lapisan kulit luar. *Actinic Keratosis* atau disingkat ”AK”, memiliki hubungan dengan *Carcinoma*. AK adalah bentuk awal dari *Carcinoma*, ketika lesi ini menembus lapisan di bawah epidermis, maka AK berubah nama menjadi *Squamous Cell Carcinoma* (SCC). Penyakit ini jika tidak diobati, akan berpotensi untuk berkembang kemudian berkembang menyerang jaringan yang lebih dalam [21].

#### 2.2.1.2 Basal Cell Carcinoma

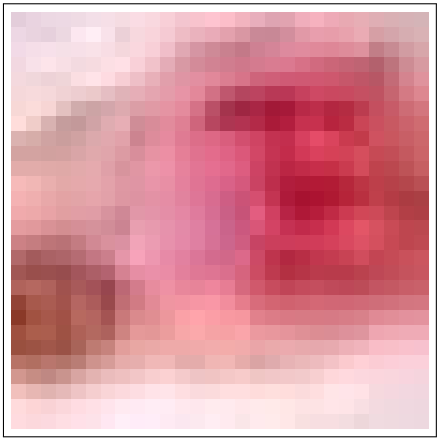

Gambar 2.2 Sampel Kelas *Basal Cell Carcinoma*

*Basal Cell Carcinoma* atau ”BCC” merupakan jenis kanker kulit yang umum terjadi, terutama pada orang dewasa berkulit cerah dan biasanya diawali pertumbuhan yang lambat dan risiko metastasis yang rendah. Faktor utama dari BCC adalah paparan sinar ultraviolet yang membuat lesi ini muncul paling sering di kulit yang terpapar sinar matahari. Adapun faktor lain penyebab BCC ini muncul, seperti kondisi imunosupresi (penurunan sistem imun) dan sindrom genetik tertentu seperti *Basal Cel Naevus Syndroeme* yang menyebabkan BCC muncul pada usia muda [22].

#### 2.2.1.3 Benign Keratosis-Like Lesions

Gambar 2.3 Sampel Kelas *Benign Keratosis-Like Lesions*

*Benign Keratosis* atau disingkat ”BKL” bukan merupakan diagnosis penyakit kulit tunggal, melainkan kategori umum yang digunakan untuk mengklasifikasikan tiga jenis *benign lesions* yang berbeda. Tiga jenis adalah *seborheicc keratoses*, *solar lentigo*, dan *lichen planus-like keratoses*. Ketiga jenis tersebut digabungkan karena memiliki kemiripan secara biologis, meskipun secara dermatologis ketiga jenis tersebut dapat terlihat berbeda [23]. Secara klinis, ketiga lesi tersebut sama-sama bersifat jinak dan tidak menunjukkan karakteristik keganasan. Oleh karena itu, pengelompokan BKL sering digunakan dalam studi dermatologi dan dataset citra medis. Selain itu, kesamaan pola visual pada ketiga lesi tersebut menjadikan BKL relevan untuk dikaji dalam penelitian.

#### 2.2.1.4 Dermatofibroma

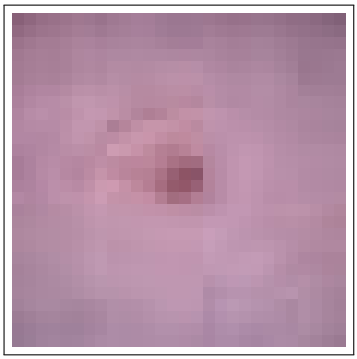

Gambar 2.4 Sampel Kelas *Dermatofibroma*

*Dermatofibroma* atau disingkat ”df” merupakan lesi kulit jinak yang dianggap sebagai proliferasi jinak atau reaksi peradangan akibat trauma ringan. Gambaran dermatoskopik paling umum dari lesi kulit ini adalah adanya garis-garis retikular di bagian tepi dengan disertai bercak putih di bagian tengah [23].

#### 2.2.1.5 Melanoma

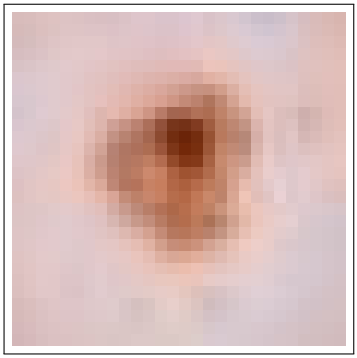

Gambar 2.5 Sampel Kelas *Melanoma*

*Melanoma* atau disingkat ”mel” merupakan kanker yang berasal dari sel melanosit dan dapat muncul dalam berbagai varian. Jika kanker ini diangkat

pada stadium awal dengan operasi pengangkatan sederhana, maka kanker dapat disembuhkan [23]. Pada stadium lanjut melanoma memiliki tingkat agresivitas yang tinggi dan berpotensi menyebar ke organ lain. Secara dermatoskopik, melanoma sering menunjukkan pola yang tidak teratur, variasi warna, serta batas lesi yang tidak jelas. Oleh karena itu, deteksi dini melanoma menjadi aspek yang sangat penting dalam upaya menurunkan angka mortalitas akibat kanker kulit.

#### 2.2.1.6 Melanocytic Nevi

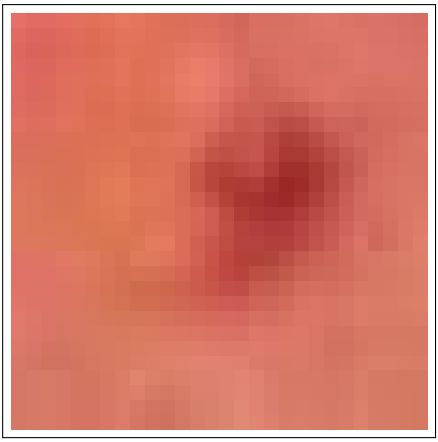

Gambar 2.6 Sampel Kelas *Melanocytic Nevi*

*Melanocytic Nevi* atau disingkat ”nv” merupakan tumor jinak yang berasal dari sel melanosit, yang dapat muncul dalam berbagai varian. Dari *point of view* dermatoskopik, varian-varian tersebut bisa sangat berbeda satu sama lain [23]. Perbedaan ini mencakup variasi warna, struktur, dan pola distribusi pigmen pada permukaan kulit. Secara klinis, melanocytic nevi umumnya bersifat non-malignan dan memiliki risiko rendah untuk berkembang menjadi melanoma.

#### 2.2.1.7 Vascular Lesions

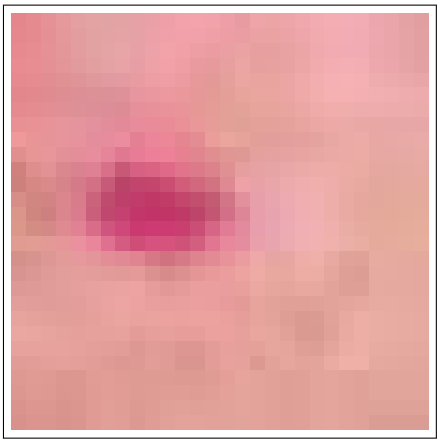

Gambar 2.7 Sampel Kelas *Vascular Lesions*

*Vascular Lesions* atau disingkat ”vasc” meliputi berbagai jenis, mulai dari *cherry angiomas*, *angiokeratomas*, dan *pyogenic granulomas*. *Hemorrhage* juga termasuk dalam kategori ini. Secara gambaran dermatoskopik, *angioma* mempunyai ciri khas yaitu warna merah atau ungu dengan adanya struktur padat yang jelas, yang disebut dengan istilah ”red clods” (gumpalan merah) atau lacunes (rongga kecil) [23].

### 2.2.2 Imbalanced Data

Data tidak seimbang (*imbalanced data*) secara teknis merujuka pada kumpulan data yang memperlihatkan distribusi data yang tidak merata antar kelas. Dalam pemahaman umum, istilah ini merujuk pada kumpulan data yang menunjukkan ketidakseimbangan yang signifikan atau bahkan ekstrem. Ketidakseimbangan ini secara khusus dikenal sebagai ketidakseimbangan antarkelas, di mana kelas mayoritas jauh lebih mendominasi kelas minoritas. Ketimpangan rasio dalam skala 100:1 hingga 10000:1 merupakan fenomena yang lumrah terjadi. Meskipun ketidakseimbangan data ini sering merujuk pada

masalah biner, ketidakseimbangan juga dapat terjadi pada data *multi-class* [24].

### 2.2.3 Data Augmentasi

Kebutuhan data latih untuk melatih model *deep learning* seperti *Convolutional Neural Network* membutuhkan jumlah data yang besar. Jumlah data latih yang terbatas akan membuat model rentan terhadap *overfitting*. Kondisi di mana model memiliki performa yang baik terhadap data latih tetapi gagal menggeneralisasi dengan baik pada data uji. Terdapat salah satu teknik untuk mengatasi masalah ini yaitu data augmentasi. Data augmentasi adalah teknik untuk memperbanyak jumlah data latih secara buatan dengan cara membuat versi data yang telah dimodifikasi dari data yang sudah ada. Augmentasi yang diterapkan seperti rotasi, *flipping*, atau pergeseran warna, dengan mengasumsikan tidak mengubah makna atau label dari data aslinya [25]. Penggunaan teknik augmentasi data sebagai metode yang umum dan mudah untuk mengurangi *overfitting* [26].

#### 2.2.3.1 *Flip*

Augmentasi data menggunakan metode flip dikategorikan sebagai pendekatan manipulasi geometris dasar yang berfungsi meningkatkan dataset pelatihan secara signifikan tanpa mengubah label kelas data yang sebenarnya. Teknik ini bekerja dengan membalikkan orientasi citra, baik secara vertikal maupun horizontal, yang bertujuan agar model dapat mengenali fitur objek dari berbagai sudut pandang [25].

#### 2.2.3.2 Rotasi

Rotasi merupakan teknik augmentasi data dengan cara memutar gambar pada sudut tertentu. Rotasi dapat dilakukan dengan sudut tetap, seperti 15°, 45°, atau sudut acak. Rotasi pada gambar dapat membantu model untuk mengenali objek dari berbagai sudut pandang. Tujuannya adalah agar sistem tidak bingung ketika menemui gambar yang posisinya miring di dunia nyata. Jadi, meskipun

pengambilan fotonya tidak tegak lurus, objek di dalamnya tetap bisa dikenali dengan baik [27].

#### 2.2.3.3 *Random Erasing*

*Random erasing* merupakan teknik baru untuk augmentasi data. *Random erasing* dapat mengatasi masalah oklusi. Beberapa objek tidak selalu terlihat sepenuhnya dalam gambar, masalah ini disebut dengan oklusi. Objek tidak jarang terhalang atau tertutup oleh objek lain sehingga hanya sebagian yang terlihat. Hal ini membuat model sulit mengenali objek saat proses latih, jika beberapa bagian dari objek tidak terlihat atau tertutup. Dengan *random erasing*, objek akan sengaja dihapus atau ditutup secara acak dibeberapa bagian oleh sebuah area berbentuk persegi panjang yang diisi dengan nilai acak pada gambar. Teknik ini membuat model tidak belajar hanya dari fitur tertentu pada objek. Dengan demikian, model menjadi tidak tidak terlalu kompleks dan tidak menghafal pola tertentu pada gambar yang membuat model menjadi lebih *robust.* [28].

#### 2.2.3.4 *Random Augmentation*

*Random augmentation* merupakan teknik augmentasi yang dilakukan secara otomatis dengan tujuan untuk mengatasi kelemahan pada teknik sebelumnya seperti *AutoAugment*. Masalah pada teknik sebelumnya dikarenakan membutuhkan komputasi yang tinggi untuk mencari augmentasi yang optimal dan membutuhkan *search phase* yang rumit. Dengan *random augmentation*, meringankan proses dengan cara menghapus *search phase* [29].

#### 2.2.3.5 *Color Jitter*

*Color jitter* merupakan teknik augmentasi dengan cara mengubah warna pada gambar secara acak dengan tujuan membuat model tidak terlalu sensitif terhadap perubahan warna pada gambar. Teknik ini membuat model untuk menggeneralisasi menjadi lebih baik. Teknik ini membutuhkan empat komponen utama yaitu kecerahan, kontras, saturasi, dan *Hue* [30].

### 2.2.4 Convolutional Neural Network

*Convolutional Neural Network* (CNN) adalah salah satu model *deep learning* yang digunakan untuk memproses data citra. CNN terdiri dari lapisan konvolusi dan *pooling*, satu atau lebih lapisan *fully connected*, dan lapisan *output* di akhir. Lapisan konvolusi dan *pooling* berfungsi untuk ekstraksi fitur. Hasil dari ekstraksi fitur akan dikirim ke lapisan *fully connected* untuk dilakukannya klasifikasi. Istilah lain untuk lapisan *fully connected* adalah lapisan *dense* atau *Multi- Layer Perceptron* (MLP) [31].

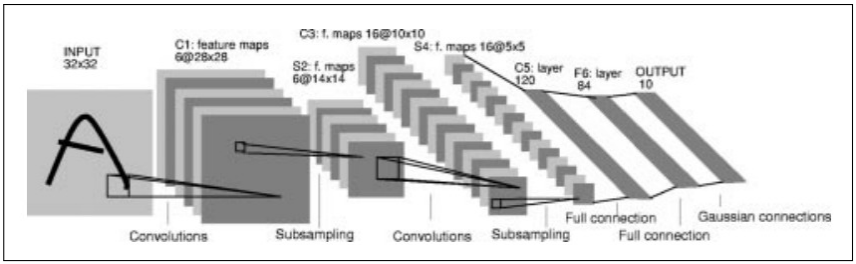


Gambar 2.8 Illustrasi Convolutional Neural Network [31]

Merujuk pada gambar 2.8 proses CNN dimulai dengan penerimaan data citra sebagai masukan. Data ini selanjutnya diolah secara bertahap melalui serangkaian lapisan jaringan. Tujuan dari lapisan-lapisan tersebut adalah untuk mengekstraksi fitur-fitur penting dari citra, yang pada akhirnya digunakan untuk mengklasifikasikan citra itu ke dalam kelas-kelas yang relevan. Berikut ini adalah penjelasan mengenai lapisan-lapisan yang menyusun CNN:

1. Lapisan konvolusi

   Lapisan konvolusi yang terdiri dari sejumlah kernel (filter) konvolusi yang berperan untuk mengekstrak fitur pada data input. Proses konvolusi yaitu melakukan pergeseran kernel di atas gambar input, kemudian nilai pada kernel dengan nilai piksel pada posisi yang bersesuaian akan dikalikan setelah itu dijumlahkan untuk menghasilkan *feature map*. *Feature map* yang dihasilkan akan digunakan sebagai satu kelas fitur gambar

yang diekstraksi. Beberapa lapisan konvolusi akan ditumpukkan untuk mengekstrak fitur yang *higher-level* dan lebih lengkap.

2. Activation Function

   *Activation Function* adalah fungsi matematis yang berperan penting dalam *neural network* dengan memperkuat representasi dan kemampuan untuk pembelajaran model. Tanpa adanya fungsi aktivasi, pemrosesan setiap lapisan hanya proses fungsi linier. Dengan adanya fungsi aktivasi, model dapat mengenal non-linieritas dalam jaringan. Fungsi aktivasi sebagai fungsi keputusan untuk membantu model mempelajari pola yang kompleks. Beberapa fungsi aktivasi yang umum digunakan seperti Sigmoid, Tanh, ReLU, dan Leaky ReLU.

3. Lapisan pooling

   Lapisan *pooling* ditambahkan setelah lapisan konvolusi menghasilkan *feature map*. Tujuan dari lapisan *pooling* adalah untuk mengurangi jumlah dimensi *feature map*, dan meminimalkan *overfitting*. Terdapat dua metode *pooling* yang umum digunakan, yaitu *max pooling* dan *average pooling*. Pada *max pooling*, nilai maksimum dari area yang oleh kernel (filter) diambil sebagai representasi area tersebut. Sedangkan pada *average pooling*, nilai rata-rata dari area yang kernel ambil sebagai representasi area tersebut.

4. Lapisan Fully Connected Lapisan *fully connected* adalah lapisan yang biasanya ditempatkan di akhir dari jaringan CNN, bertujuan untuk klasifikasi. Pada lapisan ini, setiap neuron saling terhubung satu sama lain. Secara umum, CNN akan mengambil *feature map* yang dihasilkan dari proses sebelumnya, kemudian di-*flatten* menjadi vektor satu dimensi, lalu dikirim ke lapisan *fully connected*. Lapisan ini penting untuk integrasi informasi lokal yang memiliki sifat pembeda kelas yang telah diekstraksi oleh lapisan konvolusi dan *pooling* sebelumnya.

### 2.2.5 Residual Network

Arsitektur yang sering disebut dengan ”ResNet” diperkenalkan oleh Kaiming He dkk didalam jurnal yang berjudul ”*Deep Residual Learning for Image Recognition*” pada tahun 2015 [32]. *Residual Network* (ResNet) merupakan arsitektur CNN yang dirancang untuk mengatasi masalah degradasi pada *deep neural network*. Terjadinya degradasi disebabkan kedalaman *neural network* meningkat dan membuat akurasi model menurun dengan cepat. Degradasi bukan karena *overfitting* melainkan penambahan *layer* yang dalam pada model yang cukup dalam, alhasil training error meningkat. Untuk mengatasi masalah ini, arsitektur ResNet memiliki konsep *residual learning* di mana beberapa *stacked layer* menyesuaikan *desired underlying mapping*. Konsep ini didukung dengan adanya *shortcut connections* yang melewati satu atau lebih *layer*. Terdapat perbedaan arsitektur yang dimana ResNet-34 dengan arsitektur yang mempunyai 34 *layer* tanpa *residual learning* yang dapat dilihat pada gambar 2.9.

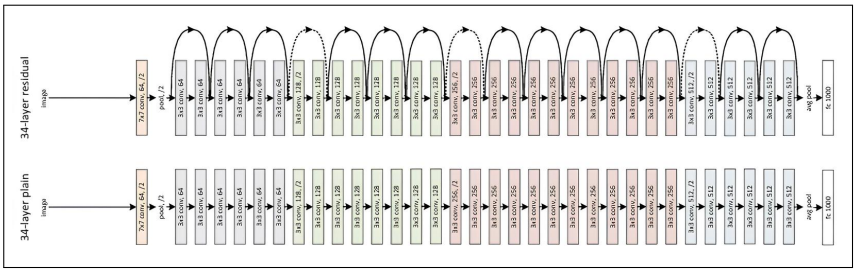


Gambar 2.9 ResNet-34 dan CNN 34 *layer* tanpa residual learning [32]

ResNet memiliki beberapa jenis berdasarkan dengan jumlah *layer*. Terdapat ResNet-18 dengan 18 *layer*, ResNet-34 dengan 34 *layer*, ResNet-50 dengan 50 *layer*, dan lain-lain. Pada penelitian ini akan menggunakan arsitektur ResNet-18 dan ResNet-50 untuk membandingkan performa keduanya. Pemilihan kedua arsitektur tersebut didasarkan pada perbedaan kompleksitas

model dan kedalaman jaringan. Dengan membandingkan dua arsitektur yang memiliki jumlah parameter berbeda, diharapkan dapat diperoleh gambaran pengaruh kedalaman jaringan terhadap hasil klasifikasi.Berikut struktur dari kedua arsitektur dapat dilihat pada tabel 2.2 dan tabel 2.3.

Tabel 2.2 Struktur ResNet-18 [32]

| **Nama Lapisan** | **Ukuran Output** | **34-Layer** |
|---|---|---|
| Conv1 | $112 \times 112$ | $7 \times 7$, 64, stride 2 |
| *Max Pooling* | $3 \times 3$ | stride 2 |
| Conv2_x | $56 \times 56$ | $\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$ |
| Conv3_x | $28 \times 28$ | $\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$ |
| Conv4_x | $14 \times 14$ | $\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$ |
| Conv5_x | $7 \times 7$ | $\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$ |
| *Average Pooling* | | |
| *Fully Connected Layer* | | |
| *Softmax* | | |

Tabel 2.3 Struktur ResNet-50 [32]

| **Nama Lapisan** | **Ukuran Output** | **34-Layer** |
|---|---|---|
| Conv1 | $112 \times 112$ | $7 \times 7$, 64, stride 2 |
| *Max Pooling* | $3 \times 3$ | stride 2 |
| Conv2_x | $56 \times 56$ | $\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$ |
| Conv3_x | $28 \times 28$ | $\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$ |
| Conv4_x | $14 \times 14$ | $\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$ |
| Conv5_x | $7 \times 7$ | $\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$ |
| *Average Pooling* | | |
| *Fully Connected Layer* | | |
| *Softmax* | | |

#### 2.2.5.1 Residual Learning

Pada tahun 2016, Kaiming He dkk memperkenalkan konsep *residual learning* pada arsitektur *deep learning*. Lapisan-lapisan dalam jaringan disusun kembali untuk mempelajari fungsi residual yang mereferensikan input asli. Konsep *residual learning* ini membuat lapisan-lapisan jaringan cukup mempelajari selisih atau residual dari input asli, yaitu $\mathcal{F}(x) := \mathcal{H}(x) - x$, dibandingkan mempelajari fungsi target langsung yaitu $\mathcal{H}(x)$. Hasil dari pembelajaran fungsi residual ini kemudian ditambahkan ke input asli ($x$) tersebut ($\mathcal{F}(x) + x$). Pengoptimalan fungsi residual lebih efisien dibandingkan pemetaan asli, karena jaringan cukup menekan nilai residual mendekati nol untuk mencapai pemetaan identitas. Hal ini diimplementasikan melalui *shortcut connections* yang menjumlahkan input identitas langsung ke output lapisan. Konsep ini juga dapat mengatasi masalah degradasi yang disebabkan karena penambahan kedalaman pada jaringan [32].

#### 2.2.5.2 Shortcut Connections

*Shortcut connections* merupakan jalur koneksi yang melompati satu atau lebih lapisan jaringan. Dalam arsitektur ResNet, jalur koneksi ini melakukan *identity mapping*, yang mana *output* dari lapisan yang berupa fungsi residual ditambahkan dengan input asli. Secara matematis direpresentasikan sebagai $y = \mathcal{F}(x, \{W_i\}) + x$, di mana $x$ adalah input dan $y$ adalah output. Penggunaan *shortcut connections* memiliki keunggulan yaitu efisien. Dengan adanya jalur ini, tidak menambahkan parameter ekstra maupun meningkatkan kompleksitas komputasi pada jaringan [32].

### 2.2.6 Confusion Matrix

*Confusion Matrix* adalah tabel yang digunakan untuk mengevaluasi kinerja model klasifikasi. *Confusion Matrix* terdapat empat komponen utama, yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN).

Matriks ini membantu menganalisis kemampuan klasifikasi model secara rinci, dengan melihat seberapa tepat hasil tebakan model jika dibandingkan dengan data yang sebenarnya [33]. *Confusion Matrix* bukan hanya digunakan untuk data yang memiliki dua kelas, tetapi matriks ini dapat digunakan untuk data multi-kelas. Ilustrasi *Confusion Matrix* multi-kelas dapat dilihat pada gambar 2.10.

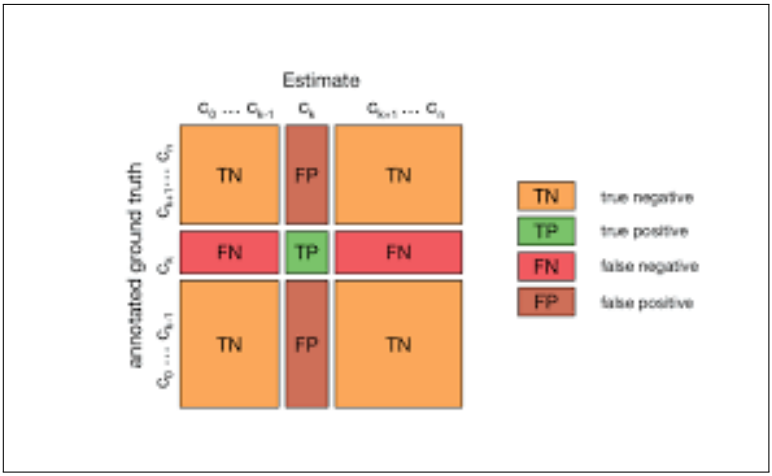


Gambar 2.10 Ilustrasi Confusion Matrix Multi-Kelas

Keterangan:

1. *True Positive* (TP): jumlah data yang nilai aktualnya positif dan nilai prediksinya positif.
2. *True Negative* (TN): jumlah data yang nilai aktualnya negatif dan nilai prediksinya negatif.
3. *False Positive* (FP): jumlah data yang nilai aktualnya negatif dan nilai prediksinya positif.
4. *False Negative* (FN): jumlah data yang nilai aktualnya positif dan nilai prediksinya negatif.

Dari nilai komponen utama pada *Confusion Matrix*, dapat dilakukan

perhitungan kinerja model menggunakan persamaan berikut.

1. *Accuracy*

   *Accuracy* mengukur seberapa akurat model dalam mengklasifikasikan data. Rumus akurasi dapat dilihat pada persamaan Rumus 2.1.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$ (Rumus 2.1 Accuracy )

2. *Precision*

   Precision mengukur seberapa akurat prediksi positif yang dibuat oleh model. Nilainya dihitung dari rasio antara prediksi positif yang benar (TP) dibagi dengan keseluruhan data yang diprediksi positif oleh model (TP + FP). Rumus *precision* dapat dilihat pada persamaan Rumus 2.2.

$$Precision = \frac{TP}{TP + FP}$$ (Rumus 2.2 Precision )

3. *Recall*

   Recall adalah metrik yang menunjukkan kemampuan sebuah model dalam menemukan kembali semua data yang sebenarnya positif. Nilainya dihitung dari rasio antara prediksi positif yang benar (TP) dibagi dengan jumlah total data yang faktanya positif (TP + FN). Rumus *recall* dapat dilihat pada persamaan Rumus 2.3.

$$Recall = \frac{TP}{TP + FN}$$ (Rumus 2.3 Recall )

4. *F1-Score*

   F1-Score adalah rata-rata harmonik (harmonic mean) dari Precision dan Recall. Metrik ini menggabungkan kedua metrik tersebut untuk memberikan satu skor tunggal, yang sangat berguna terutama jika terdapat ketidakseimbangan kelas (imbalanced classes). Rumus *F1-Score* dapat dilihat pada persamaan Rumus 2.4.

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$ (Rumus 2.4 F1-Score )

### 2.2.7 Matthews Correlation Coefficient

*Matthews Correlation Coefficient* (MCC) merupakan metrik evaluasi untuk klasifikasi biner maupun multi-kelas yang menghasilkan skor dalam interval [-1; +1], jika *classifier* memperoleh nilai tinggi untuk komponen dasar dari *confusion matrix* yaitu, akurasi, *precision*, *recall*, dan *false negative* (FN). MCC juga dapat digunakan pada klasifikasi multi-kelas. Nilai +1 menunjukkan klasifikasi sempurna, nilai mendekati 0 menunjukkan prediksi yang dibuat secara acak, dan nilai -1 menunjukkan prediksi yang berlawanan sempurna dimana semua sampel negatif diprediksi sebagai positif dan sebaliknya. Keunggulan MCC adalah mampu dalam menangani *imbalanced data* dikarenakan MCC diakui *robust* terhadap *imbalanced data* [34]. Berikut persamaan MCC untuk klasifikasi multi-kelas yang dapat dilihat pada Rumus 2.5.

$$MCC = \frac{c \times s - \sum_k^K p_k \times t_k}{\sqrt{(s^2 - \sum_k^K p_k^2) \times (s^2 - \sum_k^K t_k^2)}}$$ (Rumus 2.5 MCC )

Keterangan:

k: Jumlah total kelas

c: Jumlah total sampel yang diprediksi dengan benar (*True Positive*)

s: Jumlah total keseluruhan sampel

$p_k$: jumlah prediksi untuk kelas k (total elemen yang diprediksi sebagai kelas k)

$t_k$: jumlah sampel aktual untuk kelas k (ground truth untuk kelas k)

# BAB III
# METODE PENELITIAN

## 3.1 Alur Penelitian

Penelitian ini berfokus pada augmentasi data kelas minoritas untuk membandingkan hasil atau performa arsitektur ResNet-18 dan ResNet-50. Alur penelitian dijelaskan pada diagram yang dapat dilihat pada Gambar 3.1. Penelitian dimulai dari identifikasi masalah hingga selesai.

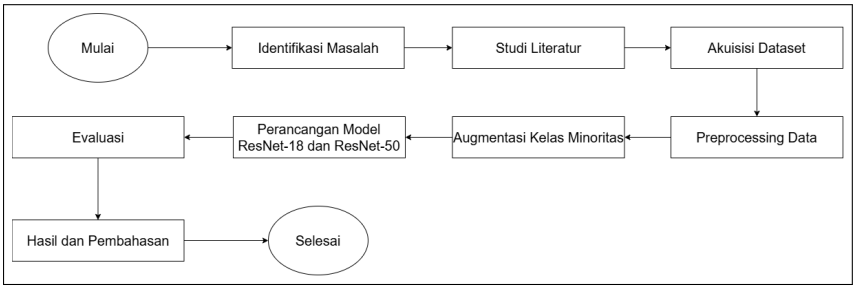


Gambar 3.1 Diagram Alur Penelitian

## 3.2 Penjabaran Langkah Penelitian

Penjelasan dari setiap langkah pada alur penelitian akan dijelaskan secara rinci untuk memberikan detail yang jelas terhadap metode yang digunakan. Berikut penjelasan dari setiap langkah penelitian tersebut.

### 3.2.1 Identifikasi Masalah

Tahap awal yang dilakukan sebelum penelitian adalah identifikasi masalah. Identifikasi dilakukan dengan cara menelaah karakteristik dataset DermaMNIST yang digunakan dalam penelitian seperti jumlah kelas, distribusi data dari masing-masing kelas, dan ukuran dari citra penyakit kulit. Pada penelitian klasifikasi citra penyakit kulit menggunakan dataset DermaMNIST yang dilakukan oleh Nerma Kadric dkk pada tahun 2025, terdapat ketidakseimbangan kelas yang

signifikan di mana berdampak terhadap performa model [12]. Berdasarkan hal tersebut, dilakukan eksplorasi terhadap dataset dan ditemukannya kelas yang jumlah data nya sedikit (kelas minoritas) dibandingkan kelas lainnya yang memiliki jumlah data yang banyak (kelas mayoritas). Kondisi ketidakseimbangan kelas ini menjadi dasar dilakukannya penelitian untuk mengevaluasi efektivitas teknik augmentasi pada kelas minoritas dalam membandingkan performa model ResNet-18 dan ResNet-50 pada klasifikasi citra penyakit kulit menggunakan dataset DermaMNIST.

### 3.2.2 Studi Literatur

Tahap studi literatur dilakukan dengan mengumpulkan dan mengkaji berbagai sumber akademis terpercaya, meliputi jurnal ilmiah dan publikasi terkini yang relevan dengan penelitian. Referensi yang dikumpulkan berdasarkan pada topik klasifikasi citra penyakit kulit menggunakan deep learning, imbalanced data pada multi-kelas, penanganan imbalanced data melalui teknik augmentasi, dan model ResNet-18 dan ResNet-50. Tahap ini bertujuan untuk membangun landasan teoritis yang kuat dan berkaitan dengan penelitian yang dilakukan.

### 3.2.3 Akuisisi Dataset

Proses pengumpulan data dalam riset ini menggunakan dataset DermaMNIST yang diambil dari platform MedMNIST, yaitu open-source yang menyediakan koleksi dataset citra medis. Dataset DermaMNIST berisi gambar-gambar penyakit kulit berwarna dengan dimensi 28x28 piksel dan 224x224 piksel, yang dikelompokkan menjadi 7 kelas berbeda sesuai jenis penyakit kulitnya. Dataset ini terdiri dari total 10.015 gambar yang terbagi menjadi data latih, data validasi, dan data uji. Ketujuh kelas penyakit kulit tersebut meliputi actinic keratosis and intraepithelial carcinoma, basal cell carcinoma, benign keratosis-like lesions, dermatofibroma, melanoma, melanocytic nevi, dan vascular lesions.

### 3.2.4 Preprocessing Data

Sebelum pelatihan model melakukan dataset yang sudah dikumpulkan, data akan diolah terlebih dahulu. Tahapan tersebut disebut dengan *Preprocessing Data*. Tahap *preprocessing data* akan melakukan *resizing* dan normalisasi data. Pada tahap *resizing*, data di-*resize* dari ukuran aslinya yaitu 28x28 menjadi 224x224 agar sesuai dengan dimensi input *default* pada arsitektur ResNet, baik ResNet-18 maupun ResNet-50. Proses normalisasi dilakukan untuk mentransformasi rentang nilai piksel dari [0, 255] menjadi [0, 1] dengan tujuan menstabilkan konvergensi selama pelatihan model dan meningkatkan efisiensi komputasi. Dataset DermaMNIST yang digunakan dalam penelitian ini terdiri dari 10.015 citra. Pembagian data mengikuti pembagian yang sudah disediakan oleh dataset, yaitu 7.007 citra untuk data *training*, 1.003 citra untuk data *validation*, dan 2.005 citra untuk data *test*.

### 3.2.5 Augmentasi Kelas Minoritas

Augmentasi data merupakan teknik untuk meningkatkan jumlah data pelatihan dengan menghasilkan variasi baru dari data yang sudah tersedia melalui berbagai modifikasi seperti rotasi, *flipping*, dan *cropping*. Teknik ini bertujuan untuk memperbesar ukuran dan meningkatkan keragaman dataset sehingga dapat mengurangi *overfitting* dan meningkatkan performa model [35]. Pada penelitian ini, augmentasi hanya diterapkan pada data di kelas minoritas. Metode yang digunakan untuk augmentasi meliputi rotasi, *flip*, dan *random erasing*. Gambar akan dirotasi secara acak dengan rentang sudut 0° hingga 45° derajat. Pada metode *flip*, gambar akan di-*flip* secara vertikal dan horizontal. Pada metode *random erasing*, gambar akan diberikan area persegi panjang dengan rasio aspek acak, kemudian nilai piksel asli diganti dengan nilai piksel acak (*noise*) atau rata-rata dataset (*mean*) [36].

### 3.2.6 Perancangan Model ResNet-18 dan ResNet-50

Tahapan ini merupakan penjelasan pada perancangan model ResNet-18 dan ResNet-50. Model ResNet menggunakan mekanisme *residual learning* dengan *skip connections* untuk mengatasi masalah *vanishing gradient*, dimana ResNet-18 memiliki 18 lapisan dan ResNet-50 memiliki 50 lapisan. Perancangan diawali dengan pembagian dataset menjadi data *training*, data *validation*, dan data *test*. Data *training* akan dilakukan augmentasi data pada kelas minoritas. Setelah pembagian dan augmentasi, dataset digunakan sebagai input pada model ResNet-18 dan ResNet-50 dan model melakukan *training*. Hasil *training* model akan disimpan dan dievaluasi untuk membandingkan performa antara kedua model.

### 3.2.7 Evaluasi

Tahapan ini adalah penjelasan terkait evaluasi yang akan digunakan pada model. Evaluasi terhadap model dilakukan menggunakan tiga cara, yakni *Confusion Matrix*, metrik evaluasi, dan *Matthews Correlation Coefficient* (MCC). *Confusion Matrix* digunakan untuk mengevaluasi kinerja model guna memberikan rincian mengenai tingkat efektivitas model. Nilai yang dihasilkan dari *Confusion Matrix* berupa nilai *True Positive*, *False Positive*, *True Negative*, dan *False Negative*. Nilai-nilai tersebut kemudian digunakan sebagai dasar perhitungan metrik evaluasi standar yang meliputi Akurasi, Presisi, *Recall*, dan *F1-Score*. Evaluasi ini juga menerapkan *Matthews Correlation Coefficient* (MCC). MCC digunakan karena kemampuannya memberikan penilaian yang lebih pada data yang tidak seimbang dibandingkan akurasi biasa.

## 3.3 Alat dan Bahan Tugas Akhir

Berisi alat-alat dan bahan-bahan yang digunakan dalam penelitian.

### 3.3.1 Alat

Berikut merupakan alat-alat yang digunakan dalam pelaksanaan penelitian:

1. Laptop
2. Code editor Microsoft Visual Studio Code
3. Python 3.10
4. Libray python: PyTorch, NumPy, Matplotlib.

### 3.3.2 Bahan

Penulis menggunakan dataset DermaMNIST yang merupakan bagian dari MedMNIST. Dataset terdiri dari citra penyakit kulit dengan 7 kelas berbeda, yaitu *melanocytic nevi* sebanyak 6705 gambar, *melanoma* sebanyak 1113 gambar, *benign keratosis-like lesions* sebanyak 1099 gambar, *basal cell carcinoma* sebanyak 514 gambar, *actinic keratoses and intraepithelial carcinoma* sebanyak 327 gambar, *vascular lesions* sebanyak 142 gambar, dan *dermatofibroma* sebanyak 115 gambar. Dataset ini digunakan untuk pelatihan dan pengujian model klasifikasi. DermaMNIST tersedia secara open access untuk digunakan dalam penelitian.

## 3.4 Metode Pengembangan

Metode yang akan digunakan pada penelitian adalah metode *Convolutional Neural Network* (CNN) dengan arsitektur ResNet-18 dan ResNet-50 untuk klasifikasi jenis penyakit kulit berdasarkan dataset DermaMNIST yang dimana membandingkan performa kedua arsitektur sebelum dan sesudah dilakukan augmentasi data yang dikhususkan untuk kelas minoritas. Penelitian sebelumnya dan penelitian yang dilakukan sama-sama menggunakan arsitektur *ResNet-18* dan *ResNet-50*, namun terdapat beberapa perbedaan pada modifikasi teknis di dalam arsitekturnya.

Perbedaan pertama terletak pada penggunaan *pretrained*. Pada penelitian sebelumnya, model yang digunakan untuk *training* dengan citra 28x28 dibangun dari awal atau *scratch*, dan untuk *training* dengan citra 224x224 menggunakan model yang sudah disediakan oleh *torchvision* namun tanpa menggunakan bobot

*pretrained*, yang ditandai dengan parameter *pretrained* bernilai ”False”. Artinya, seluruh bobot model diinisialisasi secara acak dan model belajar sepenuhnya dari nol.

Pada penelitian yang dilakukan, model yang digunakan untuk *training* dengan citra 224x224 menggunakan bobot *pretrained* dari ImageNet. Penggunaan *pretrained* memungkinkan model untuk memanfaatkan pengetahuan yang sudah dipelajari sebelumnya dari jutaan gambar pada dataset ImageNet. Hal ini sangat membantu terutama karena dataset DermaMNIST yang di-resize menjadi 224x224 memiliki kualitas gambar yang cenderung buram akibat upscaling dari ukuran asli 28x28. Dengan *pretrained*, model tidak perlu belajar dari awal sehingga proses *training* menjadi lebih efisien dan hasil yang didapatkan pun lebih baik.

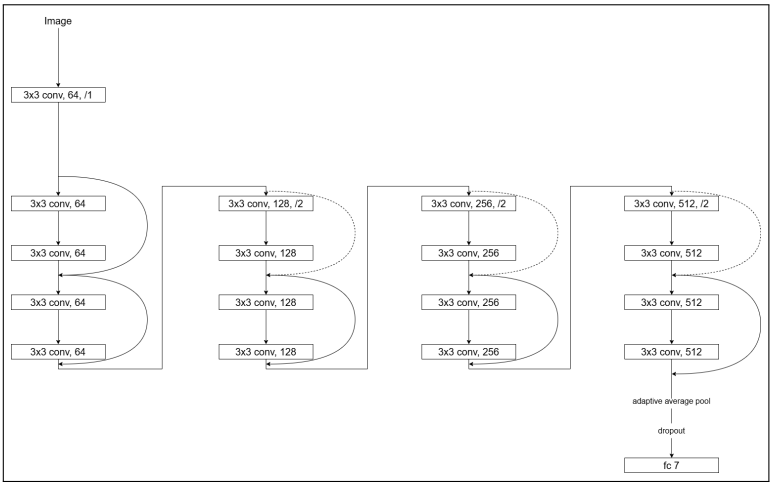


Gambar 3.2 Visualisasi Arsitektur *ResNet-18* Dengan *Dropout*

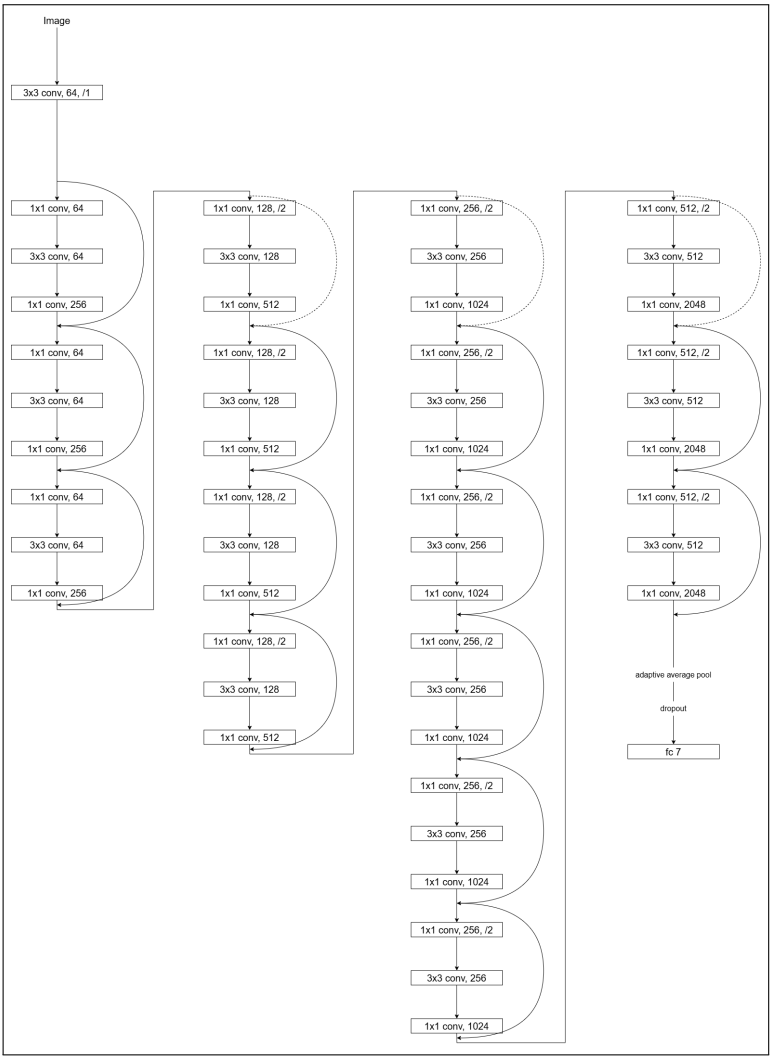


Gambar 3.3 Visualisasi Arsitektur *ResNet-50* Dengan *Dropout*

Perbedaan kedua terletak pada penggunaan *dropout*. Pada penelitian sebelumnya, tidak diterapkan *dropout* sama sekali pada arsitekturnya. Seluruh neuron aktif selama proses *training* berlangsung tanpa ada yang dinonaktifkan. Kondisi ini membuat model rentan terhadap *overfitting*, terutama karena dataset

DermaMNIST memiliki distribusi data yang tidak seimbang antar kelasnya. Pada penelitian yang dilakukan, ditambahkan *dropout* dengan *dropout rate* sebesar 0.7 yang diletakkan sebelum lapisan *fully connected*. Dengan *dropout rate* 0.7, sebanyak 70% neuron akan dinonaktifkan secara acak pada setiap iterasi *training*. Nilai *dropout* yang cukup tinggi ini sengaja dipilih karena model dilatih menggunakan data yang tidak seimbang sehingga risiko *overfitting* lebih tinggi. Dengan adanya *dropout*, model tidak terlalu bergantung pada neuron-neuron tertentu sehingga representasi fitur yang dipelajari menjadi lebih umum dan model lebih mampu melakukan generalisasi pada data baru. Visualisasi dari arsitektur *ResNet-18* dengan *dropout* dapat dilihat pada Gambar 3.2 dan visualisasi dari arsitektur *ResNet-50* dengan *dropout* dapat dilihat pada Gambar 3.3.

Perbedaan ketiga terletak pada modifikasi lapisan *fully connected*. Pada penelitian sebelumnya, lapisan *fully connected* menggunakan struktur standar yang langsung disediakan oleh *torchvision* tanpa ada modifikasi tambahan. Model langsung diarahkan untuk mengklasifikasikan data ke dalam jumlah kelas yang diinginkan tanpa penyesuaian khusus. Pada penelitian yang dilakukan, lapisan *fully connected* dimodifikasi menggunakan ”nn.Sequential” yang menggabungkan *dropout* dengan lapisan linear. Modifikasi ini dilakukan untuk dua tujuan sekaligus, yaitu menambahkan *dropout* sebagai pencegah *overfitting* dan menyesuaikan jumlah output model dengan jumlah kelas target yaitu 7 kelas penyakit kulit pada dataset DermaMNIST.

Perbedaan keempat terletak pada penggunaan *class weight* pada *loss function*. Penelitian sebelumnya tidak menggunakan *class weight* sehingga model memperlakukan semua kelas secara setara selama proses *training*. Dengan kata lain, kesalahan prediksi pada kelas mayoritas dan kelas minoritas dianggap sama pentingnya oleh model. Kondisi ini menyebabkan model lebih banyak belajar dari kelas mayoritas karena jumlah datanya yang jauh lebih banyak. Pada penelitian yang dilakukan, diterapkan *class weight* yang diletakkan pada *loss*

*function* yaitu cross-entropy loss. *Class weight* dihitung berdasarkan nilai invers dari jumlah data pada masing-masing kelas, sehingga kelas yang memiliki jumlah data lebih sedikit mendapatkan bobot yang lebih tinggi. Dengan cara ini, apabila model salah memprediksi data dari kelas minoritas maka penalti yang diterima model akan lebih besar dibandingkan jika model salah memprediksi data dari kelas mayoritas. Penerapan *class weight* ini membuat proses pembelajaran model menjadi lebih adil terhadap semua kelas meskipun jumlah datanya tidak seimbang.

## 3.5 Ilustrasi Perhitungan Metode

Berikut adalah ilustrasi perhitungan metode yang digunakan dalam penelitian.

### 3.5.1 Ilustrasi Perhitungan Konvolusi

Perhitungan lapisan konvolusi dilakukan dengan cara mengalikan matriks filter (*kernel*) dengan matriks input pada gambar. Misalkan terdapat matriks gambar sebesar 7x7 dan dan kernel 5x5. Selain itu, terdapat parameter lain yaitu *padding* dengan nilai 0 dan *stride* sebanyak 1 kali *kernel* bergeser. Contoh matriks input pada gambar 7x7 dapat dilihat pada Gambar 3.4.

| | | | | | | |
|---|---|---|---|---|---|---|
| 4 | 6 | 3 | 8 | 5 | 7 | 2 |
| 9 | 1 | 4 | 6 | 3 | 8 | 5 |
| 5 | 7 | 2 | 9 | 1 | 4 | 6 |
| 3 | 8 | 5 | 7 | 2 | 9 | 1 |
| 6 | 3 | 8 | 5 | 7 | 2 | 9 |
| 2 | 9 | 1 | 4 | 6 | 3 | 8 |
| 7 | 2 | 9 | 1 | 4 | 6 | 3 |

Gambar 3.4 Matriks Input Gambar 7x7

Kemudian terdapat *kernel* 5x5 yang akan digunakan untuk proses konvolusi. Contoh matriks *kernel* dapat dilihat pada Gambar 3.5.

| | | | | |
|---|---|---|---|---|
| 1 | 1 | 1 | 1 | 1 |
| 1 | -2 | -2 | 2 | 1 |
| 1 | -2 | -6 | -2 | 1 |
| 1 | 2 | -2 | -2 | 1 |
| 1 | 1 | 1 | 1 | 1 |

Gambar 3.5 Matriks Kernel 7x7

Selanjutnya dilakukan proses konvolusi dengan mengalikan matriks *kernel* dengan matriks input gambar. Hasil perkalian antar kedua matriks akan dijumlahkan dan menghasilkan sebuah nilai pertama dari hasil proses konvolusi. Proses konvolusi dapat dilihat pada Gambar 3.6.

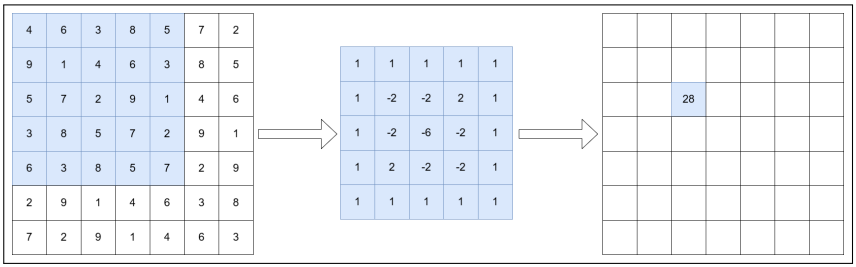


Gambar 3.6 Contoh Hasil Konvolusi

Berikut adalah perhitungan dari proses konvolusi pertama:

$$(4 \times 1) + (6 \times 1) + (3 \times 1) + (8 \times 1) + (5 \times 1) + (9 \times 1)$$
$$+ (1 \times (-2)) + (4 \times (-2)) + (6 \times 2) + (3 \times 1) + (5 \times 1) + (7 \times (-2))$$
$$+ (2 \times (-6)) + (9 \times (-2)) + (1 \times 1) + (3 \times 1) + (8 \times 2) + (5 \times (-2))$$
$$+ (7 \times (-2)) + (2 \times 1) + (6 \times 1) + (3 \times 1) + (8 \times 1) + (5 \times 1)$$
$$+ (7 \times 1) = 28$$

Proses konvolusi dilakukan secara berulang sesuai dengan parameter yang sudah ditentukan yaitu dengan pergeseran *stride* sebanyak 1 kali dan tanpa *padding*. Hasil akhir dari proses konvolusi ini adalah sebuah matriks output berukuran 3x3. Hasil akhir dari proses konvolusi dapat dilihat pada Gambar 3.8.

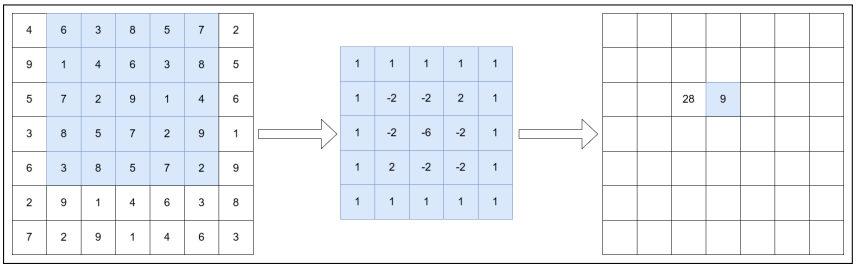


Gambar 3.7 Contoh Hasil Konvolusi

| | | |
|---|---|---|
| 28 | 9 | 37 |
| -11 | -6 | 15 |
| 5 | -19 | 11 |

Gambar 3.8 Hasil Akhir Proses Konvolusi

Berdasarkan gambar 3.8 menunjukkan bahwa hasil akhir dari proses konvolusi menghasilkan matriks output berukuran 3x3 yang dimana matriks yang dihasilkan lebih kecil dibandingkan dengan matriks input awal yang berukuran 7x7. Ukuran matriks output pada proses konvolusi dapat dihitung menggunakan rumus berikut:

$$OutputSize = \frac{I - F + 2P}{S} + 1$$

Keterangan:

I = Ukuran Input

F = Ukuran Kernel

P = Padding

S = Stride

### 3.5.2 Ilustrasi Perhitungan Fungsi Aktivasi ReLU

Fungsi aktivasi ReLU (Rectified Linear Unit) beroperasi dengan mengubah setiap nilai negatif dalam matriks menjadi 0, sedangkan nilai positif tidak mengalami perubahan. Fungsi ini diterapkan pada lapisan konvolusi dengan tujuan menambahkan non-linearitas ke dalam arsitektur model [20]. Berikut contoh perhitungan fungsi aktivasi ReLU pada output yang dihasilkan dari lapisan konvolusi sebelumnya.

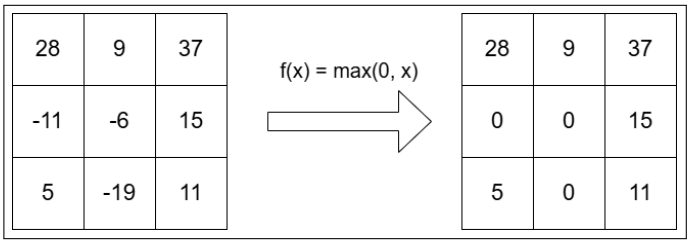


Gambar 3.9 Visualisasi Fungsi Aktivasi ReLU

### 3.5.3 Max Pooling dan Average Pooling

Proses pada lapisan *pooling* terdapat 2 jenis, *max pooling* dan *average pooling*. Max pooling yaitu mengekstrak nilai tertinggi dari setiap wilayah pada matriks yang telah melalui fungsi aktivasi ReLU. Kernel berukuran 2x2 digunakan dalam lapisan Pooling ini dengan parameter stride bernilai 1. Contoh implementasi perhitungan pada *max pooling* disajikan pada ilustrasi berikut:

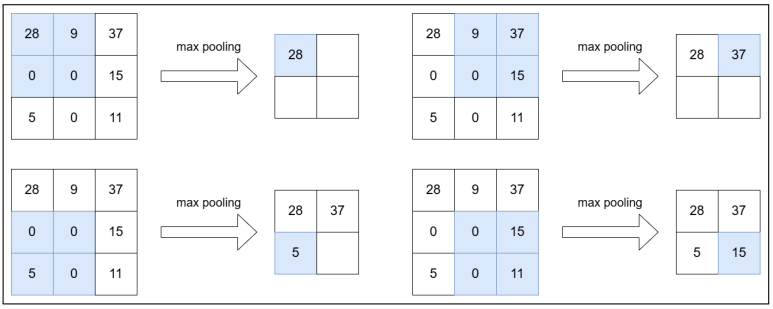


Gambar 3.10 Visualisasi Perhitungan Max Pooling

*Average pooling* yaitu mengekstrak nilai rata-rata dari setiap wilayah pada matriks yang telah melalui fungsi aktivasi ReLU. Kernel berukuran 2x2 digunakan dalam lapisan Pooling ini dengan parameter stride bernilai 1. Contoh implementasi perhitungan pada *average pooling* disajikan pada ilustrasi berikut:

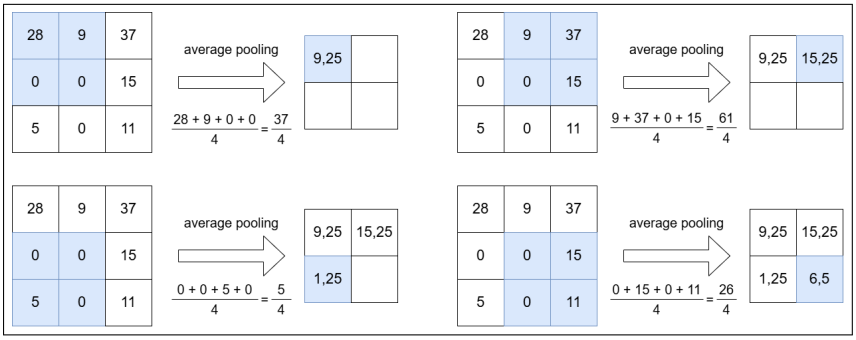


Gambar 3.11 Visualisasi Perhitungan Average Pooling

## 3.6 Rancangan Pengujian

Setelah proses pelatihan model selesai, model dievaluasi menggunakan *confussion matrix* dan *Matthews Correlation Coefficient* (MCC). Evaluasi ini bertujuan untuk mengukur kemampuan model dalam menggeneralisasi data baru.

### 3.6.1 Pengukuran *Confusion Matrix*

Pada penelitian ini, kinerja model diukur menggunakan metrik akurasi, presisi, recall, dan F1-Score yang didasarkan oleh pada confusion matrix. Matriks ini menggambarkan hubungan antara kelas aktual (*ground truth*) dengan kelas prediksi yang dihasilkan oleh model. Sebagai contoh perhitungan, tabel 3.1 menyajikan contoh data yang dihasilkan prediksi model pada data uji dari masing-masing kelasnya, yaitu *Actinic Keratosis and intraepithelial Carcinoma* (akiec), *Basal Cell Carcinoma* (bcc), *Benign Keratosis-Like Lesions* (bkl), *Dermatofibroma* (df), *Melanoma* (mel), *Melanocytic Nevi* (nv), dan *Vascular Lesions* (vasc).

Tabel 3.1 Contoh Hasil Confusion Matrix

| Aktual / Prediksi | akiec | bcc | bkl | df | mel | nv | vasc | Total Aktual |
|---|---|---|---|---|---|---|---|---|
| akiec | **8** | 2 | 1 | 0 | 0 | 1 | 0 | 12 |
| bcc | 1 | **12** | 2 | 0 | 1 | 2 | 0 | 18 |
| bkl | 2 | 1 | **15** | 0 | 2 | 3 | 0 | 23 |
| df | 0 | 0 | 1 | **6** | 1 | 1 | 0 | 9 |
| mel | 0 | 1 | 3 | 0 | **14** | 4 | 0 | 22 |
| nv | 1 | 3 | 5 | 1 | 5 | **40** | 1 | 56 |
| vasc | 0 | 0 | 0 | 0 | 0 | 1 | **9** | 10 |
| Total Prediksi | 12 | 19 | 27 | 7 | 23 | 52 | 10 | Total: 150 |

Untuk mengukur kinerja model terutama pada multi-kelas, perhitungan dilakukan untuk setiap kelas nya. Berikut perhitungan menggunakan kelas *Benign Keratosis-Like Lesions* (bkl) sebagai contoh.

Berdasarkan data yang ada pada tabel 3.1, didapatkannya nilai *True Positive* (TP), *False Positive* (FP), *True Negative* (TN), dan *False Negative* (FN) untuk

kelas bkl sebagai berikut:

1. *True Positive*

   Model berhasil memprediksi citra kelas bkl secara benar, di mana sampel yang memang termasuk kelas bkl diklasifikasikan sebagai bkl.

$$TP = 15$$

2. *False Positive*

   Model memprediksi suatu citra sebagai kelas bkl, namun citra tersebut sebenarnya kelas lain dan bukan termasuk kelas bkl.

$$FP = 1 + 2 + 1 + 3 + 5 + 0 = 12$$

3. *False Negative*

   Model salah memprediksi yang mana kelas bkl diklasifikasikan sebagai kelas lain.

$$FN = 2 + 1 + 0 + 2 + 3 + 0 = 8$$

4. *True Negative*

   Model secara tepat mengklasifikasikan citra yang tidak termasuk dalam kelas bkl ke dalam kelas lain yang sesuai (Total seluruh data dikurangi TP, FP, dan FN).

$$TN = 150 - (15 + 12 + 8) = 150 - 35 = 115$$

Nilai dari masing-masing komponen pada *confusion matrix* sudah didapatkan. Selanjutnya menghitung metrik evaluasi yang meliputi *accuracy*, *precision*, *recall*, dan *F1-Score* untuk mengukur kinerja model.

1. *Accuracy*

   *Accuracy* mengukur seberapa akurat model dalam mengklasifikasikan data, menilai seberapa baik model memprediksi hasil. Perhitungan menggunakan rumus yang sesuai pada Rumus 2.1. Berikut perhitungan *accuracy*:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Accuracy = \frac{15 + 115}{15 + 115 + 12 + 8} = \frac{130}{150} = 0,8667(86,67\%)$$

2. *Precision*

   Perhitungan *precision* menggunakan rumus yang sesuai pada Rumus 2.2. *Precision* diukur pada masing-masing kelas, sebagai contoh perhitungan dilakukan pada kelas bkl. Berikut perhitungan *precision*:

$$Precision = \frac{TP}{TP + FP}$$

$$Precision = \frac{15}{15 + 12} = \frac{15}{27} = 0,5556(55,56\%)$$

3. *Recall*

   Perhitungan *recall* menggunakan rumus yang sesuai pada Rumus 2.3. *Recall* diukur pada masing-masing kelas, sebagai contoh perhitungan dilakukan pada kelas bkl. Berikut perhitungan *recall*:

$$Recall = \frac{TP}{TP + FN}$$

$$Recall = \frac{15}{15 + 8} = \frac{15}{23} = 0,6521(65,21\%)$$

4. *F1-Score*

   Perhitungan *F1-Score* menggunakan rumus yang sesuai pada Rumus 2.4. *F1-Score* diukur pada masing-masing kelas, sebagai contoh perhitungan dilakukan pada kelas bkl. Berikut perhitungan *F1-Score*:

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

$$F1 - Score = 2 \times \frac{0,5556 \times 0,6521}{0,5556 + 0,6521} = 2 \times \frac{0,3623}{1,2077} = 0,5999(59,99\%)$$

Tabel 3.2 menyajikan hasil lengkap dari perhitungan *precision*, *recall*, dan *F1-score* dari ketujuh kelas. Tabel 3.2 dapat dilihat dibawah ini.

Tabel 3.2 Hasil Perhitungan Metrik Evaluasi per Kelas

| | *Precision* | *Recall* | *F1-score* |
|---|---|---|---|
| akiec | 0,6667 | 0,6667 | 0,6667 |
| bcc | 0,6315 | 0,6667 | 0,6486 |
| bkl | 0,5556 | 0,6521 | 0,5999 |
| df | 0,8571 | 0,6667 | 0,7500 |
| mel | 0,6086 | 0,6363 | 0,6221 |
| nv | 0,7692 | 0,7142 | 0,7406 |
| vasc | 0,9 | 0,9 | 0,9 |

Singkatan pada tabel 3.2 merupakan singkatan dari masing-masing kelas, yaitu akiec untuk *Actinic Keratosis and intraepithelial Carcinoma*, bcc untuk *Basal Cell Carcinoma*, bkl untuk *Benign Keratosis-Like Lesions*, df untuk *Dermatofibroma*, mel untuk *Melanoma*, nv untuk *Melanocytic Nevi*, dan vasc untuk *Vascular Lesions*. Penjelasan dari masing-masing kelas dapat dilihat pada dasar teori yang menjelaskan dataset DermaMNIST.

### 3.6.2 Perhitungan Macro Average

*Macro average* digunakan untuk mengevaluasi kinerja model secara objektif tanpa dipengaruhi oleh jumlah sampel data pada setiap kelas. Nilai *F1-Score* dihitung secara terpisah untuk masing-masing kelas, kemudian dirata-ratakan secara aritmatika sederhana. Untuk contoh perhitungan, perhitungan *macro average* menggunakan nilai *F1-Score* dari masing-masing kelas yang pada tabel 3.2. Berikut perhitungan *macro average*:

$$Macro\ Average = \frac{F1_{akiec} + F1_{bcc} + F1_{bkl} + F1_{df}}{7}$$

$$+\frac{F1_{mel} + F1_{nv} + F1_{vasc}}{7}$$

$$Macro\ Average = \frac{0,6667 + 0,6486 + 0,5999 + 0,7500 + 0,6221 + 0,7406 + 0,9}{7}$$

$$= \frac{4,9279}{7} = 0,7040\ (70,40\%)$$

### 3.6.3 Perhitungan Matthews Correlation Coefficient

*Matthews Correlation Coefficient* digunakan untuk mengukur kualitas pada klasifikasi biner maupun multi-kelas. Koefisien ini memperhitungkan *true* dan *false positives*, dan *negatives*. MCC adalah nilai korelasi koefisian antara -1 dan +1. Koefisien +1 mewakili prediksi yang sempurna, 0 mewakili prediksi acak rata-rata, dan -1 mewakili prediksi terbalik. MCC memperhitungkan seluruh elemen *confusion matrix* (TP, TN, FP, FN). Rumus MCC untuk multi-kelas adalah sebagai berikut.

$$MCC = \frac{c \times s - \sum_k^K p_k \times t_k}{\sqrt{(s^2 - \sum_k^K p_k^2) \times (s^2 - \sum_k^K t_k^2)}}$$

Keterangan:

k: Jumlah total kelas

c: Jumlah total sampel yang diprediksi dengan benar (*True Positive*)

s: Jumlah total keseluruhan sampel

$p_k$: jumlah prediksi untuk kelas k (total elemen yang diprediksi sebagai kelas k)

$t_k$: jumlah sampel aktual untuk kelas k (ground truth untuk kelas k)

Pertama mengidentifikasi nilai variabel yang diperlukan pada kelas bkl,

yang mana diperoleh nilai-nilai berikut:

1. K (Jumlah total kelas) = 7
2. c (Jumlah total yang diprediksi dengan benar) = 8 + 12 + 15 + 6 + 14 + 40 + 9 = 104
3. s (Jumlah total keseluruhan) = 150
4. $p_k$ (Jumlah prediksi untuk kelas bkl)

   $p_{akiec}$ = 12, $p_{bcc}$ = 19, $p_{bkl}$ = 27, $p_{df}$ = 7, $p_{mel}$ = 23, $p_{nv}$ = 52, $p_{vasc}$ = 10
5. $t_k$ (Jumlah sampel aktual untuk kelas bkl)

   $t_{akiec}$ = 12, $t_{bcc}$ = 18, $t_{bkl}$ = 23, $t_{df}$ = 9, $t_{mel}$ = 22, $t_{nv}$ = 56, $t_{vasc}$ = 10

Setelah mengidentifikasi nilai variabel yang diperlukan, selanjutnya melakukan perhitungan secara bertahap.

1. Menghitung $\sum_k^K p_k \times t_k$

$$\sum_k^K p_k \times t_k = (12\times12)+(19\times18)+(27\times23)+(7\times9)+(23\times22)+(52\times56)+(10\times10)$$
$$= 144 + 342 + 621 + 63 + 506 + 2.912 + 100 = 4.688$$

2. Menghitung $\sum_k^K p_k^2$ dan $\sum_k^K t_k^2$

$$\sum_k^K t_k^2 = 12^2 + 18^2 + 23^2 + 9^2 + 22^2 + 56^2 + 10^2$$
$$= 144 + 324 + 529 + 81 + 484 + 3.136 + 100 = 4.798$$

$$\sum_{k}^{K} p_k^2 = 12^2 + 19^2 + 27^2 + 7^2 + 23^2 + 52^2 + 10^2$$
$$= 144 + 361 + 729 + 49 + 529 + 2.704 + 100 = 4.616$$

3. Menghitung nilai MCC

$$MCC = \frac{(104 \times 150) - 4.688}{\sqrt{(150^2 - 4.616) \times (150^2 - 4.798)}}$$

$$MCC = \frac{15.600 - 4.688}{\sqrt{(22.500 - 4.616) \times (22.500 - 4.798)}}$$

$$MCC = \frac{10.912}{\sqrt{17.884 \times 17.702}}$$

$$MCC = \frac{10.912}{\sqrt{316.582.568}}$$

$$MCC = \frac{10.912}{17.792,76} \approx 0,613$$

Berdasarkan hasil perhitungan ilustrasi di atas menunjukkan nilai MCC sebesar 0,613. Nilai ini mengindikasikan korelasi positif yang cukup kuat antara hasil prediksi model dengan label sebenarnya, meskipun terdapat ketidakseimbangan jumlah data antar kelas.

# BAB IV
# HASIL DAN PEMBAHASAN

## 4.1 Hasil Penelitian

Berikut merupakan hasil penelitian terhadap arsitektur *ResNet-18* dan *ResNet-50* dengan menerapkan augmentasi data kelas minoritas pada dataset DermaMNIST yang dilakukan oleh penulis.

### 4.1.1 Akuisisi Dataset

Dataset yang digunakan merupakan dataset *open-source* yang di-*import* dari website MedMNIST. Dataset yang dipilih untuk penelitian ini yaitu dataset DermaMNIST yang merupakan citra dermatoskopi dari lesi kulit. Citra dari dataset memiliki resolusi asli 28x28 piksel berwarna RGB yang terbagi menjadi 7 kelas penyakit. Berikut 7 kelas penyakit beserta contoh citra dari masing-masing kelas.

Tabel 4.1 Contoh Citra dari Setiap Kelas Penyakit

| No. | Kelas Penyakit | Gambar |
|---|---|---|
| 1. | *Actinic Keratoses* dan *Intraepithelial Carcinoma* | 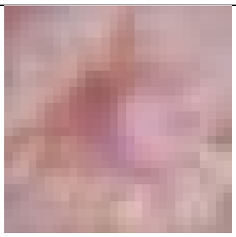 |
| 2. | *Basal Cell Carcinoma* | 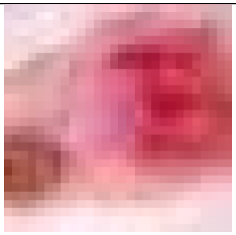 |

| No. | Kelas Penyakit | Gambar |
|---|---|---|
| 3 | *Benign Keratosis-like Lesions* | 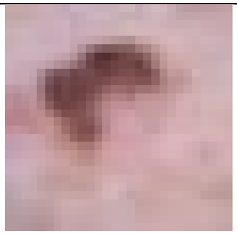 |
| 4. | *Dermatofibroma* | |
| 5. | *Melanocytic Nevi* | 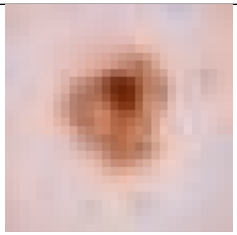 |
| 6. | *Melanoma* | 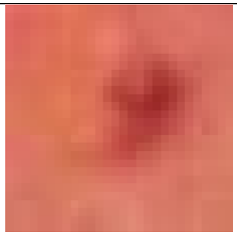 |
| 7. | *Vascular Lesions* | 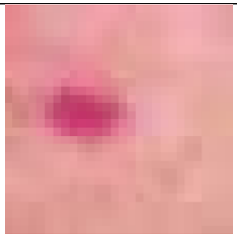 |

### 4.1.2 Pembagian Dataset

Dataset yang digunakan dalam penelitian ini memiliki jumlah data sebanyak 10.015 yang dibagi menjadi tiga bagian yaitu data latih (training data), data validasi (validation data), dan data uji (test data). Data latih dan data validasi digunakan untuk proses *training* dan *validation* model, sedangkan data uji digunakan untuk menguji performa model setelah proses *training* selesai. Pembagian dataset dibagi dengan ratio 70% data latih, 10% data validasi, dan 20% data uji. Jumlah data latih sebanyak 7.007 data, data validasi sebanyak 1.003 data, dan data uji sebanyak 2.005 data. Untuk persebaran data latih, validasi, dan tes per kelasnya disajikan dalam Tabel 4.2.

Tabel 4.2 Persebaran Data

| **Nama Kelas** | **Data Latih** | **Data Validasi** | **Data Uji** | **Total Data** |
|---|---|---|---|---|
| *Actinic Keratoses and Intraepithelial Carcinoma* | 228 | 33 | 66 | 327 |
| *Basal Cell Carcinoma* | 359 | 52 | 103 | 514 |
| *Benign Keratosis-like Lesions* | 769 | 110 | 220 | 1099 |
| *Dermatofibroma* | 80 | 12 | 23 | 115 |
| *Melanoma* | 779 | 111 | 223 | 1113 |
| *Melanocytic Nevi* | 4693 | 671 | 1341 | 6705 |
| *Vascular Lesions* | 99 | 14 | 29 | 142 |

### 4.1.3 *Preprocessing* Data

Pada tahap ini dataset dilakukan *preprocessing* sebelum dataset masuk ke model untuk dilakukannya proses *training*. *Preprocessing* yang dilakukan yaitu *resize* dan normalisasi nilai citra. *Resize* dilakukan untuk mengubah resolusi citra dari 28x28 piksel menjadi 224x224 piksel. Proses ini dilakukan untuk menyesuaikan inputan model yang dimana *ResNet* menerima inputan citra dengan resolusi 224x224 piksel. Selain itu, alasan citra dilakukan *resize* menjadi 224x224 piksel dikarenakan ingin melakukan perbandingan hasil dengan hasil

yang model yang di-*training* dengan resolusi citra 28x28 piksel.

Kemudian dilakukannya normalisasi nilai citra untuk mengubah rentang nilai piksel dari [0, 255] menjadi [0, 1]. Normalisasi dilakukan supaya saat proses *training* stabil. Normalisasi menggunakan nilai mean dan standar deviasi dari ImageNet yaitu [0.485, 0.456, 0.406] dan [0.229, 0.224, 0.225].

Kode 4.1 Kode Normalisasi dan Resize

```
data_mean = [0.485, 0.456, 0.406]
data_std = [0.229, 0.224, 0.225]

def get_base_transform(size):
    return transforms.Compose([
        transforms.Resize((size, size)),
        transforms.ToTensor(),
        transforms.Normalize(mean=data_mean, std=data_std)
    ])
```

### 4.1.4 Augmentasi Data

Dataset yang sudah melewati *preprocessing*, dataset di-augmentasi untuk memperbanyak jumlah data dan model dapat belajar dari berbagai jenis variasi citra. Augmentasi dilakukan hanya data pada kelas minoritas saja. Augmentasi yang dilakukan pada penelitian ini yaitu *flip* (horizontal dan vertikal), *rotation*, *color jitter*, *random erasing*, dan *random augment*. Penerapan augmentasi ini bertujuan untuk mengurangi ketidakseimbangan distribusi kelas sehingga model tidak cenderung bias terhadap kelas mayoritas. Dengan variasi transformasi tersebut, model diharapkan mampu mempelajari fitur terhadap perubahan orientasi, pencahayaan, maupun gangguan visual pada citra.

Kode 4.2 Kode Augmentasi Data

```
def get_aug_transform(size):
    return transforms.Compose([
        transforms.Resize((size, size)),
        transforms.RandAugment(num_ops=2, magnitude=9),
        transforms.RandomHorizontalFlip(p=0.5),
        transforms.RandomVerticalFlip(p=0.5),
        transforms.RandomRotation(degrees=20),
        transforms.ColorJitter(brightness=0.3, contrast=0.3,
     saturation=0.3, hue=0.1),

        transforms.ToTensor(),

        transforms.RandomErasing(p=0.5, scale=(0.02, 0.15)),

        transforms.Normalize(mean=data_mean, std=data_std)
    ])
```

#### 4.1.4.1 *Flip*

*Flip* merupakan teknik augmentasi yang membalikkan orientasi citra secara horizontal maupun vertikal. Teknik ini bertujuan supaya model dapat belajar fitur objek dari berbagai sudut pandang.

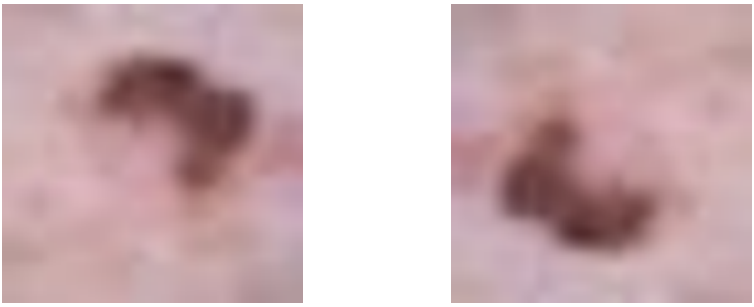

(a) Flip Horizontal (b) Flip Vertical

Gambar 4.1 Hasil Augmentasi Flip

#### 4.1.4.2 *Rotation*

*Rotation* merupakan teknik augmentasi yang memutar citra dengan sudut tertentu. Rotasi pada gambar dapat membantu model untuk mengenali objek dari berbagai sudut pandang. Teknik ini bertujuan supaya model tidak bingung ketika menemui gambar yang posisinya miring di dunia nyata. Pada penelitian ini, rotasi dilakukan dengan sudut 20 derajat.

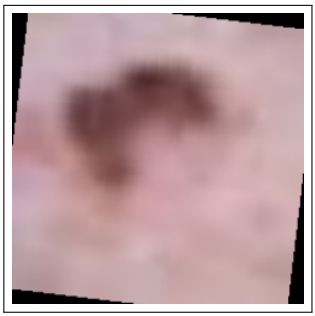

Gambar 4.2 Hasil Augmentasi Rotasi

#### 4.1.4.3 *Color Jitter*

*Color jitter* merupakan teknik augmentasi yang memodifikasi karakteristik warna pada citra seperti *brightness*, *contrast*, *saturation*, dan *hue* secara acak atau bisa diatur secara manual. Teknik ini bertujuan agar model tidak bergantung pada kondisi pencahayaan atau distribusi warna tertentu pada gambar.

Gambar 4.3 Hasil Augmentasi Color Jitter

#### 4.1.4.4 *Random Erasing*

*Random erasing* merupakan teknik augmentasi yang menghapus objek secara sengaja atau menutupi beberapa bagian secara acak dengan sebuah area berbentuk persegi panjang. Teknik ini bertujuan supaya model tidak menghafal pola tertenut pada gambar.

Gambar 4.4 Hasil Augmentasi Random Erasing

#### 4.1.4.5 *Random Augment*

*Random augment* merupakan teknik augmentasi yang menerapkan kombinasi beberapa transformasi secara acak pada citra dalam satu proses augmentasi. Teknik ini bertujuan untuk menghasilkan variasi data yang lebih beragam sehingga model tidak menghafal pola tertentu dan mampu melakukan generalisasi dengan lebih baik.

Gambar 4.5 Hasil Augmentasi Random Augment

### 4.1.5 Hasil *Training* Model

Pada penelitian ini, didapatkan hasil *training* model dengan menggunakan arsitektur *ResNet-18* dan *ResNet-50* dengan menerapkan augmentasi data kelas minoritas pada dataset DermaMNIST. Hasil yang disajikan dari masing-masing model dan *size* ukuran citra yang digunakan yaitu 28x28 piksel dan 224x224 piksel.

#### 4.1.5.1 Hasil *ResNet-18* Menggunakan Citra *Size* 28x28 Piksel

Pada model *ResNet-18 scratch* ini di *training* menggunakan citra berukuran 28x28 piksel. Model yang digunakan merupakan model *scratch*, yang dimana model menginisialisasi bobot secara acak. Hal ini berarti proses pembelajaran dilakukan sepenuhnya berdasarkan data penelitian tanpa memanfaatkan bobot *pretrained*. Struktur kode model dapat dilihat pada Kode 4.3 dan hasil evaluasi

disajikan pada Tabel 4.3.

Kode 4.3 Kode ResNet-18 28x28

```
class BasicBlock(nn.Module):
    expansion = 1
    def __init__(self, in_planes, planes, stride=1):
        super(BasicBlock, self).__init__()
        self.conv1 = nn.Conv2d(in_planes, planes, kernel_size=3,
     stride=stride, padding=1, bias=False)
        self.bn1 = nn.BatchNorm2d(planes)
        self.conv2 = nn.Conv2d(planes, planes, kernel_size=3,
     stride=1, padding=1, bias=False)
        self.bn2 = nn.BatchNorm2d(planes)
        self.shortcut = nn.Sequential()
        if stride != 1 or in_planes != self.expansion*planes:
            self.shortcut = nn.Sequential(
                nn.Conv2d(in_planes, self.expansion*planes,
     kernel_size=1, stride=stride, bias=False),
                nn.BatchNorm2d(self.expansion*planes)
            )
    def forward(self, x):
        out = F.relu(self.bn1(self.conv1(x)))
        out = self.bn2(self.conv2(out))
        out += self.shortcut(x)
        out = F.relu(out)
        return out
```

Tabel 4.3 Hasil Evaluasi *ResNet-18* Dengan Citra 28×28 Piksel

| **Metrik Evaluasi** | **Nilai** |
|---|---|
| *Accuracy* | 0.60 |
| *Precision* (Macro) | 0.44 |
| *Recall* (Macro) | 0.62 |
| *F1-Score* (Macro) | 0.45 |
| *Matthews Correlation Coefficient* | 0.41 |
| *AUC* | 0.91 |

Berdasarkan Tabel 4.3, model *ResNet-18* menghasilkan akurasi sebesar 0.60. Walaupun demikian, nilai *F1-Score* makro yang dihasilkan hanya 0.45 yang menunjukkan bahwa model memiliki performa yang kurang baik. Hal ini dikarenakan nilai *precision* makro (0.44) yang rendah dibandingkan nilai *recall* makro (0.62). Kondisi menunjukkan model mampu mendeteksi dalam cakupan yang cukup luas tetapi tingkat ketepatan dalam mendeteksi masih rendah yang mengakibatkan *false positive* meningkat. Didukung dengan nilai *matthews correlation coefficient* (0.41) yang menunjukkan bahwa prediksi model masih tidak efektif yang menyebabkan model masih tidak optimal, walaupun model

cukup bagus dalam membedakan kelas yang ditunjukkan pada nilai *AUC* sebesar 0.91.

#### 4.1.5.2 Hasil *ResNet-50* Menggunakan Citra *Size* 28x28 Piksel

Pada model *ResNet-50 scratch* ini di *training* menggunakan citra 28x28 piksel. Struktur kode model dapat dilihat pada Kode 4.4 dan hasil evaluasi disajikan pada Tabel 4.4.

Kode 4.4 Kode ResNet-50 28x28

```
class Bottleneck(nn.Module):
    expansion = 4
    def __init__(self, in_planes, planes, stride=1):
        super(Bottleneck, self).__init__()
        self.conv1 = nn.Conv2d(in_planes, planes, kernel_size=1, bias=False)
        self.bn1 = nn.BatchNorm2d(planes)
        self.conv2 = nn.Conv2d(planes, planes, kernel_size=3, stride=stride, padding=1, bias=False)
        self.bn2 = nn.BatchNorm2d(planes)
        self.conv3 = nn.Conv2d(planes, self.expansion * planes, kernel_size=1, bias=False)
        self.bn3 = nn.BatchNorm2d(self.expansion*planes)
        self.shortcut = nn.Sequential()
        if stride != 1 or in_planes != self.expansion*planes:
            self.shortcut = nn.Sequential(
                nn.Conv2d(in_planes, self.expansion*planes, kernel_size=1, stride=stride, bias=False),
                nn.BatchNorm2d(self.expansion*planes)
            )
    def forward(self, x):
        out = F.relu(self.bn1(self.conv1(x)))
        out = F.relu(self.bn2(self.conv2(out)))
        out = self.bn3(self.conv3(out))
        out += self.shortcut(x)
        out = F.relu(out)
        return out
```

Tabel 4.4 Hasil Evaluasi *ResNet-50* Dengan Citra 28×28 Piksel

| **Metrik Evaluasi** | **Nilai** |
|---|---|
| *Accuracy* | 0.62 |
| *Precision* (Macro) | 0.41 |
| *Recall* (Macro) | 0.59 |
| *F1-Score* (Macro) | 0.45 |
| *Matthews Correlation Coefficient* | 0.44 |
| *AUC* | 0.89 |

Berdasarkan Tabel 4.4, model *ResNet-50* mencapai akurasi sebesar 0.62. Nilai *f1-score* makro sebesar 0.45 menandakan terdapat masalah pada konsistensi

performa di seluruh kelas yang disebabkan rendahnya nilai *precision* makro. Jika nilai *precision* makro (0.41) dibandingkan dengan nilai *recall* makro (0.59), membuat karakteristik model cenderung mengklasifikasikan banyak data sebagai kelas positif, tapi membuat risiko meninggkatnya *false positive*. Nilai *matthews correlation coefficient* (MCC) sebesar 0.44 membuat kondisi menjadi selaras. Model masih tidak efektif ditandai dengan hubungan antara hasil klasifikasi dan label aktual masih belum mencapai tahap optimal. Meski demikian, model masih mampu untuk memisahkan antar kelas dengan baik yang ditunjukkan pada nilai *AUC* sebesar 0.89.

#### 4.1.5.3 Hasil *ResNet-18* Menggunakan Citra *Size* 224x224 Piksel

Pada proses *training* ini, menggunakan model *ResNet-18* pretrained dari ImageNet. Penggunaan model *pretrained* dikarenakan dataset yang di-*resize* menjadi 224x224 piksel. Dataset akan buram dikarenakan ukuran asli citra yaitu 28x28 piksel. Kode untuk model *ResNet-18 pretrained* dapat dilihat pada Kode 4.5 dan hasil evaluasi disajikan pada Tabel 4.5.

Kode 4.5 Kode ResNet-18 224x224

```
if model_flag == 'resnet18':
            # Untuk ResNet18 (Size 224)
            model = resnet18(weights=ResNet18_Weights.IMAGENET1K_V1)
            num_ftrs = model.fc.in_features
            model.fc = nn.Sequential(
                nn.Dropout(p=dropout_prob),
                nn.Linear(num_ftrs, n_classes)
            )
```

Tabel 4.5 Hasil Evaluasi *ResNet-18* Dengan Citra 224×224 Piksel

| **Metrik Evaluasi** | **Nilai** |
|---|---|
| *Accuracy* | 0.80 |
| *Precision* (Macro) | 0.71 |
| *Recall* (Macro) | 0.76 |
| *F1-Score* (Macro) | 0.73 |
| *Matthews Correlation Coefficient* | 0.64 |
| *AUC* | 0.95 |

Berdasarkan hasil evaluasi yang tersaji pada Tabel 4.5, model *ResNet-18 pretrained* dengan citra berukuran 224x224 piksel menunjukkan akurasi yang mencapai 0.80. Nilai *f1-score* makro mencapai 0.73 menunjukkan model memiliki keseimbangan yang cukup baik dalam mengenali data pada setiap kelasnya. Nilai *precision* makro (0.71) dan nilai *recall* makro (0.76) yang mana selisih keduanya tidak terlalu jauh, membuat model dapat meminimalkan kesalahan dalam prediksi. Nilai *matthews correlation coefficient* (MCC) sebesar 0.64 menandakan terdapat korelasi positif yang cukup kuat antara hasil prediksi dengan label aktualnya. Model mampu memisahkan antar kelas dengan baik yang ditunjukkan pada nilai *AUC* sebesar 0.95.

#### 4.1.5.4 Hasil *ResNet-50* Menggunakan Citra *Size* 224x224 Piksel

Pada proses *training* ini, model yang digunakan merupakan model *ResNet-50 pretrained* dari ImageNet. Data inputan berupa citra dengan ukuran 224x224 piksel. Kode untuk model *ResNet-50 pretrained* dapat dilihat pada Kode dan hasil evaluasi disajikan pada Tabel .

Kode 4.6 Kode ResNet-50 224x224

```
else:
    # Untuk ResNet50 (Size 224)
    model = resnet50(weights=ResNet50_Weights.IMAGENET1K_V1)
    num_ftrs = model.fc.in_features
    model.fc = nn.Sequential(
        nn.Dropout(p=dropout_prob),
        nn.Linear(num_ftrs, n_classes)
    )
```

Tabel 4.6 Hasil Evaluasi *ResNet-50* Dengan Citra 224×224 Piksel

| **Metrik Evaluasi** | **Nilai** |
|---|---|
| *Accuracy* | 0.74 |
| *Precision* (Macro) | 0.69 |
| *Recall* (Macro) | 0.74 |
| *F1-Score* (Macro) | 0.70 |
| *Matthews Correlation Coefficient* | 0.59 |
| *AUC* | 0.95 |

Berdasarkan hasil evaluasi pada Tabel 4.3, model *ResNet-50 pretrained* memperoleh akurasi sebesar 0.74. *F1-score* makro yang didapatkan sebesar 0.70 memberikan gambaran bahwa model cukup baik dalam identifikasi pada seluruh kelas. *Precision* makro dengan nilai 0.69 dan *recall* dengan nilai 0.74 menunjukkan kesalahan yang rendah dengan deteksi yang cukup baik. Selain itu, MCC yang didapatkan adalah 0.59 dan nilai *AUC* sebesar 0.95.

## 4.2 Analisis Hasil Penelitian

Pada bagian ini dilakukan analisis perbandingan antara hasil *baseline* dengan hasil penelitian yang sudah dilakukan. Perbandingan dilakukan untuk melihat performa yang berhasil dicapai seperti dari segi akurasi, *loss*, maupun ketahanan model dalam menangani variasi data.

Perbandingan antara penelitian sebelumnya yang tidak menerapkan augmentasi kelas minoritas dengan penelitian yang dikerjakan dapat dilihat dari tiga faktor utama yaitu strategi augmentasi untuk penanganan data tidak seimbang, performa metrik evaluasi, dan ketahanan model terhadap *overfitting*.

Penelitian sebelumnya tidak melakukan teknik augmentasi apapun, terutama pada kelas minoritasnya. Penelitian sebelumnya hanya sebatas melakukan *preprocessing* berupa *resize* citra dan normalisasi citra. Tanpa augmentasi pada kelas minoritas, model cenderung lebih banyak belajar dari kelas mayoritas yaitu Melanocytic Nevi yang memiliki 4.693 data latih, sementara kelas minoritas seperti Dermatofibroma hanya memiliki 80 data latih. Kondisi ini membuat model kurang mampu mengenali pola pada kelas minoritas secara maksimal.

Dibandingkan dengan penelitian yang dilakukan, diterapkan teknik augmentasi khusus pada kelas minoritas menggunakan beberapa teknik sekaligus yaitu *flip* horizontal dan vertikal, *rotation* sebesar 20 derajat, *color jitter*, *random erasing*, dan *random augment*. Dengan menerapkan beberapa teknik augmentasi tersebut secara bersamaan, variasi data pada kelas minoritas menjadi lebih

beragam sehingga model memiliki lebih banyak kesempatan untuk mempelajari karakteristik kelas minoritas. Selain itu, penelitian ini juga menggunakan *class weight* yang diterapkan pada *loss function*. *Class weight* memberikan penalti yang lebih besar apabila model salah memprediksi pada kelas minoritas, sehingga model tidak hanya fokus belajar dari kelas mayoritas saja.

Perbedaan yang paling terlihat antara penelitian sebelumnya dan penelitian yang dilakukan ada pada nilai *recall* dan *f1-score*. Pada penelitian sebelumnya, model *ResNet-18* dengan citra 224x224 hanya mendapatkan nilai *recall* sebesar 0.53. Artinya, dari seluruh data yang seharusnya terdeteksi pada masing-masing kelas, model hanya mampu mendeteksi sekitar setengahnya saja. Nilai *recall* yang rendah ini menunjukkan bahwa model masih sering gagal mendeteksi data yang benar, terutama pada kelas minoritas.

Sementara pada penelitian yang dilakukan, nilai *recall* pada model *ResNet-18* dengan citra 224x224 berhasil meningkat menjadi 0.76. Peningkatan ini menunjukkan bahwa dengan adanya augmentasi pada kelas minoritas, model menjadi lebih mampu mengenali data dari masing-masing kelas, termasuk kelas yang datanya sedikit. Selisih nilai recall antara kedua penelitian ini cukup besar yaitu sebesar 0.23, yang membuktikan bahwa augmentasi kelas minoritas memberikan pengaruh terhadap kemampuan model dalam mendeteksi data pada tiap kelas.

Untuk nilai *f1-score*, penelitian sebelumnya hanya mendapatkan nilai 0.56 pada model *ResNet-18* dengan citra 224x224. Nilai *f1-score* yang rendah ini terjadi karena selisih antara nilai *precision* dan *recall* yang cukup jauh, yaitu *precision* 0.66 dan *recall* hanya 0.53. Sedangkan pada penelitian yang dilakukan, nilai *f1-score* berhasil mencapai 0.73 dengan nilai *precision* 0.71 dan *recall* 0.76 yang selisihnya tidak terlalu jauh. Hal ini menunjukkan model yang menggunakan augmentasi kelas minoritas lebih seimbang dalam hal ketepatan prediksi dan kemampuan mendeteksi data yang benar.

Penelitian yang dilakukan juga menambahkan metrik evaluasi khusus

untuk data tidak seimbang yaitu *Matthews Correlation Coefficient* (MCC). Metrik ini digunakan karena lebih adil dalam menilai performa model pada data yang tidak seimbang dibandingkan hanya menggunakan akurasi biasa. Nilai MCC yang diperoleh sebesar 0.64 pada model terbaik yaitu *ResNet-18* dengan citra 224x224, membuktikan terdapat korelasi positif yang cukup kuat antara hasil prediksi dengan label aktualnya meskipun data antar kelas tidak seimbang. Penelitian sebelumnya tidak menggunakan MCC sebagai metrik evaluasinya sehingga penilaian performa model pada kondisi data tidak seimbang menjadi kurang menyeluruh.

Dari sisi ketahanan model terhadap *overfitting*, penelitian sebelumnya tidak menggunakan *dropout* sehingga seluruh neuron aktif selama proses *training*. Kondisi ini membuat model cenderung menghafal data latih dan kurang mampu melakukan generalisasi pada data baru, yang ditandai dengan grafik val loss yang tidak menurun bahkan cenderung naik selama proses *training* berlangsung.

Pada penelitian yang dilakukan, diterapkan *dropout* dengan nilai 0.7 yang diletakkan sebelum lapisan *fully connected*. Artinya sebanyak 70% neuron dinonaktifkan secara acak pada setiap iterasi *training*. Penerapan *dropout* ini terbukti membantu menekan risiko *overfitting* yang dapat dilihat dari grafik val loss yang cenderung menurun seiring berjalannya proses *training* meskipun terdapat beberapa lonjakan di beberapa epoch. Dengan grafik val loss yang menurun, model menjadi lebih stabil dan mampu melakukan generalisasi yang lebih baik terhadap data baru yang belum pernah dilihat sebelumnya.

### 4.2.1 Hasil Model *Baseline*

Model *baseline* melakukan *training* menggunakan dua arsitektur yaitu *ResNet-18* dan *ResNet-50* dan menggunakan citra dengan ukuran 28x28 dan 224x224 piksel sebagai inputan di masing-masing model. Pada model *baseline* tidak dilakukannya augmentasi pada data terutama pada kelas minoritas nya. *Baseline* hanya melakukan *rezise* dan normalisasi.

#### 4.2.1.1 Model *ResNet-18 Baseline*

Model *ResNet-18 baseline* di-*training* menggunakan dua ukuran citra. Untuk *training* yang menggunakan citra 28x28 piksel, model menggunakan *scratch* sedangkan untuk *training* yang menggunakan citra 224x224 piksel, model menggunakan model yang sudah disediakan oleh *torchvision*. Hasil evaluasi disajikan pada Tabel 4.7 untuk *training* 28x28 piksel dan Tabel 4.8 untuk *training* 224x224 piksel.

Tabel 4.7 Hasil Evaluasi *ResNet-18 Baseline* dengan Citra 28×28 Piksel

| **Metrik Evaluasi** | **Nilai** |
|---|---|
| *Accuracy* | 0.75 |
| *Precision* (Macro) | 0.62 |
| *Recall* (Macro) | 0.50 |
| *F1-Score* (Macro) | 0.54 |
| *AUC* | 0.92 |

Hasil yang didapatkan dari *training* yaitu model *ResNet-18 baseline* dengan citra 28x28 piksel menghasilkan akurasi sebesar 0.75. Pada *precision* makro mendapatkan 0.62 menunjukkan model memprediksi suatu kelas yang benar sesuai dengan labelnya sebesar 62%, dan sisanya merupakan *false positive*. Berdasarkan nilai *precision* yang didapatkan bahwa model masih sering melakukan kesalahan dalam prediksi. Untuk *recall* makro mendapatkan 0.50 menunjukkan model mampu mendeteksi seluruh sampel yang seharusnya masuk dalam masing-masing kelas adalah 50%. Dengan kata lain, model hanya mampu mengenali setengah dari total data yang benar-benar termasuk dalam suatu kelas. Nilai *recall* yang rendah dapat didefinisikan bahwa model masih kurang optimal mendeteksi seluruh data pada masing-masing kelasnya. Meskipun demikian, nilai *AUC* mendapatkan 0.92 yang mana model dapat memisahkan kelas dengan baik.

Tabel 4.8 Hasil Evaluasi *ResNet-18 Baseline* dengan Citra 224×224 Piksel

| **Metrik Evaluasi** | **Nilai** |
|---|---|
| *Accuracy* | 0.78 |
| *Precision* (Macro) | 0.66 |
| *Recall* (Macro) | 0.53 |
| *F1-Score* (Macro) | 0.56 |
| *AUC* | 0.93 |

Berdasarkan Tabel 4.8, nilai akurasi berada pada angka 0.78. Untuk *precision* makro mendapatkan 0.66 yang menandakan rata-rata model dalam memprediksi di setiap kelasnya cukup baik. Dilain sisi, model masih belum cukup baik untuk prediksi data yang benar dari keseluruhan data di kelasnya masing-masing, dilihat dari nilai *recall* makro sebesar 0.53. Dikarenakan kedua nilai *precision* makro dan *recall* makro yang belum cukup baik, mengakibatkan nilai rata-rata harmonik yaitu *f1-score* makro mendapatkan nilai 0.56. Meskipun demikian, model mampu untuk membedakan antar kelasnya dilihat dari nilai *AUC* sebesar 0.93.

#### 4.2.1.2 Model *ResNet-50 Baseline*

Model *ResNet-50 baseline* di-*training* dengan dua ukuran citra. Pada *training* dengan ukuran citra 28x28 piksel, model dibangun dari awal (*scratch*), sementara untuk ukuran citra 224x224 piksel, model memanfaatkan model yang sudah disediakan oleh *torchvision*. Untuk hasil evaluasi dari masing-masing ukuran citra ditampilkan pada Tabel 4.9 untuk citra 28x28 piksel dan Tabel 4.10 untuk citra 224x224 piksel.

Tabel 4.9 Hasil Evaluasi *ResNet-50 Baseline* dengan Citra 28×28 Piksel

| **Metrik Evaluasi** | **Nilai** |
|---|---|
| *Accuracy* | 0.74 |
| *Precision* (Macro) | 0.65 |
| *Recall* (Macro) | 0.45 |
| *F1-Score* (Macro) | 0.48 |
| *AUC* | 0.91 |

Berdasarkan Tabel 4.9, Model mendapatkan akurasi sebesar 0.74. Untuk *precision* makro mendapatkan 0.65 yang menandakan rata-rata model dalam memprediksi di setiap kelasnya cukup baik. Tetapi *precision* makro cukup buruk yang mana nilainya adalah 0.45. Nilai tersebut menandakan model masih sering salah memprediksi yang benar dari keseluruhan data pada kelas nya masing-masing. Dikarenakan salah satu dari komponen untuk *f1-score* memiliki nilai yang rendah dan nilai antara keduanya cukup jauh, membuat nilai *f1-score* makro mendapatkan nilai 0.48 yang menunjukkan bahwa model memiliki performa yang kurang baik. Meskipun demikian, model masih mampu untuk membedakan antar kelasnya dilihat dari nilai *AUC* sebesar 0.91.

Tabel 4.10 Hasil Evaluasi *ResNet-50 Baseline* dengan Citra 224×224 Piksel

| **Metrik Evaluasi** | **Nilai** |
|---|---|
| *Accuracy* | 0.76 |
| *Precision* (Macro) | 0.55 |
| *Recall* (Macro) | 0.49 |
| *F1-Score* (Macro) | 0.52 |
| *AUC* | 0.92 |

*ResNet-50* yang di-*training* dengan citra 224x224 piksel mendapatkan akurasi sebesar 0.76. Untuk *precision* makro dan *recall* makro mendapatkan nilai yang cukup rendah yaitu 0.55 dan 0.49. Nilai tersebut menandakan performa model masih rendah dalam mendeteksi keseluruhan data yang seharusnya termasuk ke dalam masing-masing kelas. Berdasarkan nilai *recall* makro, model

kurang baik dalam mendeteksi data pada tiap kelasnya. Didukung dengan nilai *f1-score* makro yang rendah yaitu 0.52, menandakan keseimbangan *precision* dan *recall* yang masih rendah. Nilai *AUC* yaitu 0.92 menunjukkan model masih mampu untuk membedakan antar kelasnya dengan baik. Dengan demikian, model ini masih belum optimal dan memerlukan peningkatan.

### 4.2.2 Perbandingan Model *Baseline* Dengan Model Sendiri

Kedua model *baseline* dan model sendiri terdapat perbedaan, walaupun model yang digunakan sama yaitu *ResNet-18* dan *ResNet-50*. Perbedaan berada pada model yang di-*train* untuk citra 28x28 dan model yang di-*train* untuk citra 224x224. Untuk model yang di-*train* dengan citra 28x28 menggunakan *scratch* dan untuk model yang di-*train* dengan citra 224x224 menggunakan model bukan *scratch* atau *pretrained*.

Dalam struktur model yang di-*training* dengan citra 28x28, terdapat sebuah perbedaan struktur pada model *baseline* dengan model sendiri. Perbedaan struktur dapat dilihat pada Kode 4.7.

Kode 4.7 Perbedaan Model *Scratch*

```
# Model Baseline (Scratch)
def forward(self, x):
    out = F.relu(self.bn1(self.conv1(x)))
    out = self.layer1(out)
    out = self.layer2(out)
    out = self.layer3(out)
    out = self.layer4(out)
    out = self.avgpool(out)
    out = out.view(out.size(0), -1)
    out = self.linear(out)
    return out

#-------------------------------------------------------------#

# Model Sendiri (Scratch)
def forward(self, x):
    out = F.relu(self.bn1(self.conv1(x)))
    out = self.layer1(out)
    out = self.layer2(out)
    out = self.layer3(out)
    out = self.layer4(out)
    out = self.avgpool(out)
    out = out.view(out.size(0), -1)
    out = self.dropout(out) # Dropout
    out = self.linear(out)
    return out
```

Pada *Baseline*, model tidak menggunakan *dropout* sehingga seluruh neuron

pada setiap layer berkontribusi penuh saat proses *training*. Berbeda dengan model sendiri yang menggunakan *dropout* yang diletakka sesudah *pooling* dan sebelum *fully connected*. *Dropout rate* yang digunakan pada model *scratch* yaitu 0.7, yang berarti 70% neuron akan dinonaktifkan secara acak pada setiap iterasi *training*. Perlu diingat bahwa model ini dilatih dari awal (*scratch*) dan memiliki dataset yang tidak seimbang, *Dropout rate* dibuat cukup ekstrim ini bertujuan untuk menekan risiko overfitting [37]. Selain itu, penggunaan dropout dengan nilai yang tinggi juga dapat mendorong model untuk mempelajari representasi fitur yang lebih robust, dengan berharap model tidak ketergantungan pada neuron tertentu saat *training* berlangsung.

Selanjutnya pada struktur model yang di-*training* dengan citra 224x224, terdapat sebuah perbedaan struktur pada model *baseline* dengan model sendiri. Perbedaan struktur dapat dilihat pada Kode 4.8.

Kode 4.8 Perbedaan Model *Pretrained*

```
# Model Baseline (Pretrained)
if model_flag == 'resnet18':
    model =  resnet18(pretrained=False, num_classes=n_classes) if
     resize else ResNet18(in_channels=n_channels,
     num_classes=n_classes)
elif model_flag == 'resnet50':
    model =  resnet50(pretrained=False, num_classes=n_classes) if
     resize else ResNet50(in_channels=n_channels,
     num_classes=n_classes)
else:
    raise NotImplementedError

#-----------------------------------------------------------#

# Model Sendiri (Pretrained)
if model_flag == 'resnet18':
    model = resnet18(weights=ResNet18_Weights.IMAGENET1K_V1)
    num_ftrs = model.fc.in_features
    model.fc = nn.Sequential(
        nn.Dropout(p=dropout_prob),
        nn.Linear(num_ftrs, n_classes)
    )
else:
    model = resnet50(weights=ResNet50_Weights.IMAGENET1K_V1)
    num_ftrs = model.fc.in_features
    model.fc = nn.Sequential(
        nn.Dropout(p=dropout_prob),
        nn.Linear(num_ftrs, n_classes)
    )
```

Berdasarkan pada Kode 4.8, terdapat perbedaan saat melakukan *train* dengan citra 224x224. Pada model *baseline* kedua model yaitu *ResNet-18* dan

*ResNet-50* menggunakan model yang sudah disiapkan oleh *PyTorch* dengan memanggil pustaka *torchvision* dan pada *baseline* tidak menggunakan *pretrained* yang ditandai parameter *pretrained* yang bernilai *False*. Sedangkan untuk model sendiri, kedua model menggunakan *pretrained* dari ImageNet.

### 4.2.3 Penggunaan *Class Weight*

Pada penelitian ini, digunakannya *class weight* yang diletakkan pada *loss function* yaitu *cross-entropy loss*. Penggunaan dapat *class weight* dapat dilihat pada Kode 4.9.

Kode 4.9 Penggunaan *Class Weight*

```
counts = np.array([327, 514, 1099, 115, 1113, 6705, 142])
weights = 1.0 / counts
weights = weights / weights.sum() * n_classes
class_weights = torch.tensor(weights).float().to(device)

criterion = nn.CrossEntropyLoss(weight=class_weights)
```

Penggunaan *class weight* pada penelitian ini bertujuan untuk menangani *imbalanced data*. Berdasarkan pada Kode 4.9, menghitung nilai invers dari jumlah data pada masing-masing kelas untuk menentukan bobot yang berguna untuk memberikan penalti lebih besar saat model salah memprediksi pada kelas minoritas. Proses ini akan memberikan bobot tertinggi pada kelas dengan jumlah data nya paling sedikit sementara kelas yang memiliki jumlah data nya paling banyak mendapatkan bobot yang rendah. *Class weight* digunakan pada *loss function* yaitu *cross-entropy loss* supaya model dapat setara terhadap semua kelas.

### 4.2.4 Perbandingan Hasil *Baseline* Dengan Hasil Sendiri

Pada bagian ini dilakukan perbandingan hasil evaluasi dari *baseline* dengan hasil evaluasi dari model sendiri. Keduanya diuji menggunakan data uji sebanyak 2.005 data. Perbedaan berada pada augmentasi kelas minoritas yang dilakukan pada model sendiri, sedangkan pada *baseline* tidak dilakukan augmentasi pada data terutama pada kelas minoritas nya. Perbandingan hasil evaluasi dapat

dilihat pada Tabel 4.11.

Tabel 4.11 Perbandingan Hasil *Baseline* dan Model Sendiri

| | **Accuracy** | **Precision** | **Recall** | **F1-Score** | **AUC** |
|---|---|---|---|---|---|
| **Augmentasi Minoritas** | | | | | |
| ResNet-18 (28) | 0.60 | 0.44 | 0.62 | 0.45 | 0.91 |
| Resnet-50 (28) | 0.62 | 0.41 | 0.59 | 0.45 | 0.89 |
| Resnet-18 (224) | **0.80** | **0.71** | **0.76** | **0.73** | **0.95** |
| Resnet-50 (224) | 0.74 | 0.69 | 0.74 | 0.70 | **0.95** |
| **Tanpa Augmentasi Minoritas** | | | | | |
| ResNet-18 (28) | 0.75 | 0.62 | 0.50 | 0.54 | 0.92 |
| Resnet-50 (28) | 0.74 | 0.65 | 0.45 | 0.48 | 0.91 |
| Resnet-18 (224) | 0.78 | 0.66 | 0.53 | 0.56 | 0.93 |
| Resnet-50 (224) | 0.76 | 0.55 | 0.49 | 0.52 | 0.92 |

Berdasarkan pada Tabel 4.11 terkait perbandingan hasil evaluasi antara model *baseline* yang tanpa augmentasi minoriotas dengan model sendiri yang menggunakan augmentasi minoritas, hasil *ResNet-18* dengan citra 224x224 yang dilakukannya augmentasi pada kelas minoritas lebih unggul secara keseluruhan. Berdasarkan hal tersebut bahwa *ResNet-18* dengan citra 224x224 yang dilakukannya augmentasi kelas minoritas menunjukkan lebih baik dalam mengenali pola data, dapat menjaga keseimbangan ketepatan saat memprediksi (*precision*) dan mampu deteksi data yang benar dari keseluruhan data pada kelas nya masing-masing (*recall*). Sementara untuk model *ResNet-18* dengan citra 224x224 yang tidak melakukan augmentasi minoritas memiliki hasil yang rendah yang membuat model tersebut masih salah dalam mendeteksi data yang benar dari keseluruhan data pada kelas nya masing-masing berdasarkan nilai *recall*-nya yang berada pada angka 0.53. Selain hasil *ResNet-18* dengan citra 224x224 augmentasi minorits yang unggul, model dapat mengurangi risiko overfitting yang mana grafik *val loss* yang menurun seiring berjalanya proses *training* walaupun terdapat lonjakan dibeberapa epoch dibandingkan *ResNet-18* 224x224 tanpa melakukan augmentasi minoritas yang masih *overfitting* yang

ditandai *val loss* yang tidak menurun sampai akhir proses *training*. Untuk grafik *loss Resnet-18* 224x224 augmentasi minoritas dapat dilihat pada Gambar 4.6 dan grafik los *Resnet-18* 224x224 tanpa augmentasi minoritas (*baseline*) dapat dilihat pada Gambar 4.7.

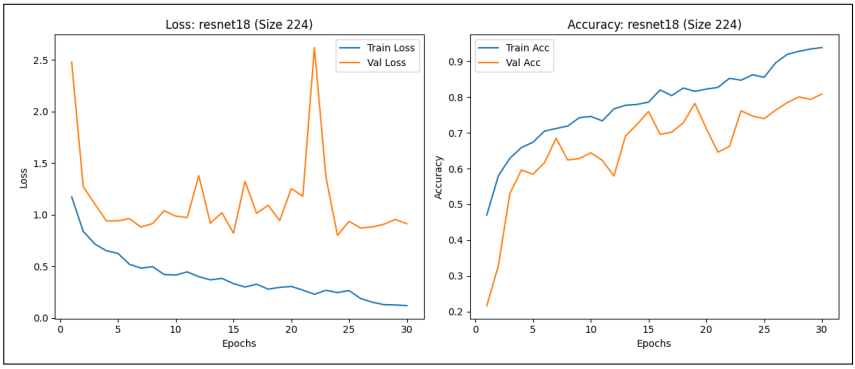


Gambar 4.6 Grafik Loss Resnet-18 224x224 Augmentasi Minoritas

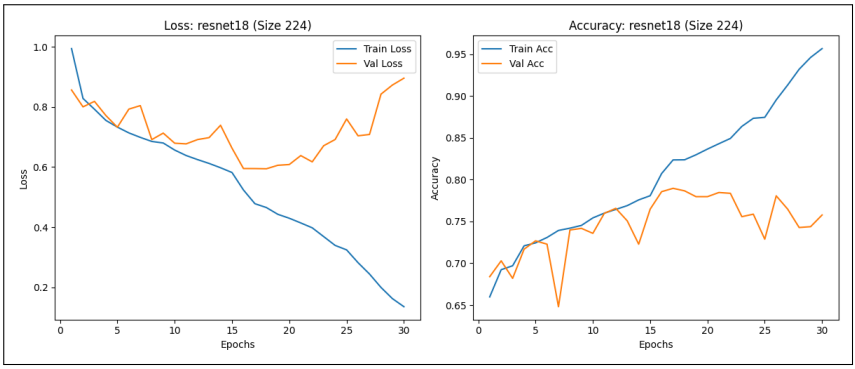


Gambar 4.7 Grafik Loss Resnet-18 224x224 Tanpa Augmentasi Minoritas

Untuk model *ResNet-18* dengan citra 28x28 yang dilakukan augmentasi minoritas, hasil evaluasi model masih belum melebihi model *baseline* yang tidak melakukan augmentasi minoritas. Dari segi akurasi, model *ResNet-18* dengan augmentasi minoritas hanya mendapatkan akurasi sebesar 0.60 yang mana lebih rendah dibandingkan model *baseline* yang mendapatkan akurasi sebesar

0.75. Nilai *precision* makro pun hanya mendapatkan 0.44 berbanding jauh dengan model *baseline* yang mendapatkan *precision* 0.62. Dikarenakan nilai *precision* yang rendah pada model *ResNet-18* augmentasi minoritas, membuat nilai *f1-score* mendapatkan nilai yang rendah yaitu 0.45. Meskipun pada model *baseline*, nilai *f1-score* nya mendapatkan 0.54 yang mana masih belum cukup baik tetapi dibandingkan dengan *ResNet-18* dengan augmentasi minortias, nilai *f1-score* pada model *baseline* lebih baik. Disisi lain, dapat dilihat pada *loss* yang didapatkan pada kedua model. Grafik *loss* pada *ResNet-18* yang dilakukannya augmentasi minoritas menunjukkan rendah nya risiko *overfitting* yang mana grafik pada *val loss* menurun seiring proses *training* dibandingkan dengan grafik *loss* pada model *baseline* yang tidak menurun seiring proses *training*. Untuk grafik *loss Resnet-18* 28x28 augmentasi minoritas dapat dilihat pada Gambar 4.8 dan grafik *loss Resnet-18* 28x28 tanpa augmentasi minoritas (*baseline*) dapat dilihat pada Gambar 4.9.

Gambar 4.8 Grafik Loss Resnet-18 28x28 Augmentasi Minoritas

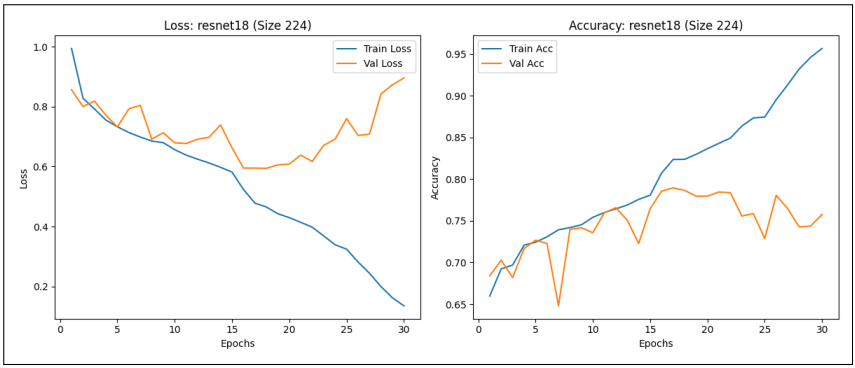


Gambar 4.9 Grafik Loss Resnet-18 28x28 Tanpa Augmentasi Minoritas

Model selanjutnya yaitu *ResNet-50* dengan citra 28x28 yang di-*training* dengan citra 28x28. Pada model *ResNet-50* yang dilakukan augmentasi minoritas mendapatkan akurasi 0.62 yang mana akurasi tersebut masih rendah dibandingkan dengan model *baseline* yang mendapatkan akurasi sebesar 0.74. Secara keseluruhan hasil, *ResNet-50* masih di bawah model *baseline* yang tidak melakukan augmentasi minoritas. Nilai *precision* pada model *ResNet-50* dengan augmentasi minoritas mendapatkan nilai 0.41 yang mana nilai tersebut masih rendah dibandingkan dengan model *baseline* yang mendapatkan nilai *precision* sebesar 0.65. Walaupun nilai *recall* pada model yang melakukan augmentasi minoritas mendapatkan nilai 0.59 diatas model *baseline*. Meskipun demikian, untuk nilai *f1-score* pada kedua model tidak cukup baik yang mana model *ResNet-50* dengan augmentasi minoritas hanya mendapatkan nilai 0.45 dan model *baseline* mendapatkan nilai 0.48. Untuk *loss* pada kedua model, model *baseline* masih berisiko *overfitting* dilihat pada grafik *val loss* yang menaik dibandingkan grafik *val loss* pada model *ResNet-50* dengan augmentasi minoritas yang terlihat menurun. Gambar grafik *loss* dapat dilihat pada Gambar untuk *ResNet-50* dengan augmentasi minoritas dan Gambar untuk model *baseline*.

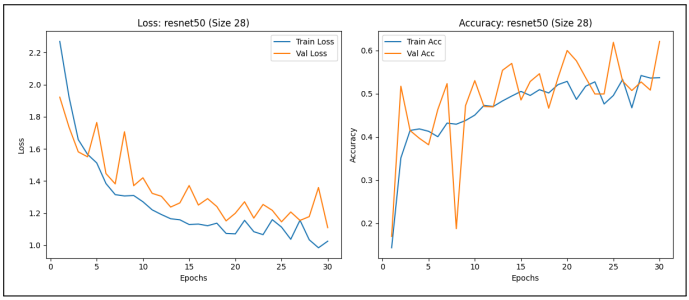


Gambar 4.10 Grafik Loss Resnet-50 28x28 Augmentasi Minoritas

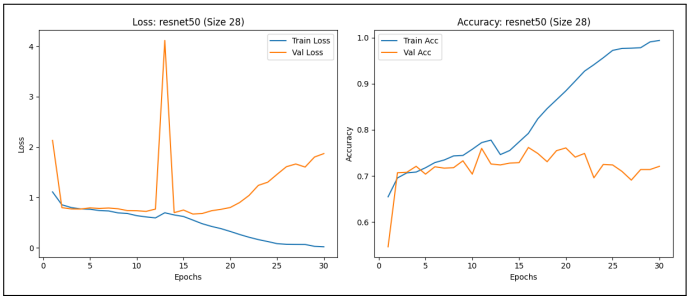


Gambar 4.11 Grafik Loss Resnet-50 28x28 Tanpa Augmentasi Minoritas

Kemudian terdapat model *ResNet-50* yang di-*training* menggunakan citra 224x224. Pada kedua model yaitu *ResNet-50* dengan augmentasi minoritas dengan model *baseline*, model *baseline* masih unggul dari akurasi yang mendapatkan 0.76 dibandingkan model *ResNet-50* dengan augmentasi minoritas yang mendapatkan akurasi 0.74. Tetapi untuk nilai *precision* dan *recall*, model *baseline* lebih rendah yang mana mendapatkan nilai 0.55 dan 0.49 dibandingkan model *ResNet-50* dengan augmentasi minoritas yang mendapatkan nilai *precision* 0.69 dan nilai *recall* 0.74. Kedua nilai tersebut menyebabkan nilai *f1-score* pada model *ResNet-50* dengan augmentasi minoritas mendapatkan nilai sebesar 0.70 lebih baik dibandingkan dengan model *baseline* yang nilai *f1-score*-nya 0.52. Dari sisi *loss*, model *ResNet-50* dengan augmentasi minoritas masih rentan terhadap *overfitting* jika dilihat dari grafik *val loss* dari kedua model tidak

menurun selama proses *training* dibandingkan model *baseline* yang risiko nya rendah terhadap *overfitting*. Grafik *loss* dapat dilihat pada Gambar 4.12 dan Gambar 4.13.

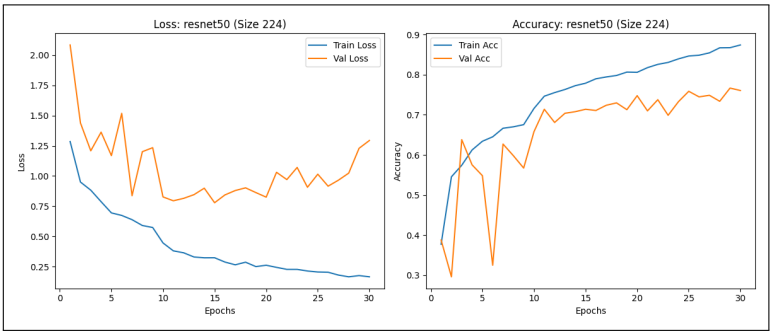


Gambar 4.12 Grafik Loss Resnet-50 224x224 Augmentasi Minoritas

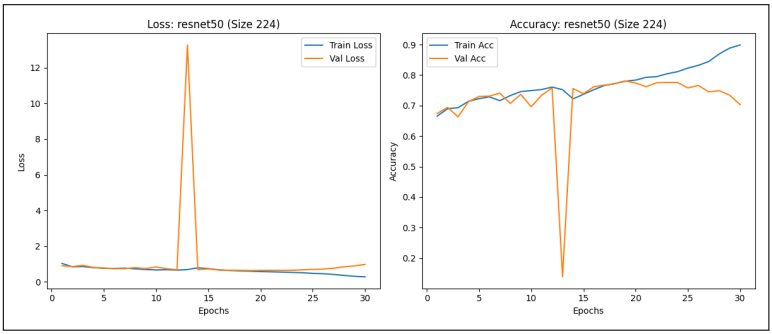


Gambar 4.13 Grafik Loss Resnet-50 224x224 Tanpa Augmentasi Minoritas

Berdasarkan perbandingan hasil diatas, bahwa penerapan augmentasi data pada kelas minoritas memberikan pengaruh terhadap performa model. Pengaruh tersebut dapat dilihat dari masing-masing metrik evaluasi antara model yang menerapkan augmentasi kelas minoritas dengan model yang tidak menerapkan augmentasi kelas minoritas (*baseline*).

===== REVISIAN PAK TANTO (NOMOR 2) =====

===== REVISIAN PAK TANTO (NOMOR 2) =====

===== REVISIAN PAK TANTO (NOMOR 3) =====

===== REVISIAN PAK TANTO (NOMOR 3) =====

# BAB V
# KESIMPULAN DAN SARAN

## 5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilaksanakan terhadap arsitektur *ResNet-18* dan *ResNet-50* dengan menerapkan augmentasi data kelas minoritas pada dataset DermaMNIST, dapat disimpulkan sebagai berikut.

1. Penerapan augmentasi data yang ditujukan khusus untuk kelas minoritas memberikan dampak terhadap kedua performa model yaitu *ResNet-18* dan *ResNet-50* dalam mengklasifikasikan data pada dataset DermaMNIST. Kemampuan model meningkat dalam mempelajari kelas minoritas karena didukung augmentasi sehingga proses pembelajaran menjadi seimbang. Hal ini dapat dilihat dari hasil evaluasi pada model sendiri.
2. Hasil menunjukkan performa yang berbeda terhadap *ResNet-18* dan *ResNet-50* setelah melakukan proses *training* pada dataset DermaMNIST yang kelas minoritasnya sudah diterapkan augmentasi data. Dari 4 skema yang telah dilakukan, model *ResNet-18* yang dilatih dengan citra 224x224 memiliki hasil yang lebih baik. Model *ResNet-18* dengan citra 224x224 mendapatkan akurasi sebesar 0.80 (80%), didukung dengan nilai *precision* yang mendapatkan nilai sebesar 0.71, nilai *recall* mendapatkan sebesar 0.76 dan nilai *f1-score* sebesar 0.73. Selain itu, model mampu dengan baik dalam memisahkan data dari masing-masing kelasnya yang dilihat dari nilai *AUC* sebesar 0.95. Nilai MCC yang berada pada nilai 0.64 menunjukkan model mampu mengklasifikasi dengan cukup baik dan tingkat korelasi positif yang kuat antara prediksi dan aktual, serta model sudah tidak bergantung lagi denga kelas mayoritas.

## 5.2 Saran

Berdasarkan penelitian yang telah dilakukan terhadap arsitektur *ResNet-18* dan *ResNet-50* dengan menerapkan augmentasi data kelas minoritas pada dataset DermaMNIST, terdapat beberapa saran untuk penelitian selanjutnya antara lain.

1. Dapat membuang atau dilakukannya *undersampling* pada kelas mayoritas yang ekstrim dengan tujuan saat melakukan *oversampling* seperti augmentasi data pada kelas minoritas tidak agresif.
2. Menggunakan teknik augmentasi data lainnya seperti *geometric transformations* yang meliputi *shear* atau *perspective transformation*. Dapat juga menggunakan teknik yang *advanced* seperti augmentasi berbasis AI yang menggunakan GANs (*Generative Adversarial Networks*) atau *Difussion Models* untuk menghasil data gambar sintesis baru.
3. Menggunakan arsitektur *CNN Based* yang lebih modern seperti *EfficientNet*, *Inception Network*, jika model ingin dimasukkan ke dalam sebuah sistem dapat menggunakan *MobileNet* yang ringan dan cepat. Dapat juga menggunakan arsitektur *Transformer Based* khusus citra seperti *Swin Transformer* atau *Vision Transformer* (ViT).

# DAFTAR PUSTAKA


[1] Margaret Chustecki. "Benefits and Risks of AI in Health Care: Narrative Review". *Interact J Med Res* 13 (2024), e53616. 1929-073X.

[2] Na Kyung Lee and Jong Seung Kim. "Status and trends of the digital healthcare industry". *Healthcare Informatics Research* 30.3 (2024), pp. 172–183.

[3] Irohito Nozomi, Febri Aldi, and Rio Bayu Sentosa. "Views on Deep Learning for Medical Image Diagnosis". *Journal of Applied Engineering and Technological Science (JAETS)* 4.1 (2022), pp. 547–553.

[4] Mengfang Li et al. "Medical image analysis using deep learning algorithms". *Frontiers in public health* 11 (2023), p. 1273253.

[5] Lanting He, Lan Luan, and Dan Hu. "Deep learning-based image classification for AI-assisted integration of pathology and radiology in medical imaging". *Frontiers in Medicine* 12 (2025), p. 1574514.

[6] Nurkhasanah Nurkhasanah and Murinto Murinto. "Klasifikasi penyakit kulit wajah menggunakan metode convolutional neural network". *Sainteks* 18.2 (2021), pp. 183–190.

[7] Nadia Ifti Khani and Sindhu Rakasiwi. "Penerapan Convolutional Neural Network dengan ResNet-50 untuk Klasifikasi Penyakit Kulit Wajah Efektif". *Edumatic: Jurnal Pendidikan Informatika* 9.1 (2025), pp. 217–225.

[8] Alifia Revan Prananda et al. "Klasifikasikan Jenis Cacat Kulit Menggunakan SMOTE-GoogLeNet". *JITU: Journal Informatic Technology And Communication* 8.1 (2024), pp. 21–30.

[9] CHALIFA CHAZAR et al. "Pendekatan Augmentasi Citra Fundus pada Model EfficientNet untuk Klasifikasi Tingkat Keparahan Retinopati

Diabetik dengan Dataset Tidak Seimbang". *MIND (Multimedia Artificial Intelligent Networking Database) Journal* 10.2 (2025), pp. 180–194.

[10] Tasya Berliani, Enggalwiguno Rahardja, and Lina Septiana. "Perbandingan Kemampuan Klasifikasi Citra X-ray Paru-paru menggunakan Transfer Learning ResNet-50 dan VGG-16". *Journal of Medicine and Health* 5.2 (2023), pp. 123–135.

[11] Ade Maulani Bilgis, Nurhadi Surojudin, and Ahmad Fauzi. "Penerapan Deep Learning Berbasis DenseNet Untuk Deteksi Diabetic Retinopathy Pada Citra Fundus Mata". *CESS (Journal of Computer Engineering, System and Science)* 10.2 (2025), pp. 380–388.

[12] Nerma Kadric, Amila Akagic, and Medina Kapo. *Improving Diagnostic Accuracy of Pigmented Skin Lesions With CNNs: an Application on the DermaMNIST Dataset*. 2025. arXiv: 2507.12961 [eess.IV].

[13] Micheila Jiemesha and Daniel Martomanggolo Wonohadidjojo. "Classification of Skin Diseases Using Transfer Learning with ResNet-50 Architecture and Data Preprocessing Using Real-ESRGAN and Wiener Filter". *INSYST: Journal of Intelligent System and Computation* 7.1 (2025), pp. 01–10.

[14] Sofia Biju Francis and Jai Prakash Verma. "Deep CNN ResNet-18 based model with attention and transfer learning for Alzheimer's disease detection". *Frontiers in Neuroinformatics* 18 (2025), p. 1507217.

[15] 1st Lt Pushkar Aggarwal. "Data augmentation in dermatology image recognition using machine learning". *Skin Research and Technology* 25.6 (2019), pp. 815–820.

[16] Ian Mateos Gonzalez et al. *Lightweight Deep Models for Dermatological Disease Detection: A Study on Instance Selection and Channel Optimization*. 2025. arXiv: 2504.01208 [eess.IV].

[17] Arindam Halder et al. “A fuzzy rank-based deep ensemble methodology for multi-class skin cancer classification”. *Scientific Reports* 15.1 (2025), p. 6268.

[18] Gogor Putra Hafi Puja Gusti et al. “Implementasi Algoritma Convolutional Neural Network (Resnet-50) untuk Klasifikasi Kanker Kulit Benign dan Malignant: Implementation of Convolutional Neural Network Algorithm (ResNet-50) for Benign and Malignant Skin Cancer Classification”. *MALCOM: Indonesian Journal of Machine Learning and Computer Science* 4.3 (2024), pp. 984–992.

[19] X XuRonald et al. “A low-cost high-performance data augmentation for deep learning-based skin lesion classification”. *BME frontiers* (2022).

[20] Jiancheng Yang et al. “MedMNIST v2 - A large-scale lightweight benchmark for 2D and 3D biomedical image classification”. *Scientific Data* 10.1 (Jan. 2023). 2052-4463.

[21] Clay J. Cockerell. “Histopathology of incipient intraepidermal squamous cell carcinoma (“actinic keratosis”)”. *Journal of the American Academy of Dermatology* 42.1, Part 2 (2000), S11–S17. 0190-9622.

[22] Nicole Basset-Seguin and Florian Herms. “Update on the management of basal cell carcinoma”. *Acta dermato-venereologica* 100.11 (2020), p. 5750.

[23] Philipp Tschandl, Cliff Rosendahl, and Harald Kittler. “The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions”. *Scientific data* 5.1 (2018), pp. 1–9.

[24] Haibo He and Edwardo A. Garcia. “Learning from Imbalanced Data”. *IEEE Transactions on Knowledge and Data Engineering* 21.9 (2009), pp. 1263–1284.

[25] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. http://www.deeplearningbook.org. MIT Press, 2016.

[26] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. “ImageNet Classification with Deep Convolutional Neural Networks”. *Advances in Neural Information Processing Systems*. Ed. by F. Pereira et al. Vol. 25. Curran Associates, Inc., 2012.

[27] Richard Szeliski. *Computer vision: algorithms and applications*. Springer Nature, 2022.

[28] Zhun Zhong et al. “Random Erasing Data Augmentation”. *Proceedings of the AAAI Conference on Artificial Intelligence* 34.07 (2020), pp. 13001–13008.

[29] Ekin D. Cubuk et al. *RandAugment: Practical automated data augmentation with a reduced search space*. 2019. arXiv: 1909.13719 [cs.CV].

[30] Aston Zhang et al. *Dive into Deep Learning*. https://D2L.ai. Cambridge University Press, 2023.

[31] Y. Lecun et al. “Gradient-based learning applied to document recognition”. *Proceedings of the IEEE* 86.11 (1998), pp. 2278–2324.

[32] Kaiming He et al. *Deep Residual Learning for Image Recognition*. 2015. arXiv: 1512.03385 [cs.CV].

[33] Nurul Khasanah et al. “Skin cancer classification using random forest algorithm”. *Sisfotenika* 11.2 (2021), pp. 137–147.

[34] Davide Chicco and Giuseppe Jurman. “The Matthews correlation coefficient (MCC) should replace the ROC AUC as the standard metric for assessing binary classification”. *BioData Mining* 16.1 (2023), p. 4.

[35] Kiran Maharana, Surajit Mondal, and Bhushankumar Nemade. “A review: Data pre-processing and data augmentation techniques”. *Global Transitions Proceedings* 3.1 (2022). International Conference on Intelligent Engineering Approach(ICIEA-2022), pp. 91–99. 2666-285X.

[36] S Febrian Tumewu, DH Setiabud, and Indar Sugiarto. “Klasifikasi Motif Batik menggunakan metode Deep Convolutional Neural Network dengan Data Augmentation”. *Jurnal Infra* 8.2 (2020), pp. 189–194.

[37] Nitish Srivastava et al. “Dropout: a simple way to prevent neural networks from overfitting”. *The journal of machine learning research* 15.1 (2014), pp. 1929–1958.

# LAMPIRAN

**A Dataset**

**B Hasil Wawancara**

**C Rincian Kasus Uji**