

**ANALISIS PERFORMA RESNET-18 DAN RESNET-50 DENGAN
PENERAPAN AUGMENTASI DATA KELAS MINORITAS PADA
DATASET DERMAMNIST**

TUGAS AKHIR

Diajukan sebagai syarat menyelesaikan jenjang strata Satu (S-1) di
Program Studi Teknik Informatika, Fakultas Teknologi Industri, Institut
Teknologi Sumatera

Oleh:

Arkan Hariz Chandrawinata Liem

122140038



**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
LAMPUNG SELATAN
2025**

DAFTAR ISI

DAFTAR ISI	ii
DAFTAR TABEL	iv
DAFTAR GAMBAR	v
DAFTAR RUMUS	vi
DAFTAR KODE	vii
BABI PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	4
1.4 Batasan Masalah	4
1.5 Manfaat Penelitian	5
1.6 Sistematika Penulisan	5
BAB II TINJAUAN PUSTAKA	7
2.1 Tinjauan Pustaka	7
2.2 Dasar Teori	12
2.2.1 DermaMNIST	12
2.2.1.1 Actinic Keratosis and Intraepithelial Carcinoma	13
2.2.1.2 Basal Cell Carcinoma	13
2.2.1.3 Benign Keratosis-Like Lesions	13
2.2.1.4 Dermatofibroma	14
2.2.1.5 Melanoma	14
2.2.1.6 Melanocytic Nevi	14
2.2.1.7 Vascular Lesions	14
2.2.2 Imbalanced Data	14

2.2.3	Data Augmentasi	15
2.2.3.1	Rotasi	15
2.2.3.2	Flip	16
2.2.3.3	Random Erasing	16
2.2.4	Convolutional Neural Network	16
2.2.5	Residual Network	18
2.2.5.1	Residual Learning	21
2.2.5.2	Shortcut Connections	22
2.2.6	Confusion Matrix	22
2.2.7	Matthews Correlation Coefficient	24
BAB III	METODE PENELITIAN	26
3.1	Alur Penelitian	26
3.2	Penjabaran Langkah Penelitian	26
3.2.1	Identifikasi Masalah	26
3.2.2	Studi Literatur	27
3.2.3	Akuisisi Dataset	27
3.2.4	Preprocessing Data	28
3.2.5	Augmentasi Kelas Minoritas	28
3.2.6	Perancangan Model ResNet-18 dan ResNet-50	29
3.2.7	Evaluasi	29
3.3	Alat dan Bahan Tugas Akhir	29
3.3.1	Alat	29
3.3.2	Bahan	30
3.4	Metode Pengembangan	30
3.5	Ilustrasi Perhitungan Metode	30
3.5.1	Ilustrasi Perhitungan Konvolusi	31
3.5.2	Ilustrasi Perhitungan Fungsi Aktivasi ReLU	34
3.5.3	Max Pooling dan Average Pooling	34

3.6 Rancangan Pengujian 35

3.6.1 Pengukuran *Confusion Matrix* 36

3.6.2 Perhitungan Macro Average 39

3.6.3 Perhitungan Matthews Correlation Coefficient 40

DAFTAR PUSTAKA 43

DAFTAR TABEL

Tabel 2.1	Tabel Studi Literatur	10
Tabel 2.2	Struktur ResNet-18	19
Tabel 2.3	Struktur ResNet-50	20
Tabel 3.1	Contoh Hasil Confusion Matrix	36
Tabel 3.2	Hasil Perhitungan Metrik Evaluasi per Kelas	39

DAFTAR GAMBAR

Gambar 2.1	Ilustrasi Convolutional Neural Network	17
Gambar 2.2	Gambaran ResNet-34 dan CNN 34 <i>layer</i> tanpa residual learning	19
Gambar 2.3	Ilustrasi Confusion Matrix Multi-Kelas	23
Gambar 3.1	Diagram Alur Penelitian	26
Gambar 3.2	Matriks Input Gambar 7x7	31
Gambar 3.3	Matriks Kernel 7x7	32
Gambar 3.4	Contoh Hasil Konvolusi	32
Gambar 3.5	Contoh Hasil Konvolusi	33
Gambar 3.6	Hasil Akhir Proses Konvolusi	33
Gambar 3.7	Visualisasi Fungsi Aktivasi ReLU	34
Gambar 3.8	Visualisasi Perhitungan Max Pooling	35
Gambar 3.9	Visualisasi Perhitungan Average Pooling	35

DAFTAR RUMUS

Rumus 2.1	Rumus Accuracy	23
Rumus 2.2	Rumus Precision	24
Rumus 2.3	Rumus Recall	24
Rumus 2.4	Rumus F1-Score	24
Rumus 2.5	Rumus Matthews Correlation Coefficient	25

DAFTAR KODE

BAB I

PENDAHULUAN

1.1 Latar Belakang

Bidang kesehatan kini sudah memperlihatkan penggunaan tren teknologi seperti *artificial intelligence* (AI) dalam kegiatan medis. Pemanfaatan AI dalam bidang kesehatan banyak digunakan untuk meningkatkan akurasi diagnosis, personalisasi pengobatan, serta membuat proses administrasi di rumah sakit menjadi efisien [1]. Kemajuan teknologi kesehatan digital telah mendorong transformasi sistem pelayanan medis menuju pendekatan yang lebih terintegrasi dan berbasis informasi. Meski demikian, aspek keselamatan data pribadi tetap menjadi fokus utamanya [2]. Melalui transformasi tersebut, diharapkan terjadi perluasan akses masyarakat terhadap pelayanan kesehatan yang berkualitas dan terjangkau.

Salah satu implementasi *artificial intelligence* yang menonjol dalam bidang kesehatan adalah pada pengolahan citra medis. Kontribusi teknologi kecerdasan buatan dalam sektor kesehatan mengalami perkembangan signifikan, khususnya pada citra medis dan klasifikasi penyakit. Dengan menggunakan *deep learning* seperti *Convolutional Neural Network* (CNN) menunjukkan performa yang sangat baik dalam mengidentifikasi dan mengelompokkan berbagai penyakit dari citra medis seperti fundus mata, radiologi, dan hasil pemindaian lainnya. Pendekatan ini memungkinkan ekstraksi fitur penting secara otomatis, sehingga mempercepat proses diagnosis dan memperkecil risiko kesalahan manusia dalam interpretasi gambar medis [3]. Hasil penelitian dari berbagai studi literatur mengindikasikan bahwa teknologi kecerdasan buatan berkontribusi dalam meningkatkan akurasi deteksi penyakit serta menyediakan alternatif otomatisasi untuk analisis citra medis yang sebelumnya sangat bergantung pada keahlian manual [4]. Selain itu, pengembangan framework inovatif berbasis

deep learning berperan besar dalam mengintegrasikan patologi dan radiologi, sehingga menghasilkan klasifikasi penyakit yang lebih presisi dan transparan [5]. Teknologi kecerdasan buatan dengan tingkat presisi yang menyamai atau bahkan mengungguli kemampuan praktisi medis, berkontribusi dalam mengoptimalkan manajemen perawatan pasien melalui pendekatan yang lebih fokus.

Namun dalam penerapannya pada klasifikasi penyakit spesifik seperti penyakit kulit, muncul tantangan terkait data yang tidak seimbang. Klasifikasi penyakit kulit menggunakan citra medis memiliki salah satu tantangan yaitu data yang tidak seimbang atau *imbalanced data* antar kelas penyakit. Masalah ini menyebabkan model menghasilkan prediksi yang lebih akurat pada kelas mayoritas dibandingkan dengan kelas minoritas yang performanya lebih rendah [6]. Ketidakseimbangan data dapat memicu bias prediksi dan sensitivitas model akan berkurang terhadap penyakit minoritas, yang akhirnya menyebabkan risiko misdiagnosis pada kasus penting meningkat. Beberapa penelitian telah mengamati bahwa data yang tidak terdistribusi dengan seimbang, menyebabkan presisi dan recall akan rendah, seperti yang ditemukan pada penelitian klasifikasi penyakit kulit wajah dengan menggunakan ResNet-50 [7]. Salah satu dataset yang banyak digunakan dalam klasifikasi penyakit kulit adalah DermaMNIST, yang juga memiliki distribusi data yang tidak merata antar kelas. Dalam mengatasi masalah tersebut, teknik augmentasi data sering dimanfaatkan pada kelas minoritas supaya performa model meningkat [8].

Augmentasi pada kelas minoritas telah terbukti dalam meningkatkan performa model, yang merupakan salah satu solusi untuk mengatasi data yang tidak seimbang pada klasifikasi penyakit kulit berbasis citra medis, terutama dalam mendeteksi penyakit yang spesifik atau langka [9]. Dengan teknik augmentasi untuk menambahkan data, keberagaman dan jumlah data pada kelas minoritas akan meningkat sehingga model dapat lebih sensitif dan adil dalam melakukan prediksi. Arsitektur yang digunakan untuk melakukan klasifikasi citra medis pada penelitian ini adalah ResNet-18 dan Resnet-50. Arsitektur

ResNet-50 dan ResNet-18 menerapkan konsep *residual learning* melalui *skip connections* untuk mengatasi masalah *vanishing* dan *exploding gradient*, di mana ResNet-50 memfasilitasi aliran informasi pada jaringan dalam, sedangkan ResNet-18 dibangun dengan struktur spesifik yang terdiri dari 17 lapisan konvolusi, max pooling 3×3 , serta lapisan fully connected dengan fungsi aktivasi ReLU [10] [11]. Performa model dievaluasi menggunakan Matthews Correlation Coefficient (MCC) untuk memastikan penilaian yang adil, terutama pada kasus dengan ukuran kelas data yang tidak seimbang [12]. Selain itu, evaluasi performa juga dilengkapi dengan penggunaan *confusion matrix* yang meliputi akurasi, *precision*, *recall*, dan *f1-score*. Hasil evaluasi dari masing-masing arsitektur yaitu ResNet-18 dan ResNet-50 akan dibandingkan untuk menentukan arsitektur yang memberikan performa terbaik dalam klasifikasi citra medis sesudah melakukan augmentasi data.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana menerapkan teknik augmentasi data yang ditujukan hanya pada kelas minoritas untuk meningkatkan performa model klasifikasi citra penyakit kulit berbasis dataset DermaMNIST yang tidak seimbang ?
2. Bagaimana performa arsitektur ResNet-18 dan ResNet-50 dalam mengklasifikasikan citra penyakit kulit setelah diterapkan augmentasi khusus pada kelas minoritas dibandingkan tanpa augmentasi ?
3. Bagaimana metrik evaluasi seperti akurasi, *precision*, *recall*, dan *F1-score* serta pengukuran MCC dalam mengukur performa model pada data klasifikasi penyakit kulit yang tidak seimbang ?

1.3 Tujuan Penelitian

Penelitian ini bertujuan untuk mengatasi permasalahan ketidakseimbangan data pada klasifikasi citra penyakit kulit dengan menerapkan pendekatan augmentasi pada kelas minoritas. Secara khusus, tujuan dari penelitian ini adalah sebagai berikut:

1. Menerapkan teknik augmentasi data yang ditujukan khusus pada kelas minoritas dalam dataset DermaMNIST untuk mengatasi ketidakseimbangan data dan meningkatkan keberagaman citra penyakit kulit.
2. Mengukur performa arsitektur ResNet-18 dan ResNet-50 dalam klasifikasi citra penyakit kulit sebelum dan sesudah penerapan augmentasi pada kelas minoritas, untuk mengetahui efektivitas strategi augmentasi terhadap akurasi dan keadilan prediksi antar kelas.
3. Mengevaluasi performa model dengan menggunakan metrik akurasi, *precision*, *recall*, dan *F1-score* serta pengukuran MCC sebagai evaluasi yang tepat dalam konteks data yang tidak seimbang.

1.4 Batasan Masalah

Supaya ruang lingkup penelitian ini lebih terarah dan realistis untuk diselesaikan dalam waktu yang telah ditentukan, maka penelitian ini dibatasi pada hal-hal berikut:

1. Penelitian hanya menggunakan dataset DermaMNIST, yang terdiri dari citra medis penyakit kulit dalam tujuh kelas dengan distribusi data yang tidak seimbang.
2. Teknik augmentasi citra hanya diterapkan pada kelas minoritas, tanpa melakukan augmentasi pada kelas mayoritas.
3. Arsitektur yang digunakan hanya ResNet-18 dan Resnet-50 untuk perbandingan performa.

1.5 Manfaat Penelitian

Penelitian diharapkan dapat memberikan manfaat baik bagi penulis sendiri maupun dunia akademik. Adapun manfaat dari penelitian sebagai berikut:

1. Memberikan solusi praktis dalam menangani ketidakseimbangan data pada klasifikasi citra penyakit kulit melalui teknik augmentasi khusus pada kelas minoritas.
2. Menyediakan perbandingan empiris performa arsitektur ResNet-18 dan ResNet-50 dalam klasifikasi citra medis dengan data tidak seimbang.
3. Berkontribusi pada pengembangan metode evaluasi model menggunakan metrik yang tepat untuk data tidak seimbang dalam konteks klasifikasi citra medis.

1.6 Sistematika Penulisan

Sistematika penulisan ini bertujuan untuk memberikan gambaran umum mengenai struktur dan isi dari laporan tugas akhir yang disusun. Penulisan dibagi ke dalam lima bab utama yang saling berkaitan dan disusun secara sistematis untuk memudahkan pembaca memahami alur penelitian dari awal hingga akhir.

Bab I

Pada Bab ini, berisi penjabaran mengenai latar belakang permasalahan yang menjadi dasar dilakukannya penelitian ini. Selain itu, bab ini juga memuat rumusan masalah, tujuan penelitian, manfaat penelitian, batasan masalah, serta sistematika penulisan.

Bab II

Bab ini memuat teori-teori dan konsep yang relevan dengan penelitian, seperti teori tentang klasifikasi citra, augmentasi data, ketidakseimbangan kelas, arsitektur *Convolutional Neural Network* (CNN), serta penjelasan mengenai dataset DermaMNIST dan penelitian terdahulu yang mendukung.

Bab III

Bab ini menjelaskan metode yang digunakan dalam penelitian, mulai dari tahapan pengolahan data, penerapan teknik augmentasi pada kelas minoritas, perancangan model ResNet-18, hingga proses pelatihan dan evaluasi model.

Bab IV

Bab ini menyajikan hasil eksperimen yang diperoleh, termasuk analisis performa model berdasarkan metrik evaluasi yang digunakan serta pembahasan terhadap pengaruh augmentasi kelas minoritas terhadap hasil klasifikasi.

Bab V

Bab ini berisi kesimpulan dari penelitian yang dilakukan berdasarkan hasil yang diperoleh serta memberikan saran untuk pengembangan atau penelitian selanjutnya.

BAB II

TINJAUAN PUSTAKA

2.1 Tinjauan Pustaka

Dalam penelitian ini, studi literatur dilakukan untuk meninjau riset terdahulu. Peningjauan ini berfungsi sebagai panduan utama bagi peneliti untuk mengantisipasi dan merumuskan pendekatan yang berbasis bukti dalam menghadapi permasalahan yang mungkin timbul. Berikut adalah beberapa penelitian terdahulu yang berkaitan dengan penelitian ini:

1. Penelitian sebelumnya oleh Nermi Kadric, Amila Akagic, dan Medina Kapo pada tahun 2025 dengan judul penelitian "*Improving Diagnostic Accuracy of Pigmented Skin Lesions With CNNs: A Case Study with DermaMNIST Dataset*" membahas terkait upaya untuk meningkatkan akurasi diagnostik lesi kulit berpigmen, yang merupakan indikator kondisi serius seperti melanoma. Penelitian ini juga menyoroti berbagai kelemahan pada dataset DermaMNIST orisinal, termasuk resolusi gambar yang rendah (28x28), ketidakseimbangan data, dan organisasi data yang buruk yang terbukti tidak memadai untuk klasifikasi yang andal. Terdapat perbandingan metode yang digunakan sebelumnya. Penelitian sebelumnya membandingkan model ResNet-50 dan EfficientNetV2L, serta menerapkan *transfer learning* pada dua versi dataset yaitu DermaMNIST orisinal dan DermaMNIST-C (versi perbaikan resolusi 224x224). Sedangkan penelitian yang akan dilakukan membandingkan model ResNet-18 dan ResNet-50 [13].
2. Penelitian sebelumnya oleh Ian Mateos Gonzales, Estefani Jaramilla Nava, Abraham Sánchez Morales, Jesús García Ramírez, dan Ricardo Ramos Aguilar pada tahun 2025 dengan judul penelitian "*Lightweight Deep Models for Dermatological Disease Detection: A Study on Instance*

Selection and Channel Optimization” membahas tentang pengembangan model deep learning yang ringan untuk deteksi penyakit dermatologis. Penelitian ini menggunakan dataset DermaMNIST yang terdiri dari 7 kelas yang berbeda. Penelitian ini meneliti dengan menggunakan data yang sedikit dengan cara seleksi instance menggunakan K-Means Clustering. Namun, penelitian yang akan dilakukan tidak mengurangi data melainkan menambahkan data pada kelas minoritas. Selain itu, penelitian akan dilakukan menggunakan arsitektur ResNet-18 dan ResNet-50 sedangkan penelitian sebelumnya menggunakan Lighweight Deep Models [14].

3. Penelitian yang dilakukan pada tahun 2022 oleh Shuwei Shen, Mengjuan Xu, Fan Zhang, Pengfei Shao, Honghong Liu, Liang Xu, dan Ronald X. Xu dengan judul *”A Low-Cost and High-Performance Data Augmentation for Deep-Learning-Based Skin Lesion Classification”* membahas tantangan dataset yang tidak seimbang dalam klasifikasi lesi kulit menggunakan arsitektur EfficientNet. Penelitian ini menerapkan strategi augmentasi otomatis (*Low-Cost-Augment*) yang teroptimasi untuk meningkatkan keseimbangan data dan performa klasifikasi pada dataset HAM10000. Meskipun arsitektur utama yang diuji berupa EfficientNet, hasil eksperimen menunjukkan bahwa augmentasi otomatis dapat meningkatkan *accuracy* tanpa memerlukan data eksternal. Namun, keterbatasannya adalah belum diuji pada arsitektur ResNet-18 dan ResNet-50 serta belum diaplikasikan pada dataset DermaMNIST [15].
4. Penelitian sebelumnya oleh Arindam Halder, Anogh Dalal, Sanghita Gharami, Marcin Wozniak, Muhammad Fajal Ijaz, dan Pawan Kumar Singh pada tahun 2025 dengan judul penelitian *”A fuzzy rank-based deep ensemble methodology for multi-class skin cancer classification”* membahas masalah klasifikasi kanker kulit multi-kelas dan tantangan *imbalanced dataset*. Penelitian ini menggunakan *deep ensemble* yang menggabungkan beberapa arsitektur, yaitu Xception, InceptionResNetV2,

dan MobileNetV2. Dalam mengatasi data yang tidak seimbang, penelitian sebelumnya menerapkan augmentasi data untuk menyeimbangkan dataset sebelum proses pelatihan. Dengan menerapkan augmentasi data membuktikan bahwa dapat berhasil meningkatkan performa. Penelitian sebelumnya relevan dengan penelitian yang akan dilakukan dengan adanya beberapa perbedaan. Penelitian yang akan dilakukan menerapkan augmentasi data pada kelas minoritas serta menggunakan ResNet-18 dan ResNet-50 untuk mengukur pengaruh augmentasi terhadap performa kedua model [16].

5. Penelitian yang dilakukan pada tahun 2024 oleh Gogor Putra, Elin Haerani, Fadhillah Syafria, Febi Yanto, dan Siska Kurnia Gusti dengan judul "Implementasi Algoritma *Convolutional Neural Network* (Resnet-50) untuk Klasifikasi Kanker Kulit Benign dan Malignant". Penelitian ini membahas tentang klasifikasi kanker kulit untuk membedakan antara lesi *Benign* dan *Malignant*, yang merupakan masalah klasifikasi biner. Penelitian ini melakukan implmentasi *transfer learning* menggunakan arsitektur ResNet-50 yang telah dilatih. Penelitian sebelumnya relevan karena menggunakan arsitektur yang sama yaitu ResNet-50. Terdapat perbedaan dengan penelitian yang akan dilakukan, yaitu menangani klasifikasi multi-kelas dengan masalah *imbalanced data*. Serta melakukan augmentasi data pada kelas minoritas [17].

Tabel 2.1 Tabel Studi Literatur

No.	Judul	Masalah	Metode	Hasil
1.	Nerma Kadric, Amila Akagic, Medina Kapo [2025] [Improving Diagnostic Accuracy of Pigmented Skin Lesions With CNNs: A Case Study with DermaMNIST Dataset]	Kelemahan dataset DermaMNIST yang memiliki resolusi gambar yang rendah (28 x 28), <i>imbalanced data</i> .	<i>Trasnfer learning</i> arsitektur ResNet-50 dan EfficientNetV2L dengan menggunakan dataset DermaMNIST orisinal dan DermaMNIST-C (resolusi 224 x 224).	Arsitektur EfficientNetV2L mencapai akurasi 84.90% pada dataset DermaMNIST-C.
2.	Ian Mateos Gonzales, Estefani Jaramilla Nava, Abraham Sánchez Morales, Jesús García Ramírez, Ricardo Ramos Aguilar [2025] [Lightweight Deep Models for Dermatological Disease Detection: A Study on Instance Selection and Channel Optimization]	Model <i>deep learning</i> yang ringan untuk deteksi penyakit dermatologis.	Menggunakan <i>Lightweight Deep Models</i> , melakukan <i>instance selection</i> menggunakan K-Means Clustering untuk mengurangi data pada kelas mayoritas.	Model dengan 472K parameter mencapai akurasi 71.57%, dengan komputasi yang lebih efisien yang sebanding dengan model ResNet.

No.	Judul	Masalah	Metode	Hasil
3.	Shuwei Shen, Mengjuan Xu, Fan Zhang, Pengfei Shao, Honghong Liu, Liang Xu, Chi Zang, Peng Liu, Peng Yao, Ronald X. Xu [2022] [A Low-Cost High-Performance Data Augmentation for Deep Learning-Based Skin Lesion Classification]	Data klasifikasi lesi kulit yang tidak seimbang.	Menggunakan arsitektur EfficientNet b2 serta menerapkan <i>Low Cost Augment</i> untuk augmentasi data.	Dengan menerapkan <i>Low Cost Augment</i> dan menggunakan arsitektur EfficientNet b2, hasil yang didapatkan dengan evaluasi BACC mencapai 0.853.
4.	Arindam Halder, Anogh Dalal, Sanghita Gharami, Marcin Wozniak, Muhammad Fazal Ijaz, Pawar Kuman Singh [2025] [A fuzzy rank-based deep ensemble methodology for multi-class skin cancer classification]	<i>Imbalanced data</i> pada klasifikasi kanker kulit multi-class.	<i>Fuzzy ensemble</i> dengan menggabungkan Xception, InceptionResNet V2, dan MobileNetV2. Menerapkan augmentasi data untuk menyeimbangkan dataset.	Model ensemble mencapai akurasi 95% pada dataset HAM10000 dan mencapai akurasi 73% dengan menguji model dengan dataset DermaMNIST.

No.	Judul	Masalah	Metode	Hasil
5.	Gogor Putra Hafi Puja Gusti, Elin Haerani, Fadhillah Syafria, Febi Yanto, Siska Kurnia Gusti [2024] [Implementasi Algoritma Convolutional Neural Network (ResNet-50) untuk Klasifikasi Kanker Kulit Benign dan Malignant]	Klasifikasi kanker kulit untuk membedakan antara Benign (jinak) dan Malignant (ganas), yang merupakan masalah klasifikasi biner.	Implementasi <i>transfer learning</i> menggunakan ResNet-50 yang <i>pre-trained</i> .	Dengan menggunakan ResNet-50 mencapai akurasi 90% dengan <i>loss</i> 13%.

2.2 Dasar Teori

Berikut ini adalah dasar teori atau penjelasan teori terkait yang akan digunakan dalam penelitian ini.

2.2.1 DermaMNIST

DermaMNIST adalah salah satu dari dataset yang ada di dalam koleksi MedMNIST. DermaMNIST berdasar pada HAM10000 yang merupakan kumpulan gambar dermatoskopik dari lesi kulit berpigmen yang memiliki *multi-class*. DermaMNIST memiliki 10.015 gambar yang diklasifikasikan ke dalam 7 kelas, yaitu *actinic keratosis and intraepithelial carcinoma*, *basal cell carcinoma*, *benign keratosis-like lesions*, *dermatofibroma*, *melanoma*, *melanocytic nevi*, *vascular lesions* [18].

2.2.1.1 Actinic Keratosis and Intraepithelial Carcinoma

Actinic Keratosis adalah sel kulit yang mengalami transformasi neoplastik diakibatkan paparan sinar UV. Pertumbuhan *Actinic Keratosis* masih berada di lapisan kulit luar. *Actinic Keratosis* atau disingkat "AK", memiliki hubungan dengan *Carcinoma*. AK adalah bentuk awal dari *Carcinoma*, ketika lesi ini menembus lapisan di bawah epidermis, maka AK berubah nama menjadi *Squamous Cell Carcinoma* (SCC). Penyakit ini jika tidak diobati, akan berpotensi untuk berkembang kemudian berkembang menyerang jaringan yang lebih dalam [19].

2.2.1.2 Basal Cell Carcinoma

Basal Cell Carcinoma atau "BCC" merupakan jenis kanker kulit yang umum terjadi, terutama pada orang dewasa berkulit cerah dan biasanya diawali pertumbuhan yang lambat dan risiko metastasis yang rendah. Faktor utama dari BCC adalah paparan sinar ultraviolet yang membuat lesi ini muncul paling sering di kulit yang terpapar sinar matahari. Adapun faktor lain penyebab BCC ini muncul, seperti kondisi immunosupresi (penurunan sistem imun) dan sindrom genetik tertentu seperti *Basal Cell Naevus Syndroeme* yang menyebabkan BCC muncul pada usia muda [20].

2.2.1.3 Benign Keratosis-Like Lesions

Benign Keratosis atau disingkat "BKL" bukan merupakan diagnosis penyakit kulit tunggal, melainkan kategori umum yang digunakan untuk mengklasifikasikan tiga jenis *benign lesions* yang berbeda. Tiga jenis adalah *seborrheic keratoses*, *solar lentigo*, dan *lichen planus-like keratoses*. Ketiga jenis tersebut digabungkan karena memiliki kemiripan secara biologis, meskipun secara dermatologis ketiga jenis tersebut dapat terlihat berbeda [21].

2.2.1.4 Dermatofibroma

Dermatofibroma atau disingkat "df" merupakan lesi kulit jinak yang dianggap sebagai proliferasi jinak atau reaksi peradangan akibat trauma ringan. Gambaran dermatoskopik paling umum dari lesi kulit ini adalah adanya garis-garis retikular di bagian tepi dengan disertai bercak putih di bagian tengah [21].

2.2.1.5 Melanoma

Melanoma atau disingkat "mel" merupakan kanker yang berasal dari sel melanosit dan dapat muncul dalam berbagai varian. Jika kanker ini diangkat pada stadium awal dengan operasi pengangkatan sederhana, maka kanker dapat disembuhkan [21].

2.2.1.6 Melanocytic Nevi

Melanocytic Nevi atau disingkat "nv" merupakan tumor jinak yang berasal dari sel melanosit, yang dapat muncul dalam berbagai varian. Dari *point of view* dermatoskopik, varian-varian tersebut bisa sangat berbeda satu sama lain [21].

2.2.1.7 Vascular Lesions

Vascular Lesions atau disingkat "vasc" meliputi berbagai jenis, mulai dari *cherry angiomas*, *angiokeratomas*, dan *pyogenic granulomas*. *Hemorrhage* juga termasuk dalam kategori ini. Secara gambaran dermatoskopik, *angioma* mempunyai ciri khas yaitu warna merah atau ungu dengan adanya struktur padat yang jelas, yang disebut dengan istilah "red clods" (gumpalan merah) atau *lacunes* (rongga kecil) [21].

2.2.2 Imbalanced Data

Data tidak seimbang (*imbalanced data*) secara teknis merujuk pada kumpulan data yang memperlihatkan distribusi data yang tidak merata antar kelas. Dalam pemahaman umum, istilah ini merujuk pada kumpulan data yang menunjukkan ketidakseimbangan yang signifikan atau bahkan ekstrem.

Ketidakseimbangan ini secara khusus dikenal sebagai ketidakseimbangan antar-kelas, di mana suatu kelas (kelas mayoritas) jauh lebih mendominasi kelas lainnya (kelas minoritas). Hal yang tidak aneh menemukan perbandingan ketidakseimbangan ini dalam rasio 100:1, 1000:1, atau bahkan 10000:1. Meskipun ketidakseimbangan data ini sering merujuk pada masalah biner, ketidakseimbangan juga dapat terjadi pada data *multi-class* [22].

2.2.3 Data Augmentasi

Kebutuhan data latih untuk melatih model *deep learning* seperti *Convolutional Neural Network* membutuhkan jumlah data yang besar. Jumlah data latih yang terbatas akan membuat model rentan terhadap *overfitting*. Kondisi di mana model memiliki performa yang baik terhadap data latih tetapi gagal menggeneralisasi dengan baik pada data uji. Terdapat salah satu teknik untuk mengatasi masalah ini yaitu data augmentasi. Data augmentasi adalah teknik untuk memperbanyak jumlah data latih secara buatan dengan cara membuat versi data yang telah dimodifikasi dari data yang sudah ada. Augmentasi yang diterapkan seperti rotasi, *flipping*, atau pergeseran warna, dengan mengasumsikan tidak mengubah makna atau label dari data aslinya [23]. Penggunaan teknik augmentasi data sebagai metode yang umum dan mudah untuk mengurangi *overfitting* [24].

2.2.3.1 Rotasi

Rotasi merupakan teknik augmentasi data dengan cara memutar gambar pada sudut tertentu. Rotasi dapat dilakukan dengan sudut tetap, seperti 15°, 45°, atau sudut acak. Rotasi pada gambar dapat membantu model untuk mengenali objek dari berbagai sudut pandang. Tujuannya adalah agar sistem tidak bingung ketika menemui gambar yang posisinya miring di dunia nyata. Jadi, meskipun pengambilan fotonya tidak tegak lurus, objek di dalamnya tetap bisa dikenali dengan baik [25].

2.2.3.2 Flip


Augmentasi data menggunakan metode flip dikategorikan sebagai pendekatan manipulasi geometris dasar yang berfungsi meningkatkan dataset pelatihan secara signifikan tanpa mengubah label kelas data yang sebenarnya. Teknik ini bekerja dengan membalikkan orientasi citra, baik secara vertikal maupun horizontal, yang bertujuan agar model dapat mengenali fitur objek dari berbagai sudut pandang [26].

2.2.3.3 Random Erasing

Random erasing merupakan teknik baru untuk augmentasi data. *Random erasing* dapat mengatasi masalah oklusi. Beberapa objek tidak selalu terlihat sepenuhnya dalam gambar, masalah ini disebut dengan oklusi. Objek tidak jarang terhalang atau tertutup oleh objek lain sehingga hanya sebagian yang terlihat. Hal ini membuat model sulit mengenali objek saat proses latih, jika beberapa bagian dari objek tidak terlihat atau tertutup. Dengan *random erasing*, objek akan sengaja dihapus atau ditutup secara acak di beberapa bagian oleh sebuah area berbentuk persegi panjang yang diisi dengan nilai acak pada gambar. Teknik ini membuat model tidak belajar hanya dari fitur tertentu pada objek. Dengan demikian, model menjadi tidak terlalu kompleks dan tidak menghafal pola tertentu pada gambar yang membuat model menjadi lebih *robust*. [27].

2.2.4 Convolutional Neural Network

Convolutional Neural Network (CNN) adalah salah satu model *deep learning* yang digunakan untuk memproses data citra. CNN terdiri dari lapisan konvolusi dan *pooling*, satu atau lebih lapisan *fully connected*, dan lapisan *output* di akhir. Lapisan konvolusi dan *pooling* berfungsi untuk ekstraksi fitur. Hasil dari ekstraksi fitur akan dikirim ke lapisan *fully connected* untuk dilakukannya klasifikasi. Istilah lain untuk lapisan *fully connected* adalah lapisan *dense* atau *Multi-Layer Perceptron* (MLP) [28].



Gambar 2.1 Ilustrasi Convolutional Neural Network

Merujuk pada gambar 2.1 proses CNN dimulai dengan penerimaan data citra sebagai masukan. Data ini selanjutnya diolah secara bertahap melalui serangkaian lapisan jaringan. Tujuan dari lapisan-lapisan tersebut adalah untuk mengekstraksi fitur-fitur penting dari citra, yang pada akhirnya digunakan untuk mengklasifikasikan citra itu ke dalam kelas-kelas yang relevan. Berikut ini adalah penjelasan mengenai lapisan-lapisan yang menyusun CNN:

1. Lapisan konvolusi

Lapisan konvolusi yang terdiri dari sejumlah kernel (filter) konvolusi yang berperan untuk mengekstrak fitur pada data input. Proses konvolusi yaitu melakukan pergeseran kernel di atas gambar input, kemudian nilai pada kernel dengan nilai piksel pada posisi yang bersesuaian akan dikalikan setelah itu dijumlahkan untuk menghasilkan *feature map*. *Feature map* yang dihasilkan akan digunakan sebagai satu kelas fitur gambar yang diekstraksi. Beberapa lapisan konvolusi akan ditumpukkan untuk mengekstrak fitur yang *higher-level* dan lebih lengkap.

2. Activation Function

Activation Function adalah fungsi matematis yang berperan penting dalam *neural network* dengan memperkuat representasi dan kemampuan untuk pembelajaran model. Tanpa adanya fungsi aktivasi, pemrosesan setiap lapisan hanya proses fungsi linier. Dengan adanya fungsi aktivasi, model dapat mengenal non-linieritas dalam jaringan. Fungsi aktivasi sebagai

fungsi keputusan untuk membantu model mempelajari pola yang kompleks. Beberapa fungsi aktivasi yang umum digunakan seperti Sigmoid, Tanh, ReLU, dan Leaky ReLU.

3. Lapisan pooling

Lapisan *pooling* ditambahkan setelah lapisan konvolusi menghasilkan *feature map*. Tujuan dari lapisan *pooling* adalah untuk mengurangi jumlah dimensi *feature map*, dan meminimalkan *overfitting*. Terdapat dua metode *pooling* yang umum digunakan, yaitu *max pooling* dan *average pooling*. Pada *max pooling*, nilai maksimum dari area yang oleh kernel (filter) diambil sebagai representasi area tersebut. Sedangkan pada *average pooling*, nilai rata-rata dari area yang kernel ambil sebagai representasi area tersebut.


4. Lapisan Fully Connected

Lapisan *fully connected* adalah lapisan yang biasanya ditempatkan di akhir dari jaringan CNN, bertujuan untuk klasifikasi. Pada lapisan ini, setiap neuron saling terhubung satu sama lain. Secara umum, CNN akan mengambil *feature map* yang dihasilkan dari proses sebelumnya, kemudian di-*flatten* menjadi vektor satu dimensi, lalu dikirim ke lapisan *fully connected*. Lapisan ini penting untuk integrasi informasi lokal yang memiliki sifat pembeda kelas yang telah diekstraksi oleh lapisan konvolusi dan *pooling* sebelumnya.

2.2.5 Residual Network

Arsitektur yang sering disebut dengan "ResNet" diperkenalkan oleh Kaiming He dkk didalam jurnal yang berjudul "*Deep Residual Learning for Image Recognition*" pada tahun 2015 [29]. *Residual Network* (ResNet) merupakan arsitektur CNN yang dirancang untuk mengatasi masalah degradasi pada *deep neural network*. Terjadinya degradasi disebabkan kedalaman *neural network* meningkat dan membuat akurasi model menurun dengan cepat. Degradasi bukan karena *overfitting* melainkan penambahan *layer* yang dalam

pada model yang cukup dalam, alhasil training error meningkat. Untuk mengatasi masalah ini, arsitektur ResNet memiliki konsep *residual learning* di mana beberapa *stacked layer* menyesuaikan *desired underlying mapping*. Konsep ini didukung dengan adanya *shortcut connections* yang melewati satu atau lebih *layer*. Terdapat perbedaan arsitektur yang dimana ResNet-34 dengan arsitektur yang mempunyai 34 *layer* tanpa *residual learning* yang dapat dilihat pada gambar 2.2.



Gambar 2.2 Gambaran ResNet-34 dan CNN 34 layer tanpa residual learning

ResNet memiliki beberapa jenis berdasarkan dengan jumlah *layer*. Terdapat ResNet-18 dengan 18 *layer*, ResNet-34 dengan 34 *layer*, ResNet-50 dengan 50 *layer*, dan lain-lain. Pada penelitian ini akan menggunakan arsitektur ResNet-18 dan ResNet-50 untuk membandingkan performa keduanya. Berikut struktur dari kedua arsitektur dapat dilihat pada tabel 2.2 dan tabel 2.3.

Tabel 2.2 Struktur ResNet-18

Nama Lapisan	Ukuran Output	34-Layer
Conv1	112×112	$7 \times 7, 64, \text{stride } 2$
Max Pooling	3×3	stride 2
Conv2_x	56×56	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$

Nama Lapisan	Ukuran Output	34-Layer
Conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$
Conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$
Conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$
Average Pooling		
Fully Connected Layer		
Softmax		

Tabel 2.3 Struktur ResNet-50

Nama Lapisan	Ukuran Output	34-Layer
Conv1	112×112	$7 \times 7, 64, \text{stride } 2$
Max Pooling	3×3	stride 2
Conv2_x	56×56	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$

Nama Lapisan	Ukuran Output	34-Layer
Conv3_x	28×28	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$
Conv4_x	14×14	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$
Conv5_x	7×7	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
Average Pooling		
Fully Connected Layer		
Softmax		

2.2.5.1 Residual Learning

Pada tahun 2016, Kaiming He dkk memperkenalkan konsep *residual learning* pada arsitektur *deep learning*. Lapisan-lapisan dalam jaringan disusun kembali untuk mempelajari fungsi residual yang mereferensikan input asli. Konsep *residual learning* ini membuat lapisan-lapisan jaringan cukup mempelajari selisih atau residual dari input asli, yaitu $\mathcal{F}(x) := \mathcal{H}(x) - x$, dibandingkan mempelajari fungsi target langsung yaitu $\mathcal{H}(x)$. Hasil dari pembelajaran fungsi residual ini kemudian ditambahkan ke input asli (x) tersebut ($\mathcal{F}(x) + x$). Pengoptimalan fungsi residual lebih efisien dibandingkan pemetaan asli, karena jaringan cukup menekan nilai residual mendekati nol untuk mencapai pemetaan identitas. Hal ini diimplementasikan melalui *shortcut connections*


yang menjumlahkan input identitas langsung ke output lapisan. Konsep ini juga dapat mengatasi masalah degradasi yang disebabkan karena penambahan kedalaman pada jaringan [29].

2.2.5.2 Shortcut Connections

Shortcut connections merupakan jalur koneksi yang melompati satu atau lebih lapisan jaringan. Dalam arsitektur ResNet, jalur koneksi ini melakukan *identity mapping*, yang mana *output* dari lapisan yang berupa fungsi residual ditambahkan dengan input asli. Secara matematis direpresentasikan sebagai $y = \mathcal{F}(x, \{W_i\}) + x$, di mana x adalah input dan y adalah output. Penggunaan *shortcut connections* memiliki keunggulan yaitu efisien. Dengan adanya jalur ini, tidak menambahkan parameter ekstra maupun meningkatkan kompleksitas komputasi pada jaringan [29].

2.2.6 Confusion Matrix

Confusion Matrix adalah tabel yang digunakan untuk mengevaluasi kinerja model klasifikasi. *Confusion Matrix* terdapat empat komponen utama, yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN). Matriks ini membantu menganalisis kemampuan klasifikasi model secara rinci, dengan melihat seberapa tepat hasil tebakan model jika dibandingkan dengan data yang sebenarnya [30]. *Confusion Matrix* bukan hanya digunakan untuk data yang memiliki dua kelas, tetapi matriks ini dapat digunakan untuk data multi-kelas. Ilustrasi *Confusion Matrix* multi-kelas dapat dilihat pada gambar 2.3.



Gambar 2.3 Ilustrasi Confusion Matrix Multi-Kelas

Keterangan:

1. *True Positive* (TP): jumlah data yang nilai aktualnya positif dan nilai prediksinya positif.
2. *True Negative* (TN): jumlah data yang nilai aktualnya negatif dan nilai prediksinya negatif.
3. *False Positive* (FP): jumlah data yang nilai aktualnya negatif dan nilai prediksinya positif.
4. *False Negative* (FN): jumlah data yang nilai aktualnya positif dan nilai prediksinya negatif.

Dari nilai komponen utama pada *Confusion Matrix*, dapat dilakukan perhitungan kinerja model menggunakan persamaan berikut.

1. Akurasi

Akurasi mengukur seberapa akurat model dalam mengklasifikasikan data.

Rumus akurasi dapat dilihat pada persamaan Rumus 2.1.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (\text{Rumus 2.1})$$

2. Precision

Precision mengukur seberapa akurat prediksi positif yang dibuat oleh

model. Nilainya dihitung dari rasio antara prediksi positif yang benar (TP) dibagi dengan keseluruhan data yang diprediksi positif oleh model (TP + FP). Rumus *precision* dapat dilihat pada persamaan Rumus 2.2.

$$Precision = \frac{TP}{TP + FP} \quad (\text{Rumus 2.2})$$

3. *Recall*

Recall adalah metrik yang menunjukkan kemampuan sebuah model dalam menemukan kembali semua data yang sebenarnya positif. Nilainya dihitung dari rasio antara prediksi positif yang benar (TP) dibagi dengan jumlah total data yang faktanya positif (TP + FN). Rumus *recall* dapat dilihat pada persamaan.

$$Recall = \frac{TP}{TP + FN} \quad (\text{Rumus 2.3})$$

4. *F1-Score*

F1-Score adalah rata-rata harmonik (harmonic mean) dari Precision dan Recall. Metrik ini menggabungkan kedua metrik tersebut untuk memberikan satu skor tunggal, yang sangat berguna terutama jika terdapat ketidakseimbangan kelas (imbalanced classes). Rumus *F1-Score* dapat dilihat pada persamaan.

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (\text{Rumus 2.4})$$

2.2.7 Matthews Correlation Coefficient

Matthews Correlation Coefficient (MCC) merupakan metrik evaluasi untuk klasifikasi biner maupun multi-kelas yang menghasilkan skor dalam interval [-1; +1], jika *classifier* memperoleh nilai tinggi untuk komponen dasar dari *confusion matrix* yaitu, akurasi, *precision*, *recall*, dan *false negative* (FN). MCC juga dapat digunakan pada klasifikasi multi-kelas. Nilai +1 menunjukkan klasifikasi sempurna, nilai mendekati 0 menunjukkan prediksi yang dibuat secara acak, dan

nilai -1 menunjukkan prediksi yang berlawanan sempurna dimana semua sampel negatif diprediksi sebagai positif dan sebaliknya. Keunggulan MCC adalah mampu dalam menangani *imbalanced data* dikarenakan MCC diakui *robust* terhadap *imbalanced data* [31]. Berikut persamaan MCC untuk klasifikasi multi-kelas yang dapat dilihat pada Rumus 2.5.

$$MCC = \frac{c \times s - \sum_k^K p_k \times t_k}{\sqrt{(s^2 - \sum_k^K p_k^2) \times (s^2 - \sum_k^K t_k^2)}} \quad (\text{Rumus 2.5})$$

Keterangan:

k: Jumlah total kelas

c: Jumlah total sampel yang diprediksi dengan benar (*True Positive*)

s: Jumlah total keseluruhan sampel

p_k : jumlah prediksi untuk kelas k (total elemen yang diprediksi sebagai kelas k)

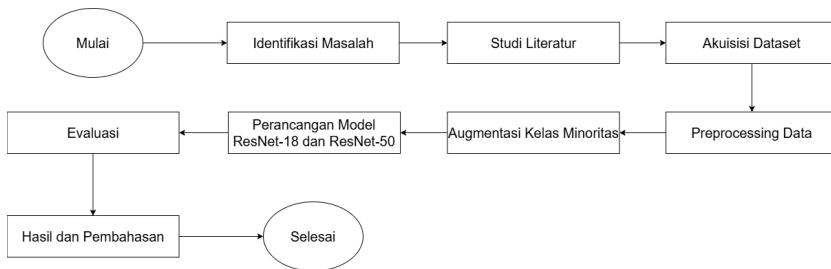
t_k : jumlah sampel aktual untuk kelas k (ground truth untuk kelas k)

BAB III

METODE PENELITIAN

3.1 Alur Penelitian

Penelitian ini berfokus pada augmentasi data kelas minoritas untuk membandingkan hasil atau performa arsitektur ResNet-18 dan ResNet-50. Alur penelitian dijelaskan pada diagram yang dapat dilihat pada Gambar 3.1. Penelitian dimulai dari identifikasi masalah hingga selesai.



Gambar 3.1 Diagram Alur Penelitian

3.2 Penjabaran Langkah Penelitian

Penjelasan dari setiap langkah pada alur penelitian akan dijelaskan secara rinci untuk memberikan detail yang jelas terhadap metode yang digunakan. Berikut penjelasan dari setiap langkah penelitian tersebut.

3.2.1 Identifikasi Masalah

Tahap awal yang dilakukan sebelum penelitian adalah identifikasi masalah. Identifikasi dilakukan dengan cara menelaah karakteristik dataset DermaMNIST yang digunakan dalam penelitian klasifikasi citra penyakit kulit. Pada penelitian klasifikasi citra penyakit kulit menggunakan dataset DermaMNIST yang dilakukan oleh Nerma Kadric dkk pada tahun 2025, terdapat ketidakseimbangan kelas yang signifikan di mana berdampak terhadap performa

model [13]. Berdasarkan hal tersebut, dilakukan eksplorasi terhadap dataset dan ditemukannya kelas yang jumlah data nya sedikit (kelas minoritas) dibandingkan kelas lainnya yang memiliki jumlah data yang banyak (kelas mayoritas). Kondisi ketidakseimbangan kelas ini menjadi dasar dilakukannya penelitian untuk mengevaluasi efektivitas teknik augmentasi pada kelas minoritas dalam membandingkan performa model ResNet-18 dan ResNet-50 pada klasifikasi citra penyakit kulit menggunakan dataset DermaMNIST.

3.2.2 Studi Literatur

Tahap studi literatur dilakukan dengan mengumpulkan dan mengkaji berbagai sumber akademis terpercaya, meliputi jurnal ilmiah dan publikasi terkini yang relevan dengan penelitian. Referensi yang dikumpulkan berdasarkan pada topik klasifikasi citra penyakit kulit menggunakan deep learning, imbalanced data pada multi-kelas, penanganan imbalanced data melalui teknik augmentasi, dan model ResNet-18 dan ResNet-50. Tahap ini bertujuan untuk membangun landasan teoritis yang kuat dan berkaitan dengan penelitian yang dilakukan.

3.2.3 Akuisisi Dataset

Proses pengumpulan data dalam riset ini menggunakan dataset DermaMNIST yang diambil dari platform MedMNIST, yaitu open-source yang menyediakan koleksi dataset citra medis. Dataset DermaMNIST berisi gambar-gambar penyakit kulit berwarna dengan dimensi 28x28 piksel dan 224x224 piksel, yang dikelompokkan menjadi 7 kelas berbeda sesuai jenis penyakit kulitnya. Dataset ini terdiri dari total 10.015 gambar yang terbagi menjadi data latih, data validasi, dan data uji. Ketujuh kelas penyakit kulit tersebut meliputi actinic keratosis and intraepithelial carcinoma, basal cell carcinoma, benign keratosis-like lesions, dermatofibroma, melanoma, melanocytic nevi, dan vascular lesions.

3.2.4 Preprocessing Data

Sebelum pelatihan model melakukan dataset yang sudah dikumpulkan, data akan diolah terlebih dahulu. Tahapan tersebut disebut dengan *Preprocessing Data*. Tahap *preprocessing data* akan melakukan *resizing* dan normalisasi data. Pada tahap *resizing*, data di-*resize* dari ukuran aslinya yaitu 28x28 menjadi 224x224 agar sesuai dengan dimensi input *default* pada arsitektur ResNet, baik ResNet-18 maupun ResNet-50. Proses normalisasi dilakukan untuk mentransformasi rentang nilai piksel dari [0, 255] menjadi [0, 1] dengan tujuan menstabilkan konvergensi selama pelatihan model dan meningkatkan efisiensi komputasi. Dataset DermaMNIST yang digunakan dalam penelitian ini terdiri dari 10.015 citra. Pembagian data mengikuti pembagian yang sudah disediakan oleh dataset, yaitu 7.007 citra untuk data *training*, 1.003 citra untuk data *validation*, dan 2.005 citra untuk data *test*.

3.2.5 Augmentasi Kelas Minoritas

Augmentasi data merupakan teknik untuk meningkatkan jumlah data pelatihan dengan menghasilkan variasi baru dari data yang sudah tersedia melalui berbagai modifikasi seperti rotasi, *flipping*, dan *cropping*. Teknik ini bertujuan untuk memperbesar ukuran dan meningkatkan keragaman dataset sehingga dapat mengurangi *overfitting* dan meningkatkan performa model [32]. Pada penelitian ini, augmentasi hanya diterapkan pada data di kelas minoritas. Metode yang digunakan untuk augmentasi meliputi rotasi, *flip*, dan *random erasing*. Gambar akan dirotasi secara acak dengan rentang sudut 0° hingga 45° derajat. Pada metode *flip*, gambar akan di-*flip* secara vertikal dan horizontal. Pada metode *random erasing*, gambar akan diberikan area persegi panjang dengan rasio aspek acak, kemudian nilai piksel asli diganti dengan nilai piksel acak (*noise*) atau rata-rata dataset (*mean*) [33].

3.2.6 Perancangan Model ResNet-18 dan ResNet-50

Tahapan ini merupakan penjelasan pada perancangan model ResNet-18 dan ResNet-50. Model ResNet menggunakan mekanisme *residual learning* dengan *skip connections* untuk mengatasi masalah *vanishing gradient*, dimana ResNet-18 memiliki 18 lapisan dan ResNet-50 memiliki 50 lapisan. Perancangan diawali dengan pembagian dataset menjadi data *training*, data *validation*, dan data *test*. Data *training* akan dilakukan augmentasi data pada kelas minoritas. Setelah pembagian dan augmentasi, dataset digunakan sebagai input pada model ResNet-18 dan ResNet-50 dan model melakukan *training*. Hasil *training* model akan disimpan dan dievaluasi untuk membandingkan performa antara kedua model.

3.2.7 Evaluasi

Tahapan ini adalah penjelasan terkait evaluasi yang akan digunakan pada model. Evaluasi terhadap model dilakukan menggunakan tiga cara, yakni *Confusion Matrix*, metrik evaluasi, dan *Matthews Correlation Coefficient* (MCC). *Confusion Matrix* digunakan untuk mengevaluasi kinerja model guna memberikan rincian mengenai tingkat efektivitas model. Nilai yang dihasilkan dari *Confusion Matrix* berupa nilai *True Positive*, *False Positive*, *True Negative*, dan *False Negative*. Nilai-nilai tersebut kemudian digunakan sebagai dasar perhitungan metrik evaluasi standar yang meliputi Akurasi, Presisi, *Recall*, dan *F1-Score*. Evaluasi ini juga menerapkan *Matthews Correlation Coefficient* (MCC). MCC digunakan karena kemampuannya memberikan penilaian yang lebih pada data yang tidak seimbang dibandingkan akurasi biasa.

3.3 Alat dan Bahan Tugas Akhir

Berisi alat-alat dan bahan-bahan yang digunakan dalam penelitian.

3.3.1 Alat

Berikut merupakan alat-alat yang digunakan dalam pelaksanaan penelitian:

1. Laptop dengan spesifikasi windows 11, processor Intel(R) Core(TM) i5-11400H 11th Gen @ 2.70GHz, memory 16 GB, dan graphics card NVIDIA GeForce GTX 1650, SSD 512 GB
2. Code editor Microsoft Visual Studio Code
3. Python 3.10
4. Libray python: PyTorch, NumPy, Matplotlib.

3.3.2 Bahan

Penulis menggunakan dataset DermaMNIST yang merupakan bagian dari MedMNIST. Dataset terdiri dari citra penyakit kulit dengan 7 kelas berbeda, yaitu *melanocytic nevi* sebanyak 6705 gambar, *melanoma* sebanyak 1113 gambar, *benign keratosis-like lesions* sebanyak 1099 gambar, *basal cell carcinoma* sebanyak 514 gambar, *actinic keratoses and intraepithelial carcinoma* sebanyak 327 gambar, *vascular lesions* sebanyak 142 gambar, dan *dermatofibroma* sebanyak 115 gambar. Dataset ini digunakan untuk pelatihan dan pengujian model klasifikasi. DermaMNIST tersedia secara open access untuk digunakan dalam penelitian.

3.4 Metode Pengembangan

Metode yang akan digunakan pada penelitian adalah metode *Convolutional Neural Network* (CNN) dengan arsitektur ResNet-18 dan ResNet-50 untuk klasifikasi jenis penyakit kulit berdasarkan dataset DermaMNIST yang dimana membandingkan performa kedua arsitektur sebelum dan sesudah dilakukan augmentasi data yang dikhususkan untuk kelas minoritas.

3.5 Ilustrasi Perhitungan Metode

Berikut adalah ilustrasi perhitungan metode yang digunakan dalam penelitian.

3.5.1 Ilustrasi Perhitungan Konvolusi

Perhitungan lapisan konvolusi dilakukan dengan cara mengalikan matriks filter (*kernel*) dengan matriks input pada gambar. Misalkan terdapat matriks gambar sebesar 7x7 dan kernel 5x5. Selain itu, terdapat parameter lain yaitu *padding* dengan nilai 0 dan *stride* sebanyak 1 kali *kernel* bergeser. Contoh matriks input pada gambar 7x7 dapat dilihat pada Gambar 3.2.

4	6	3	8	5	7	2
9	1	4	6	3	8	5
5	7	2	9	1	4	6
3	8	5	7	2	9	1
6	3	8	5	7	2	9
2	9	1	4	6	3	8
7	2	9	1	4	6	3


Gambar 3.2 Matriks Input Gambar 7x7

Kemudian terdapat *kernel* 5x5 yang akan digunakan untuk proses konvolusi. Contoh matriks *kernel* dapat dilihat pada Gambar 3.3.

1	1	1	1	1
1	-2	-2	2	1
1	-2	-6	-2	1
1	2	-2	-2	1
1	1	1	1	1

Gambar 3.3 Matriks Kernel 7x7

Selanjutnya dilakukan proses konvolusi dengan mengalikan matriks *kernel* dengan matriks input gambar. Hasil perkalian antar kedua matriks akan dijumlahkan dan menghasilkan sebuah nilai pertama dari hasil proses konvolusi. Proses konvolusi dapat dilihat pada Gambar 3.4.




Gambar 3.4 Contoh Hasil Konvolusi

Berikut adalah perhitungan dari proses konvolusi pertama:

$$\begin{aligned}
& (4 \times 1) + (6 \times 1) + (3 \times 1) + (8 \times 1) + (5 \times 1) + (9 \times 1) \\
& + (1 \times (-2)) + (4 \times (-2)) + (6 \times 2) + (3 \times 1) + (5 \times 1) + (7 \times (-2)) \\
& + (2 \times (-6)) + (9 \times (-2)) + (1 \times 1) + (3 \times 1) + (8 \times 2) + (5 \times (-2)) \\
& + (7 \times (-2)) + (2 \times 1) + (6 \times 1) + (3 \times 1) + (8 \times 1) + (5 \times 1) \\
& + (7 \times 1) = 28
\end{aligned}$$

Proses konvolusi dilakukan secara berulang sesuai dengan parameter yang sudah ditentukan yaitu dengan pergeseran *stride* sebanyak 1 kali dan tanpa *padding*. Hasil akhir dari proses konvolusi ini adalah sebuah matriks output berukuran 3x3. Hasil akhir dari proses konvolusi dapat dilihat pada Gambar .



Gambar 3.5 Contoh Hasil Konvolusi

28	9	37
-11	-6	15
5	-19	11

Gambar 3.6 Hasil Akhir Proses Konvolusi

Berdasarkan gambar 3.6 menunjukkan bahwa hasil akhir dari proses

konvolusi menghasilkan matriks output berukuran 3x3 yang dimana matriks yang dihasilkan lebih kecil dibandingkan dengan matriks input awal yang berukuran 7x7. Ukuran matriks output pada proses konvolusi dapat dihitung menggunakan rumus berikut:

$$OutputSize = \frac{I - F + 2P}{S} + 1$$

Keterangan:

I = Ukuran Input


F = Ukuran Kernel

P = Padding

S = Stride

3.5.2 Ilustrasi Perhitungan Fungsi Aktivasi ReLU

Fungsi aktivasi ReLU (Rectified Linear Unit) beroperasi dengan mengubah setiap nilai negatif dalam matriks menjadi 0, sedangkan nilai positif tidak mengalami perubahan. Fungsi ini diterapkan pada lapisan konvolusi dengan tujuan menambahkan non-linearitas ke dalam arsitektur model [18]. Berikut contoh perhitungan fungsi aktivasi ReLU pada output yang dihasilkan dari lapisan konvolusi sebelumnya.




Gambar 3.7 Visualisasi Fungsi Aktivasi ReLU

3.5.3 Max Pooling dan Average Pooling


Proses pada lapisan *pooling* terdapat 2 jenis, *max pooling* dan *average pooling*. Max pooling yaitu mengekstrak nilai tertinggi dari setiap wilayah pada matriks yang telah melalui fungsi aktivasi ReLU. Kernel berukuran 2x2

digunakan dalam lapisan Pooling ini dengan parameter stride bernilai 1. Contoh implementasi perhitungan pada *max pooling* disajikan pada ilustrasi berikut:



Gambar 3.8 Visualisasi Perhitungan Max Pooling

Average pooling yaitu mengekstrak nilai rata-rata dari setiap wilayah pada matriks yang telah melalui fungsi aktivasi ReLU. Kernel berukuran 2x2 digunakan dalam lapisan Pooling ini dengan parameter stride bernilai 1. Contoh implementasi perhitungan pada *average pooling* disajikan pada ilustrasi berikut:



Gambar 3.9 Visualisasi Perhitungan Average Pooling

3.6 Rancangan Pengujian

Setelah proses pelatihan model selesai, model dievaluasi menggunakan *confusion matrix* dan *Matthews Correlation Coefficient* (MCC). Evaluasi ini bertujuan untuk mengukur kemampuan model dalam menggeneralisasi data baru.

3.6.1 Pengukuran *Confusion Matrix*

Pada penelitian ini, kinerja model diukur menggunakan metrik akurasi, presisi, recall, dan F1-Score yang didasarkan oleh pada confusion matrix. Matriks ini menggambarkan hubungan antara kelas aktual (*ground truth*) dengan kelas prediksi yang dihasilkan oleh model. Sebagai contoh perhitungan, tabel 3.1 menyajikan contoh data yang dihasilkan prediksi model pada data uji dari masing-masing kelasnya, yaitu *Actinic Keratosis and intraepithelial Carcinoma* (akiec), *Basal Cell Carcinoma* (bcc), *Benign Keratosis-Like Lesions* (bkl), *Dermatofibroma* (df), *Melanoma* (mel), *Melanocytic Nev* (nv), dan *Vascular Lesions* (vasc).

Tabel 3.1 Contoh Hasil Confusion Matrix

Aktual / Prediksi	akiec	bcc	bkl	df	mel	nv	vasc	Total Aktual
akiec	8	2	1	0	0	1	0	12
bcc	1	12	2	0	1	2	0	18
bkl	2	1	15	0	2	3	0	23
df	0	0	1	6	1	1	0	9
mel	0	1	3	0	14	4	0	22
nv	1	3	5	1	5	40	1	56
vasc	0	0	0	0	0	1	9	10
Total Prediksi	12	19	27	7	23	52	10	Total: 150

Untuk mengukur kinerja model terutama pada multi-kelas, perhitungan dilakukan untuk setiap kelas nya. Berikut perhitungan menggunakan kelas *Benign Keratosis-Like Lesions* (bkl) sebagai contoh.

Berdasarkan data yang ada pada tabel 3.1, didapatkannya nilai *True Positive* (TP), *False Positive* (FP), *True Negative* (TN), dan *False Negative* (FN) untuk kelas bkl sebagai berikut:

1. *True Positive*

Model berhasil memprediksi citra kelas bkl secara benar, di mana sampel yang memang termasuk kelas bkl diklasifikasikan sebagai bkl.

$$TP = 15$$

2. *False Positive*

Model memprediksi suatu citra sebagai kelas bkl, namun citra tersebut sebenarnya kelas lain dan bukan termasuk kelas bkl.

$$FP = 1 + 2 + 1 + 3 + 5 + 0 = 12$$

3. *False Negative*

Model salah memprediksi yang mana kelas bkl diklasifikasikan sebagai kelas lain.

$$FN = 2 + 1 + 0 + 2 + 3 + 0 = 8$$

4. *True Negative*

Model secara tepat mengklasifikasikan citra yang tidak termasuk dalam kelas bkl ke dalam kelas lain yang sesuai (Total seluruh data dikurangi TP, FP, dan FN).

$$TN = 150 - (15 + 12 + 8) = 150 - 35 = 115$$

Nilai dari masing-masing komponen pada *confusion matrix* sudah didapatkan. Selanjutnya menghitung metrik evaluasi yang meliputi *accuracy*, *precision*, *recall*, dan *F1-Score* untuk mengukur kinerja model.

1. *Accuracy*

Accuracy mengukur seberapa akurat model dalam mengklasifikasikan data, menilai seberapa baik model memprediksi hasil. Perhitungan menggunakan rumus yang sesuai pada Rumus 2.1. Berikut perhitungan *accuracy*:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Accuracy = \frac{15 + 115}{15 + 115 + 12 + 8} = \frac{130}{150} = 0,8667 (86,67\%)$$

2. *Precision*

Perhitungan *precision* menggunakan rumus yang sesuai pada Rumus 2.2. *Precision* diukur pada masing-masing kelas, sebagai contoh perhitungan dilakukan pada kelas bkl. Berikut perhitungan *precision*:

$$Precision = \frac{TP}{TP + FP}$$

$$Precision = \frac{15}{15 + 12} = \frac{15}{27} = 0,5556(55,56\%)$$

3. *Recall*

Perhitungan *recall* menggunakan rumus yang sesuai pada Rumus 2.3. *Recall* diukur pada masing-masing kelas, sebagai contoh perhitungan dilakukan pada kelas bkl. Berikut perhitungan *recall*:

$$Recall = \frac{TP}{TP + FN}$$

$$Recall = \frac{15}{15 + 8} = \frac{15}{23} = 0,6521(65,21\%)$$

4. *F1-Score*

Perhitungan *F1-Score* menggunakan rumus yang sesuai pada Rumus 2.4. *F1-Score* diukur pada masing-masing kelas, sebagai contoh perhitungan dilakukan pada kelas bkl. Berikut perhitungan *F1-Score*:

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

$$F1 - Score = 2 \times \frac{0,5556 \times 0,6521}{0,5556 + 0,6521} = 2 \times \frac{0,3623}{1,2077} = 0,5999(59,99\%)$$

Tabel 3.2 menyajikan hasil lengkap dari perhitungan *precision*, *recall*, dan *F1-score* dari ketujuh kelas. Tabel 3.2 dapat dilihat dibawah ini.

Tabel 3.2 Hasil Perhitungan Metrik Evaluasi per Kelas

	<i>Precision</i>	<i>Recall</i>	<i>F1-score</i>
akiec	0,6667	0,6667	0,6667
bcc	0,6315	0,6667	0,6486
bkl	0,5556	0,6521	0,5999
df	0,8571	0,6667	0,7500
mel	0,6086	0,6363	0,6221
nv	0,7692	0,7142	0,7406
vasc	0,9	0,9	0,9

3.6.2 Perhitungan Macro Average

Macro average digunakan untuk mengevaluasi kinerja model secara objektif tanpa dipengaruhi oleh jumlah sampel data pada setiap kelas. Nilai *F1-Score* dihitung secara terpisah untuk masing-masing kelas, kemudian dirata-ratakan secara aritmatika sederhana. Untuk contoh perhitungan, perhitungan *macro average* menggunakan nilai *F1-Score* dari masing-masing kelas yang pada tabel 3.2. Berikut perhitungan *macro average*:

$$\begin{aligned}
 \text{Macro Average} &= \frac{F1_{akiec} + F1_{bcc} + F1_{bkl} + F1_{df}}{7} \\
 &\quad + \frac{F1_{mel} + F1_{nv} + F1_{vasc}}{7} \\
 \text{Macro Average} &= \frac{0,6667 + 0,6486 + 0,5999 + 0,7500 + 0,6221 + 0,7406 + 0,9}{7} \\
 &= \frac{4,9279}{7} = 0,7040 \text{ (70,40\%)}
 \end{aligned}$$

3.6.3 Perhitungan Matthews Correlation Coefficient

Matthews Correlation Coefficient digunakan untuk mengukur kualitas pada klasifikasi biner maupun multi-kelas. Koefisien ini memperhitungkan *true* dan *false positives*, dan *negatives*. MCC adalah nilai korelasi koefisien antara -1 dan +1. Koefisien +1 mewakili prediksi yang sempurna, 0 mewakili prediksi acak rata-rata, dan -1 mewakili prediksi terbalik. MCC memperhitungkan seluruh elemen *confusion matrix* (TP, TN, FP, FN). Rumus MCC untuk multi-kelas adalah sebagai berikut.

$$MCC = \frac{c \times s - \sum_k^K p_k \times t_k}{\sqrt{(s^2 - \sum_k^K p_k^2) \times (s^2 - \sum_k^K t_k^2)}}$$

Keterangan:

k: Jumlah total kelas

c: Jumlah total sampel yang diprediksi dengan benar (*True Positive*)

s: Jumlah total keseluruhan sampel

p_k : jumlah prediksi untuk kelas k (total elemen yang diprediksi sebagai kelas k)

t_k : jumlah sampel aktual untuk kelas k (ground truth untuk kelas k)

Pertama mengidentifikasi nilai variabel yang diperlukan pada kelas bkl, yang mana diperoleh nilai-nilai berikut:

1. K (Jumlah total kelas) = 7

2. c (Jumlah total yang diprediksi dengan benar) = 8 + 12 + 15 + 6 + 14 + 40 + 9 = 104

3. s (Jumlah total keseluruhan) = 150

4. p_k (Jumlah prediksi untuk kelas bkl)

$p_{akiec} = 12$, $p_{bcc} = 19$, $p_{bkl} = 27$, $p_{df} = 7$, $p_{mel} = 23$, $p_{nv} = 52$, $p_{vasc} = 10$

5. t_k (Jumlah sampel aktual untuk kelas bkl)

$t_{akiec} = 12$, $t_{bcc} = 18$, $t_{bkl} = 23$, $t_{df} = 9$, $t_{mel} = 22$, $t_{nv} = 56$, $t_{vasc} = 10$

Setelah mengidentifikasi nilai variabel yang diperlukan, selanjutnya melakukan perhitungan secara bertahap.

1. Menghitung $\sum_k^K p_k \times t_k$

$$\begin{aligned}\sum_k^K p_k \times t_k &= (12 \times 12) + (19 \times 18) + (27 \times 23) + (7 \times 9) + (23 \times 22) + (52 \times 56) + (10 \times 10) \\ &= 144 + 342 + 621 + 63 + 506 + 2.912 + 100 = 4.688\end{aligned}$$

2. Menghitung $\sum_k^K p_k^2$ dan $\sum_k^K t_k^2$

$$\begin{aligned}\sum_k^K t_k^2 &= 12^2 + 18^2 + 23^2 + 9^2 + 22^2 + 56^2 + 10^2 \\ &= 144 + 324 + 529 + 81 + 484 + 3.136 + 100 = 4.798\end{aligned}$$

$$\begin{aligned}\sum_k^K p_k^2 &= 12^2 + 19^2 + 27^2 + 7^2 + 23^2 + 52^2 + 10^2 \\ &= 144 + 361 + 729 + 49 + 529 + 2.704 + 100 = 4.616\end{aligned}$$

3. Menghitung nilai MCC

$$MCC = \frac{(104 \times 150) - 4.688}{\sqrt{(150^2 - 4.616) \times (150^2 - 4.798)}}$$

$$MCC = \frac{15.600 - 4.688}{\sqrt{(22.500 - 4.616) \times (22.500 - 4.798)}}$$

$$MCC = \frac{10.912}{\sqrt{17.884 \times 17.702}}$$

$$MCC = \frac{10.912}{\sqrt{316.582.568}}$$

$$MCC = \frac{10.912}{17.792,76} \approx 0,613$$

Berdasarkan hasil perhitungan ilustrasi di atas menunjukkan nilai MCC sebesar 0,613. Nilai ini mengindikasikan korelasi positif yang cukup kuat antara hasil prediksi model dengan label sebenarnya, meskipun terdapat ketidakseimbangan jumlah data antar kelas.

DAFTAR PUSTAKA

- [1] Margaret Chustecki. “Benefits and Risks of AI in Health Care: Narrative Review”. *Interact J Med Res* 13 (2024), e53616. 1929-073X.
- [2] Na Kyung Lee and Jong Seung Kim. “Status and trends of the digital healthcare industry”. *Healthcare Informatics Research* 30.3 (2024), pp. 172–183.
- [3] Irohito Nozomi, Febri Aldi, and Rio Bayu Sentosa. “Views on Deep Learning for Medical Image Diagnosis”. *Journal of Applied Engineering and Technological Science (JAETS)* 4.1 (2022), pp. 547–553.
- [4] Mengfang Li et al. “Medical image analysis using deep learning algorithms”. *Frontiers in public health* 11 (2023), p. 1273253.
- [5] Lanting He, Lan Luan, and Dan Hu. “Deep learning-based image classification for AI-assisted integration of pathology and radiology in medical imaging”. *Frontiers in Medicine* 12 (2025), p. 1574514.
- [6] Nurkhasanah Nurkhasanah and Murinto Murinto. “Klasifikasi penyakit kulit wajah menggunakan metode convolutional neural network”. *Sainteks* 18.2 (2021), pp. 183–190.
- [7] Nadia Ifti Khani and Sindhu Rakasiwi. “Penerapan Convolutional Neural Network dengan ResNet-50 untuk Klasifikasi Penyakit Kulit Wajah Efektif”. *Edumatic: Jurnal Pendidikan Informatika* 9.1 (2025), pp. 217–225.
- [8] Alifia Revan Prananda et al. “Klasifikasikan Jenis Cacat Kulit Menggunakan SMOTE-GoogLeNet”. *JITU: Journal Informatic Technology And Communication* 8.1 (2024), pp. 21–30.
- [9] Janet Wang et al. “From Majority to Minority: A Diffusion-based Augmentation for Underrepresented Groups in Skin Lesion Analysis”.

- International Conference on Medical Image Computing and Computer-Assisted Intervention*. Springer. 2024, pp. 14–23.
- [10] Micheila Jiemesha and Daniel Martomanggolo Wonohadidjojo. “Classification of Skin Diseases Using Transfer Learning with ResNet-50 Architecture and Data Preprocessing Using Real-ESRGAN and Wiener Filter”. *INSYST: Journal of Intelligent System and Computation* 7.1 (2025), pp. 01–10.
 - [11] Sofia Biju Francis and Jai Prakash Verma. “Deep CNN ResNet-18 based model with attention and transfer learning for Alzheimer’s disease detection”. *Frontiers in Neuroinformatics* 18 (2025), p. 1507217.
 - [12] 1st Lt Pushkar Aggarwal. “Data augmentation in dermatology image recognition using machine learning”. *Skin Research and Technology* 25.6 (2019), pp. 815–820.
 - [13] Nerma Kadric, Amila Akagic, and Medina Kapo. *Improving Diagnostic Accuracy of Pigmented Skin Lesions With CNNs: an Application on the DermaMNIST Dataset*. 2025. arXiv: [2507.12961 \[eess.IV\]](#).
 - [14] Ian Mateos Gonzalez et al. *Lightweight Deep Models for Dermatological Disease Detection: A Study on Instance Selection and Channel Optimization*. 2025. arXiv: [2504.01208 \[eess.IV\]](#).
 - [15] X XuRonald et al. “A low-cost high-performance data augmentation for deep learning-based skin lesion classification”. *BME frontiers* (2022).
 - [16] Arindam Halder et al. “A fuzzy rank-based deep ensemble methodology for multi-class skin cancer classification”. *Scientific Reports* 15.1 (2025), p. 6268.
 - [17] Gogor Putra Hafi Puja Gusti et al. “Implementasi Algoritma Convolutional Neural Network (Resnet-50) untuk Klasifikasi Kanker Kulit Benign dan Malignant: Implementation of Convolutional Neural Network Algorithm (ResNet-50) for Benign and Malignant Skin Cancer

- Classification". *MALCOM: Indonesian Journal of Machine Learning and Computer Science* 4.3 (2024), pp. 984–992.
- [18] Jiancheng Yang et al. "MedMNIST v2 - A large-scale lightweight benchmark for 2D and 3D biomedical image classification". *Scientific Data* 10.1 (Jan. 2023). 2052-4463.
 - [19] Clay J. Cockerell. "Histopathology of incipient intraepidermal squamous cell carcinoma ("actinic keratosis")". *Journal of the American Academy of Dermatology* 42.1, Part 2 (2000), S11–S17. 0190-9622.
 - [20] Nicole Basset-Seguin and Florian Herms. "Update on the management of basal cell carcinoma". *Acta dermato-venereologica* 100.11 (2020), p. 5750.
 - [21] Philipp Tschandl, Cliff Rosendahl, and Harald Kittler. "The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions". *Scientific data* 5.1 (2018), pp. 1–9.
 - [22] Haibo He and Eduardo A. Garcia. "Learning from Imbalanced Data". *IEEE Transactions on Knowledge and Data Engineering* 21.9 (2009), pp. 1263–1284.
 - [23] Connor Shorten and Taghi M Khoshgoftaar. "A survey on image data augmentation for deep learning". *Journal of big data* 6.1 (2019), pp. 1–48.
 - [24] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. "ImageNet Classification with Deep Convolutional Neural Networks". *Advances in Neural Information Processing Systems*. Ed. by F. Pereira et al. Vol. 25. Curran Associates, Inc., 2012.
 - [25] Muhammad Mega Nugraha et al. "Augmentasi Data Pengenalan Citra Batik Yogyakarta Menggunakan Pendekatan Random Crop, Rotate, Dan Mixup". *Prosiding Seminar Nasional Informatika Bela Negara (SANTIKA)* 5.1 (2025), pp. 152–158.

- [26] Dede Husen. “EVALUASI TEKNIK AUGMENTASI DATA UNTUK KLASIFIKASI TUMOR OTAK MENGGUNAKAN CNN PADA CITRA MRI”. *TEKNIMEDIA: Teknologi Informasi dan Multimedia* 5.2 (2024), pp. 219 –.
- [27] Zhun Zhong et al. “Random Erasing Data Augmentation”. *Proceedings of the AAAI Conference on Artificial Intelligence* 34.07 (2020), pp. 13001–13008.
- [28] Y. Lecun et al. “Gradient-based learning applied to document recognition”. *Proceedings of the IEEE* 86.11 (1998), pp. 2278–2324.
- [29] Kaiming He et al. *Deep Residual Learning for Image Recognition*. 2015. arXiv: [1512.03385 \[cs.CV\]](https://arxiv.org/abs/1512.03385).
- [30] Nurul Khasanah et al. “Skin cancer classification using random forest algorithm”. *Sisfotenika* 11.2 (2021), pp. 137–147.
- [31] Davide Chicco and Giuseppe Jurman. “The Matthews correlation coefficient (MCC) should replace the ROC AUC as the standard metric for assessing binary classification”. *BioData Mining* 16.1 (2023), p. 4.
- [32] Kiran Maharana, Surajit Mondal, and Bhushankumar Nemade. “A review: Data pre-processing and data augmentation techniques”. *Global Transitions Proceedings* 3.1 (2022). International Conference on Intelligent Engineering Approach(ICIEA-2022), pp. 91–99. 2666-285X.
- [33] S Febrian Tumewu, DH Setiabud, and Indar Sugiarto. “Klasifikasi Motif Batik menggunakan metode Deep Convolutional Neural Network dengan Data Augmentation”. *Jurnal Infra* 8.2 (2020), pp. 189–194.